DeepSeek AI技术洞察报告

报告日期: 2026年03月18日
生成时间: 08:26:06
数据来源: Tavily Search, 企业博客, 新闻媒体
洞察范围: 模型发布、技术动态、产品更新

一、公司概况

公司名称: DeepSeek
主要产品: DeepSeek-V3,R1
检索优先级: 高

二、最新动态检索

2.1 产品/模型发布

Answer

DeepSeek is set to release its latest AI model, DeepSeek-V4, in February, aiming to enhance code generation capabilities. The model is expected to outperform previous versions and rival top AI models like Gemini and ChatGPT.

Sources

- **知情人士：DeepSeek将于2月发布其最新旗舰AI模型 - 新浪财经** (relevance: 89%) https://finance.sina.com.cn/tech/2026-01-09/doc-inhftpvn1292475.shtml?cre=tianyi&mod=pchp&loc=35&r=0&rfunc=42&tj=cxvertical_pc_hp&tr=12 据两位知情人士透露，深度求索（DeepSeek）预计未来几周推出新一代旗舰级AI模型V4，主打强劲代码生成能力，是2024年12月发布的V3模型迭代版。
- **DeepSeek 时间线与模型发布速览 - AI 工具箱** (relevance: 87%) https://fishersama.com/deepseek-timeline 2025年1月20日，DeepSeek推出了推理模型DeepSeek-R1，并同步开源其模型权重，通过大规模强化学习技术显著提升推理能力，性能媲美顶尖闭源产品，迅速引发全球关注。MIT 许可均可

- **DeepSeek 计划二月中旬发布新模型DeepSeek-V4 - 知乎** (relevance: 86%) https://www.zhihu.com/question/1993329446883651767 我是相信DeepSeek在2月份肯定也会有一个大模型发布，我也认为大概率会是大版本的V4，我也认为下一个版本Coding能力很强，会比Anthropic和OpenAI的一些模型更

- **DeepSeek新AI模型「匹敵Gemini和ChatGPT」 - Yahoo 財經** (relevance: 84%) https://hk.finance.yahoo.com/news/deepseek%E7%99%BC%E5%B8%83%E6%96%B0%E4%BA%BA%E5%B7%A5%E6%99%BA%E8%8%E7%A8%B1%E8%A1%A8%E7%8F%BE%E5%8F%AF%E8%88%87gemini%E5%92%8Cchatgpt%E7 # 雅虎香港財經. #### 自願醫保. # DeepSeek新AI模型「匹敵Gemini和ChatGPT」. 【彭博】— 中國企業深度求索(DeepSeek)公佈數周前發布的實驗性人工智能模型的兩個新版本，增加了幾處新功能，公司稱它們將有助於結合推理並自主執行某些操作。. DeepSeek在9月發布的模型由於其實驗性質被稱為DeepSeek-V3.2-Exp，但最新版本則被簡單地命名為 DeepSeek-V3.2。該初創公司表示，這項新服務在多項推理基準測試上的表現可與OpenAI的旗艦人工智能模型GPT-5相匹敵，表明中國的開源系統至少在某些指標方面仍能與矽谷最前沿的模型競爭。. 公司在X...

- **DeepSeek-V3 正式发布** (relevance: 83%) https://api-docs.deepseek.com/zh-cn/news/news1226 # DeepSeek-V3 正式发布. 今天，我们全新系列模型 DeepSeek-V3 首个版本上线并同步开源。. 登录官网 chat.deepseek.com 即可与最新版 V3 模型对话。API 服务已同步更新，接口配置无需改动。当前版本的 DeepSeek-V3 暂不支持多模态输入输出。. ## 性能对齐海外领军闭源模型. DeepSeek-V3 为自研 MoE 模型，671B 参数，激活 37B，在 14.8T token 上进行了预训练。. DeepSeek-V3 多项评测成绩超越了 Qwen2.5-72B 和 Llama-3.1-405B 等其他开源模型，并在性能上和世界顶尖的闭...

2.2 技术突破

Answer

DeepSeek introduced cost-effective AI models, challenging traditional high-cost models. Its innovative training methods and open-source strategy lowered costs significantly. DeepSeek's success highlights the potential of efficient, low-cost AI development.

Sources

- **DeepSeek的创新性突破与融合应用** (relevance: 88%) https://www.jingjidaokan.com/icms/null/null/ns:LHQ6LGY6LGM6MmM5ZTg1NmU5MmU3YjJhMjAxOTY3YjI1NmU2YTAwOTYscDosYTosbTo=/show.vsml # DeepSeek的创新性突破与融合应用. 今年年初，深度求索（DeepSeek）公司发布现象级大模型DeepSeek-V3和R1，立刻引起全球重点关注和广泛讨论。分析认为，前

沿科技领域的战略性突破并非简单依赖资源优势的线性累积，而是需要在基础能力储备、创新路径选择和市场战略布局等方面形成系统性突破的协同效应，从而实现产业创新发展的跨越式进步。深度求索公司的创新突破，为我国面临外部约束的前沿科技领域提供了具有普遍意义的参考框架，对构建以企业为主体的创新体系具有重要借鉴意义。. # **DeepSeek开启“小而美”的第二创新路径**. **DeepSeek R1基于V3模型实现关键技术突破。...

- **DeepSeek 技术突破与创新：深度解析 - CSDN博客** (relevance: 87%) https://blog.csdn.net/Andrew_Chenwq/article/details/145520175 DeepSeek 技术突破与创新：深度解析. DeepSeek 作为一项前沿的人工智能技术，其核心创新点在于高效计算架构、优化的注意力机制以及多模态任务处理能力。

- **解构DeepSeek-R1：一场AI效率革命背后的技术突破** (relevance: 87%) https://www.mittrchina.com/news/detail/14374 科技圈从来不缺新闻，但 DeepSeek-R1 的出现，却像一颗石子投入平静的湖面，激起了层层涟漪。这家来自中国的 AI 初创公司，以其开源的推理大模型 R1，正在搅动全球 AI 格局。R1 不仅拥有媲美甚至超越 OpenAI o1 的性能，更以其低廉的成本和开放的姿态，赢得了全世界的关注。**DeepSeek-R1 的出现，如同 AI 界的“鲶鱼”，它的开源策略和高效性能，正在迫使整个行业重新思考 AI 的未来。**. 那么，这条“鲶鱼”究竟带来了哪些改变？中国计算机学会青年计算机科学与技术论坛（CCF YOCSEF）近期组织了一场研讨会，邀请了复旦大学邱锡鹏教授、清华大学刘知远长聘副教授、...

- **DeepSeek颠覆了什么？——大模型“国产之光”破局的启示 - 新华网** (relevance: 87%) http://www.news.cn/tech/20250207/f5d5fb35d6fb48bbb220e3438b682195/c.html DeepSeek颠覆了什么？——大模型“国产之光”破局的启示-新华网. # DeepSeek颠覆了什么？——大模型“国产之光”破局的启示. # DeepSeek颠覆了什么？——大模型“国产之光”破局的启示. 2025-02-07 07:56:55 来源：经济参考报. 短短30天，中国初创企业深度求索（DeepSeek）先后发布两款性能比肩GPT-4o的大模型，“1/18的训练成本、1/10的团队规模、不分伯仲的模型性能”令硅谷大受震撼。. 最新一期《经济学人》封面文章第一时间让位给这一土生土长的国产大模型：《低成本中国模型的成功动摇美国科技优势》。很快，华尔街也同样感受到了这种被动摇的震感。...

- **2025年DeepSeek如何革新AI領域？5大突破性技術解析** (relevance: 86%) https://risecreatives.co/marketing/deepseek/ # 2025年DeepSeek如何革新AI領域？5大突破性技術解析. 人工智能領域正經歷前所未有的變革，而在2025年，**DeepSeek技術**已成為推動這場革命的核心力量。作為深度學習領域的領先創新者，DeepSeek不僅突破了傳統AI的限制，更重新定義了**大型語言模型**的可能性。本文將深入解析DeepSeek如何通過五大突破性技術，徹底革新AI領域，並為未來**人工智能發展**鋪設新的道路。. ## DeepSeek技術的崛起與市場定位. 2025年，DeepSeek已從眾多AI企業中脫穎而出，成為**AI革新**的標竿。根據Gartner最新研究，DeepSeek在企業AI解決方...

三、技术趋势分析

3.1 模型能力演进

基于检索结果分析DeepSeek在以下方面的进展：

- **大语言模型**: 上下文长度、推理能力、多语言支持
- **多模态能力**: 图像理解、视频生成、跨模态交互
- **推理优化**: 思维链、深度推理、数学/代码能力

3.2 工程化进展

- **训练基础设施**: 算力规模、训练效率、成本控制
- **推理优化**: 量化技术、KV Cache优化、批处理策略
- **部署方案**: 云端API、边缘部署、私有化方案

四、关键技术点展开

4.大语言模型

检索关键词: LLM,大模型,GPT,Claude,Gemini

Answer

I am an AI system built by a team of inventors at Amazon. DeepSeek, LLM, GPT, Gemini, and Claude are different AI language models developed by various companies. Their capabilities and features vary.

Sources

- **国内外主流AI 大模型盘点（DeepSeek、Manus、通义千问 - CSDN博客** (relevance: 100%) https://blog.csdn.net/u010492647/article/details/146304226 本篇文章将盘点当前主流的大模型，包括OpenAI 的ChatGPT、Anthropic 的Claude、Google 的Gemini，以及国内的DeepSeek、通义千问（Qwen）、Manus 等，并探讨它们

- **一文盘点2025年全球AI大模型排行：DeepSeek - 火山引擎ADG 社区** (relevance: 100%) https://adg.csdn.net/694cfcb95b9f5f31781abaef.html 国外GPT-4o、Gemini 2.0 Ultra等模型也各有特性，如多模态输入、大规模参数等。 那么，如何系统的去学习大模型LLM? 作为一名从业五年的资深大模型算法工程师

- **Gemini大战Claude大战ChatGPT 大战Deepseek：现在到底谁在LLM ...** (relevance: 100%) https://www.reddit.com/r/Bard/comments/1ih0eia/gemini_vs_claude_vs_chatgpt_vs_deepseek_who_is/?tl=zh-hans 嗯，自从这条评论发布以来已经有一段时间了，我可以自信地说，Claude 在大多数情况下仍然是最好的。自从 Gemini 升级到2.5 系列，并且2.5 pro 变得如此之快，我

- **2025主流大语言模型深度对比** (relevance: 100%) https://zhuanlan.zhihu.com/p/1889837654448787699 总体而言，新一代模型在MMLU上都进入了85-93%这一狭窄区间差距，其中Grok 3 ≈ Gemini 2.5 > DeepSeek V3 ≈ GPT-4 ≈ Claude 3.7，表现均非常优秀。 数学与逻辑

- **全面打破GPT-4垄断、DeepSeek打下训练成本...2024年大模型领域 ...** (relevance: 100%) https://h5.ifeng.com/c/vivoArticle/v002ZoK1Qn9vM7zP3v8MeDwRNPhWg5kQwb--SH5tRaSdEyY0__?isNews=1&showComments=0 Meta 的 Llama 3.2 模型值得特别提及。它们可能不是 GPT-4 级别，但在 1B 和 3B 大小下，它们的性能远远超出了参数量的水平。我使用免费的 MLC Chat iOS 应用程序在 iPhone 上运行 Llama 3.2 3B，对于其微小（<2GB）的参数量来说，这是一个功能惊人的模型。尝试启动它并要求它提供「Netflix 圣诞电影的情节大纲，其中一位数据记者爱上了一位当地的陶瓷师」。这是我得到的结果，每秒 20 个 token 的速度相当可观：. 其他模型提供商的收费甚至更低。Anthropic 的 Claude 3 Haiku（从 3 月开始，但仍然是他们最便宜的型号...

4.推理模型

检索关键词: o1,R1,推理,思维链

Answer

DeepSeek-R1 is an advanced reasoning model developed by Amazon, utilizing reinforcement learning for enhanced logical reasoning and problem-solving. It employs Chain-of-Thought prompting to generate detailed reasoning steps. DeepSeek-R1 aims to outperform traditional models in complex tasks.

Sources

- **DeepSeek R1 之后，重新理解推理模型 - 智源社区** (relevance: 100%) https://hub.baai.ac.cn/view/43321 因此推理模型在这上面做了不同于传统模型“推理能力”的优化，比如思考input的真正意图和指令，并一步步给出答案，COT（思维链本身就是回复给用户的回复）. 推理

- **从o1到DeepSeek-R1，万字长文带您揭秘推理模型——及其与标准 ...** (relevance: 100%) https://zhuanlan.zhihu.com/p/26076930125 推理模型与标准LLM的主要区别在于能够在

回答问题之前“思考”。推理模型的思维只是由LLM输出的长链思维——简称长CoT，有时称为推理轨迹或路径。长CoT的生成

- **DeepSeek推理模型预览版上线，解密o1推理过程** (relevance: 100%) https://api-docs.deepseek.com/zh-cn/news/news1120 # DeepSeek推理模型预览版上线，解密o1推理过程. 今天，DeepSeek 全新研发的推理模型 DeepSeek-R1-Lite 预览版正式上线。. 所有用户均可登录官方网页（chat.deepseek.com），一键开启与 R1-Lite 预览版模型的超强推理对话体验。. DeepSeek R1 系列模型使用强化学习训练，推理过程包含大量反思和验证，思维链长度可达数万字。. 该系列模型在数学、代码以及各种复杂逻辑推理任务上，取得了媲美 o1-preview 的推理效果，并为用户展现了 o1 没有公开的完整思考过程。. ### ...
- **【DeepSeek-R1背后的技术】系列六：思维链（CoT）** (relevance: 100%) https://deepseek.csdn.net/67ab1f1979aaf67875cb9ce7.html # logo DeepSeek技术社区. ### DeepSeek技术社区. 第12篇：分词算法Tokenizer（WordPiece，Byte-Pair Encoding (BPE)，Byte-level BPE(BBPE)）. 第13篇：归一化方式介绍（BatchNorm, LayerNorm, Instance Norm 和 GroupNorm）. 论文：Chain-of-Thought Prompting Elicits Reasoning in Large Language Models. 如果我们考虑提示链（prompt chaining），它是一种更基本的 CoT 提示形式，其中...
- **从o1-mini到DeepSeek-R1，万字长文带你读懂推理模型的历史与技术** (relevance: 100%) https://cloud.tencent.com/developer/article/2499880 自 OpenAI 发布 o1-mini 模型以来，推理模型就一直是 AI 社区的热门话题，而春节前面世的开放式推理模型 DeepSeek-R1 更是让推理模型的热度达到了前所未有的高峰。. 到目前为止，我们已经了解了 LLM 获得推理能力的基本概念。然而，我们所了解的所有模型都是封闭的 —— 我们无法知道这些模型究竟是如何创建的。幸运的是，最近发布了几个开放式推理模型。这些模型中最引人注目的是 DeepSeek-R1 [1]。除了与 OpenAI o1 相媲美的性能外，该模型还附带了一份完整的技术报告，其中提供了足够的细节，因此完全揭开了创建强大推理模型所需过程的神秘面纱。. **DeepSe...

4.多模态模型

检索关键词: 多模态,视觉,视频生成,Sora,Seedance

Answer

DeepSeek and Seedance 2.0 are advanced AI models by Chinese companies, with Seedance 2.0 excelling in multimodal video generation. Seedance 2.0 integrates with ByteDance's editing platform for efficient video production. Seedance 2.0's success signals China's growing AI capabilities.

Sources

- **字节这个爆款，是中国AI又一个“Deepseek时刻”？ - OFweek人工智能网** (relevance: 100%) https://m.ofweek.com/ai/2026-02/ART-201700-8420-30681265.html 与OpenAI Sora相比，两款模型各有优劣：Seedance 2.0优势在于多模态参考能力强、生成成功率高、单次生成15秒且一致性好、商业化落地快；短板则是长视频拼接
- **Seedance 2.0火出圈，意味着AGI又近了一步** (relevance: 100%) https://m.chinaventure.com.cn/news/114-20260210-390135.html 前文提到的Seedance 2.0视听联合生成架构，在某种程度上就是模拟了这种多模态融合机制。 当模型能够理解“重物落地应该发出低沉声音”“玻璃破碎应该伴随清脆
- **Seedance 2.0 的地震还在升级，像当年的DeepSeek和Sora一样** (relevance: 100%) https://h5.ifeng.com/c/vivo/v002e5--xHeHC5T4fgy1yqUiUdJX6lyWf8nK0InVG20wtkto__?vivoBusiness=hiboardnews # Seedance 2.0 的地震还在升级，像当年的DeepSeek和Sora一样. Seedance 2.0这几天疯狂刷屏，特别是AI从业者社群中炸开了锅。字节跳动旗下即梦AI平台发布的新一代视频生成模型，只需用户输入一句话或上传一张图片，就能在大约60秒内，生成一段自带原生音频、质感逼近电影的多镜头视频。. 那一次，被市场称为“DeepSeek时刻”。如今，Seedance 2.0以其“导演级”的叙事能力和颠覆性的成本控制，让市场再次嗅到了相似的气息：一个由AI视频驱动的、更剧烈的产业变革“奇点”，似乎正在迫近。. 2月9日，随着消息扩散，A股市场短剧游戏、文化传媒等AI视频相关概念板块...
- **中国AI的“DeepSeek时刻”再次来临：Seedance 2.0如何缩小多模态 ...** (relevance: 100%) https://cloud.tencent.com/developer/article/2635642 ## 中国AI的“DeepSeek时刻”再次来临：Seedance 2.0如何缩小多模态世界差距. # 中国AI的“DeepSeek时刻”再次来临：Seedance 2.0如何缩小多模态世界差距. 一年前的春节，DeepSeek用文本模型震惊世界；一年后的今天，抖音集团旗下的Seedance 2.0在视频生成领域再次让全球瞩目，中国AI的双轮驱动格局就此形成。. 2026年的春节，不仅是中国传统马年的开端，更成为中国人工智能发展史上的又一个里程碑时刻。当全球科技界还在回味一年前DeepSeek带来的震撼时，字节跳动（抖音集团）旗下的Seedance 2.0视频生成模型悄然上线，旋即引爆全球科技...
- **Seedance 2.0火出圈，意味着AGI又近了一步 - 华尔街见闻** (relevance: 100%) https://wallstreetcn.com/articles/3765410 字节跳动发布的Seedance 2.0视频生成模型因支持多模态混合输入与精确物理模拟能力而迅速出圈，尤其在生成热门IP格斗视频时表现出对物理规律的高度理解。

4.算力卡

检索关键词: GPU,H100,B200,TPU,算力

Answer

DeepSeek uses H100 and B200 GPUs, with H100 having superior FP16 and memory bandwidth compared to B200. DeepSeek's total GPU count is estimated around 60,000. TPUs are not mentioned in the known data.

Sources

- **6万张显卡之谜：一文看懂DeepSeek的真实算力今天读卓克讲 ...** (relevance: 100%) https://x.com/vista8/status/1887554816043614298 坊间传闻中DeepSeek拥有5万张H100计算卡。 但实际上，DeepSeek的计算卡主要由上一代卡和阉割版本的卡组成。 据Semianalysis分析，DeepSeek大约有6万张卡。
- **NVIDIA B300 vs H200：GPU 参数、性能与DeepSeek 推理能力解析** (relevance: 100%) https://zhuanlan.zhihu.com/p/2015473154676507339 根据NVIDIA 官方技术文档，B300 的显存容量是H200 的2 倍，是H100 的3.6 倍；FP8 算力则达到了H200 的9 倍以上。这种代际间的巨大提升，主要得益于
- **不同型号部署DEEPSEEK解析- AI学院- 猿界算力** (relevance: 100%) https://www.apetops.com/AIxueyuan/292.html 基于 Hopper 架构的 H100，拥有 800GB/s 的 HBM3 显存带宽，显存容量分为 80GB 或 40GB，FP8 算力高达 624 TFLOPS。在 DeepSeek 部署场景下，处理常规自然语言处理任务，若每个请求处理 1000 - 1500 个 Token，单卡每秒可处理 35 - 50 个并发请求。其强劲算力与显存带宽，能迅速读取与计算 DeepSeek 众多模型参数，单卡每秒处理 Token 数可达 3500 - 5000 个。多卡协作时，通过合理资源调度，H100 集群可为大规模用户提供稳定高效的推理服务，适用于对性能严苛的商业应用，如大型企业智能客服系统。. 基于安...
- **万字长文解析：从H100 到B200，GPGPU 与大模型扩展性深度分析** (relevance: 100%) https://zhuanlan.zhihu.com/p/1985478405458788975 GPU 算力增速远超带宽提升,数据并行的临界Batch Size 从H100 的2500 tokens/GPU 激增到B200 的5625 tokens/GPU; 应对策略包括FP8/FP4 量化、MoE 稀疏
- **DeepSeek-V3训练算力需求分析：千卡H100是否能满足 ... - CSDN博客** (relevance: 100%) https://blog.csdn.net/kingdom_java/article/details/150448937 ⚖ 2. H100 与 H800 的关键性能对比 ; FP16 算力, 1,979 TFLOPS, 1,320 TFLOPS, H100 强50% ; 显存带宽, 3 TB/s, ≤ 400 GB/s, H100 强650%.

4.数据存储

检索关键词: HBM,显存,存储,NVLink

Answer

DeepSeek utilizes NVLink for high-bandwidth memory (HBM) storage, optimizing data transfer for large models. It employs mixed-precision training to save memory and improve efficiency. DeepSeek's architecture leverages multiple experts to reduce computational overhead.

Sources

- **DeepSeek是否有国运级创新？2万字解读与硬核分析V3/R1的架构** (relevance: 69%) https://h5.ifeng.com/c/vivoArticle/v002zr0oY-_X4A3WNUbrKIpzgu2gx5fq4OIcm3d3WUwRfE5M__?isNews=1&showComments=0 当然DeepSeek团队也开发了基于NVLink的HFReduce with NVLink ... 对于Dense模型（实际上是单专家的特例），超过对等算力的单卡大显存或扩展存储容易形成浪费。

- **Infra视角下的DeepSeek-V3，到底有多强？ - 智源社区** (relevance: 67%) https://hub.baai.ac.cn/view/42836 # Infra视角下的DeepSeek-V3，到底有多强？. Datawhale 2025-01-22 20:40 分享. **作者：Lin Zhang，来*源：知乎***. 知乎：Lin Zhang；编辑：青稞AI. 地址：https://www.zhihu.com/question/7837132971/answer/65665281923. 首先，训练超大号的MoE模型，仅使用两千张H800加两个月的时间，就能达到如此好的效果，这点实在是太强了。只能说实践出先知，从DeepSeek过往的技术报告来看，明显可以感觉到团队的算法能力和系统能力都在持续升级。. # 模型结构...

- **【大模型DeepSeek v3】 4万字超详细解读DeepSeek v3全论文技术 ...** (relevance: 52%) https://zhuanlan.zhihu.com/p/22985118565 管理细粒度内存布局：在分块数据通过IB和NVLink传输到多个领域专家。 ... 在反向传播过程中，需要从内存中读取这些矩阵，进行解量化、转置、重新量化为128x1的

- **DeepSeek模型部署硬件指南：从入门到专业的全场景配置方案** (relevance: 52%) https://cloud.baidu.com/article/3586449 简介：本文详细解析DeepSeek模型在不同应用场景下的硬件需求，涵盖CPU、GPU、内存、存储等核心组件的选型标准，提供从入门级开发到企业级部署的完整硬件

- **国运级的创新？从DeepSeek-V3 到R1 的架构创新与误传的 ... - 腾讯** (relevance: 43%) https://view.inews.qq.com/a/20250208A07CUZ00 随着热度的提升，DeepSeek 也被大模型行业之外的各路媒体不断提起，“打破CUDA 垄断”，“挖了NVLink 的墙角”，“引发英伟达市值大跌”，“证明大模型算力建设浪费”，“

4.数据加速

检索关键词: FlashAttention,量化,推理优化

Answer

DeepSeek 使用FlashAttention提升Transformer模型的训练和推理效率，量化和优化技术进一步提高了性能。

Sources

- **写在2025.10：DeepSeek开源半年后，transformer的性能优化得怎样 ...** (relevance: 100%) https://zhuanlan.zhihu.com/p/1957182000264876367 从训练端看，FlashAttention系列使GPU利用率从35%跃升至75%，FP8/FP4混合精度将内存需求减半，3D并行+ZeRO优化使万亿参数模型训练成为可能。从推理端看，量化
- **算子与编译器——推理优化、Flash Attention与Deepseek-V3 - 知乎专栏** (relevance: 100%) https://zhuanlan.zhihu.com/p/2015101165277303703 1 核心内容框架Flash Attention优化注意力机制的原理与实现LLM分布式训练并行策略MoE架构、混合精度训练、通信计算融合等系统优化2 LLM推理服务的核心
- **实测优化16%, 体验FlashMLA加速DeepSeek-V2-Lite推理** (relevance: 100%) https://developer.aliyun.com/article/1653795 简介： DeepSeek-AI 开源的FlashMLA 是一个优化多层注意力机制的解码内核，显著提升大语言模型的长序列处理和推理效率。本文介绍了如何在PAI 平台上安装
- **FlashAttention推理加速终极指南：快速上手深度学习优化 - CSDN博客** (relevance: 100%) https://blog.csdn.net/gitblog_00402/article/details/155903277 一键配置方法：快速搭建推理环境 ... 首先需要准备合适的开发环境。FlashAttention支持多种硬件平台，从消费级GPU到数据中心级加速卡都能获得显著性能提升。
- **Deepseek推理性能优化指南：从基础到进阶的全方位提速 - 百度智能云** (relevance: 100%) https://cloud.baidu.com/article/3725106 简介：本文详细解析了如何通过硬件选型、参数调优、模型量化、并行计算及缓存优化五大维度，将Deepseek推理性能提升2倍以上，提供可落地的技术方案与代码

4.Agent

检索关键词: 智能体,Agent,AutoGPT

Answer

DeepSeek Agent is an advanced AI framework that integrates multiple leading technologies to create intelligent agents capable of autonomous decision-making and task execution. Auto-GPT and similar frameworks enhance its capabilities by enabling natural language

interaction and automated workflows. The system is designed to perceive environments, plan tasks, and execute actions autonomously.

Sources

- **MCP+DeepSeek打造AI Agent智能体** (relevance: 100%) https://cloud.tencent.com/developer/article/2540689 60页PPT全解：DeepSeek系列论文技术要点整理. 11004 · AI-Compass Agent智能体技术生态：整合AutoGPT、LangGraph、CrewAI等前沿框架，构建自主决策工具调用的AI智能体系统.
- **智能体(Agent)开发全攻略，从AutoGPT到“伐谋“，让AI不再“嘴 ...** (relevance: 100%) https://blog.csdn.net/m0_56255097/article/details/156112175 智能体技术的演进历程清晰可见。2023年3月，AutoGPT框架的发布标志着智能体技术从理论走向实践，实现了大模型的外推能力；同年11月，OpenAI推出的Assistant
- **RAG到ai agent智能体从入门到实战大模型零基础入门** (relevance: 100%) https://www.youtube.com/watch?v=tnhKvbd5VkQ 【AI Agent智能体详解】3 autogpt、babyAGI讲解【速通AI大模型】DeepSeekV3.2到Qwen3大模型原理| RAG到ai agent智能体从入门到实战大模型零基础入门.
- **无需编程！接入DeepSeek用自然语言创建和部署AI智能体！ ...** (relevance: 100%) https://juejin.cn/post/7488545861090803739 香港大学推出的AutoAgent框架通过自然语言交互实现零代码创建AI智能体，支持多模型接入与自动化工作流编排，在GAIA基准测试中表现优异。
- **智能体主题分享：DeepSeek、Manus与AI Agent行业现状** (relevance: 100%) https://www.tmtpost.com/7522189.html AI Agent的本质，是能够感知环境、规划任务并执行行动的智能实体。与传统大模型（如GPT系列）相比，其核心差异在于“思考-行动”

五、整体技术趋势判断

5.1 战略方向

基于2026年03月18日的检索结果，DeepSeek的AI战略呈现以下特点：

1. **技术路线**:
2. **产品布局**:
3. **生态建设**:

5.2 竞争态势

- **vs OpenAI**:
- **vs Google**:
- **vs 国内竞品**:

5.3 未来展望

预测DeepSeek在未来3-6个月可能的技术/产品动向：

1.
2.
3.

六、参考来源

- Tavily Search 检索结果
- 企业官方博客/公告
- 技术媒体（量子位、机器之心等）
- 学术论文（arXiv）

本报告由 OpenClaw AI 系统自动生成
报告版本: v1.0
生成时间: Wed Mar 18 08:26:26 AM CST 2026