字节跳动 AI技术洞察报告

报告日期: 2026年03月18日
生成时间: 08:24:42
数据来源: Tavily Search, 企业博客, 新闻媒体
洞察范围: 模型发布、技术动态、产品更新

一、公司概况

公司名称: 字节跳动
主要产品: 豆包,Seedance,Seed
检索优先级: 高

二、最新动态检索

2.1 产品/模型发布

Answer

ByteDance released three AI models: Seedance 2.0 for video, Seedream 5.0 Lite for images, and the Bean Model 2.0, showcasing significant performance improvements. These models aim to enhance content creation and processing capabilities.

Sources

- **字节跳动发布三款AI模型_新浪新闻** (relevance: 86%) https://www.sina.cn/news/detail/5266526082172089.html 2026年2月字节跳动集中发布Seedance 2.0（AI视频）、Seedream 5.0 Lite（AI图片）、豆包大模型2.0三款模型，性能实现突破性升级，不仅让其与Google的
- **字節跳動推出Seedance 2.0，「大片級」AI影片顛覆好萊塢？ - WSJ** (relevance: 75%) https://cn.wsj.com/articles/%E5%AD%97%E7%AF%80%E8%B7%B3%E5%8B%95%E6%8E%A8%E5%87%BAseedance-2-0-%E5%A4%A7%E7%89%87%E7%B4%9A-ai%E5%BD%B1%E7%89%87%E9%A1%9B%E8%A6%86%E5%A5%BD%E8%90%8A%E5%A1%A2-5

gaa_at=eafs&gaa_n=AWEtsqe1UAczxiCionGl22FBfbdmH7pt79Cg8IUc46mismCbaJizBlPJptk-&gaa_ts=69b9f35a&gaa_sig=4irLZIb6Uu678Q9kDg-3cJ7zL8Xx-uUoOh14fwaah1NTobGGCTni4s6-YcUh87sZD7qAw2rVMycHyHuatlBKpw%3D%3D TikTok母公司開發出一款人工智慧(AI)模型，可以根據單一文本提示，生成具有故事情節、場景切換和鮮明人物形象的高品質影片。 總部位於北京的字節

- **字节跳动Seed** (relevance: 75%) https://seed.bytedance.com/zh/ 每秒推理速度 2146 Tokens，扩散语言模型 Seed Diffusion Preview 发布. 每秒推理速度 2146 Tokens，扩散语言模型 Seed Diffusion Preview 发布. 字节跳动 Seed 与比亚迪锂电池深化合作：将成立 AI 联合实验室加速电池研发. 字节跳动 Seed 与比亚迪锂电池深化合作：将成立 AI 联合实验室加速电池研发. 解锁任意模态模型训练，字节跳动 Seed 开源 VeOmni 框架. 解锁任意模态模型训练，字节跳动 Seed 开源 VeOmni 框架. 字节跳动 Seed Prover 取得 IMO 2025 银牌分数. 字节跳动 ...

- **中國AI 橫掃全球！字節Seedance 2.0 震撼發布讓好萊塢集體失業** (relevance: 72%) https://www.youtube.com/watch?v=Rw8A3_UnJNM TikTok母公司字節跳動正式發布新一代影片生成模型「Seedance 2.0」，在社群平台引發大量討論。技術上支援自動分鏡、音效匹配及物理邏輯運算，

- **字節跳動拋震撼彈！Seedance 2.0亮相19.9美金就可享「整間影視 ...** (relevance: 71%) https://www.youtube.com/watch?v=7hGCuvxA45w TikTok 母公司字節跳動正式發布新一代AI 影片生成模型「Seedance 2.0」，該產品目前在社群平台上引發大量生成影音討論。技術層面上，Seedance 2.0 支援

2.2 技术突破

Answer

ByteDance has made significant technical breakthroughs in AI, including large language models and multi-modal AI technologies. The company is heavily investing in AI infrastructure and hardware. ByteDance's AI efforts aim to push the limits of intelligent applications.

Sources

- **一个算法博士毕业后的六年：“我在字节跳动做大模型”** (relevance: 79%) https://seed.bytedance.com/blog/%E4%B8%80%E4%B8%AA%E7%AE%97%E6%B3%95%E5%8D%9A%E5%A3%AB%E6%AF%95%E4%E6%88%91%E5%9C%A8%E5%AD%97%E8%8A%82%E8%B7%B3%E5%8A%A8%E5%81%9A%E5 # 一个算法博士毕业后的六年：“我在字节跳动做大模型”. 在这个“六年”里，纪同学成长飞快，从一个职场新人变成了带过五六十人团队的技术负责人。. 去年，他加入公司新成

立的豆包大模型团队，全身心投入到对音乐生成模型的技术探索中。他的团队里也有很多顶尖高校博士毕业的同学，和当年的他一样对技术研究有纯粹的热情和专注，不断地在技术极限的边缘试探、突破是他们的工作日常。. 几天前，由他负责的字节跳动音乐大模型Seed-Music 发布，引发了来自全球各地音乐人的关注。当模型生成的音乐变得更悦耳，当AI 可以真正从无到有“创作”一首歌曲，音符与代码的背面，我们看到一个技术人才加入字节跳动后，拥有的无限...

- **破局者字节，全栈AI狂飙 - 证券时报** (relevance: 78%) https://stcn.com/article/detail/3303266.html 来源：21世纪经济报道作者：雷晨2025-08-29 10:35. 作为行业的后来者，字节跳动的AI棋局日渐清晰：纵向，完成从底层硬件到上层应用的全栈布局，形成成本与体验的“飞轮效应”；横向，以C端超级App流量与B端企业服务双轮驱动，构建一个强大的开放生态。. 这条路通往何方？字节跳动的答案是：坚定长期投入，“追求智能上限”，服务产业应用。其全栈AI布局正加速渗透千行百业，推动中国数字化进程迈入“AI原生”的新阶段。. 据华创证券报告显示，字节跳动基于互联网海量数据，积极建设海内外算力中心；同时，基于字节自研DPU的GPU实例，较上一代集群性能最高提升三倍以上。. 此前有消息称，2025年，...

- **传字节跳动自研芯片团队扩张至千人 - 电子工程专辑** (relevance: 65%) https://www.eet-china.com/mp/a475695.html 近日，多家媒体相继披露，字节跳动的芯片研发团队已完成隐秘扩容，规模正式突破千人，其中深耕AI芯片研发的人员超500人，CPU研发团队规模则稳定在200人左右。

- **压力给到了字节AI - 华尔街见闻** (relevance: 60%) https://wallstreetcn.com/articles/3742268 2025年的春节，本应是字节跳动AI产品豆包的高光时刻。 ... 显然，DeepSeek等竞争对手的快速崛起压缩了字节的技术窗口期，迫使公司必须在有限时间内实现突破。

- **那些选择加入字节跳动的顶尖技术同学，现在怎么样了？** (relevance: 60%) https://zhuanlan.zhihu.com/p/716554483 公司有丰富的技术落地场景，在很多领域上都有突破和发展，对敬伍这类优秀的同学来说，处处是机会和挑战。 2019年，孔涛接下字节的校招Offer，那时

三、技术趋势分析

3.1 模型能力演进

基于检索结果分析字节跳动在以下方面的进展：

- **大语言模型**: 上下文长度、推理能力、多语言支持
- **多模态能力**: 图像理解、视频生成、跨模态交互
- **推理优化**: 思维链、深度推理、数学/代码能力

3.2 工程化进展

- **训练基础设施**: 算力规模、训练效率、成本控制
- **推理优化**: 量化技术、KV Cache优化、批处理策略
- **部署方案**: 云端API、边缘部署、私有化方案

四、关键技术点展开

4.大语言模型

检索关键词: LLM,大模型,GPT,Claude,Gemini

Answer

ByteDance's Doubao-1.5-pro is a leading large language model, surpassing Gemini in performance and focusing on mobile and industrial applications. Gemini 2.0 Ultra combines Google's and DeepMind's technologies for advanced multimodal analysis. LLMs like ByteDance's and Gemini are key in AI research and applications.

Sources

- **字节跳动AI研究员暗示，即将发布比Gemini更强大的开源模型 - Reddit** (relevance: 63%) https://www.reddit.com/r/singularity/comments/18cj8pe/bytedance_ai_researcher_suggests_that_open_source/?tl=zh-hans 大型语言模型(LLM)只是构建具有自主性的人类智能的第一个可用的构建模块。我不认为它们可以独自完成所有事情。LLM 的风险仅在于它们可以帮助自动化

- **26年2月底AI大模型动态跟踪——模型狂发** (relevance: 60%) https://zhuanlan.zhihu.com/p/2011534791091176226 文本竞技场：Claude Opus 4.6略微领先Gemini 3.1 Pro，占据第一把交椅。前10名出现了唯一一个国产LLM，字节才发布的seed-2.0-pro。 编码竞技场：Claude Opus

- **2025主流大语言模型深度对比** (relevance: 59%) https://zhuanlan.zhihu.com/p/1889837654448787699 综上，六大模型在技术上各有侧重：GPT-4和Claude 3.7为高性能的通用Transformer，强调安全对齐和可靠性；Gemini 2.5 Pro结合了Google Brain和DeepMind技术，

- **2025年全球AI大模型综合排名Top 20新鲜出炉| DT指数** (relevance: 58%) https://www.dtinsight.com.cn/nd.jsp?id=3608 | | 2025年全球AI大模型综合排名Top 20新鲜出炉 | DT指数 以下是基于2025年最新评测数据（截至2025年7月）的全球大模型综合排名Top 20

榜单，涵盖技术性能、应用能力及生态支持等维度。以下整理前20名核心排名（含中国开发的国际影响力模型），并附获取完整排名的权威平台推荐。 --- **2025年全球AI大模型综合排名（Top 20）** | **排名** | **模型名称** | **开发机构** | **关键能力/亮点** | **主要应用领域** | | --- | --- | --- | --- | --- | --- | | | | | 科研分析、跨领域...

- **Gemini、GPT-4o、Claude 当评委，成AI 大语言模型“幻觉照妖镜”** (relevance: 57%) https://www.51cto.com/article/804199.html 在评估方案上，FACTS Grounding 采用Gemini 1.5 Pro、GPT-4o 和Claude 3.5 Sonnet 3 款模型作为评委，评估答案的充分性、事实准确性和文档支持性。

4.推理模型

检索关键词: o1,R1,推理,思维链

Answer

DeepSeek-R1 is a reasoning model that competes with models like o1 by using reinforcement learning. It is open-source and has lower training costs. DeepSeek-R1's success highlights the potential of open-source AI models.

Sources

- **字节跳动发布首款推理模型加剧基座模型竞争 - 财新** (relevance: 79%) https://m.caixin.com/m/2025-04-17/102310638.html # 字节跳动发布首款推理模型 加剧基座模型竞争. **【财新网】**4月17日，字节跳动旗下火山引擎面向B端发布豆包1.5深度思考模型，这是字节跳动首款推理模型，可在解决问题时“边想边搜”，根据目标规划搜索路径；同时具备视觉推理能力，可以综合理解图片中的各类信息。. 推理模型是指模型在预训练之后的阶段采用强化学习、思维链的技术，进一步“训练”提高模型处理复杂逻辑推理任务的能力。. OpenAI于2024年9月率先推出o1模型让业界转向推理模型，而后DeepSeek于1月20日推出推理模型R1，凭借顶尖的能力引发了广泛讨论。此后，互联网厂商间AI基座模型的竞争加剧，腾讯、阿里先后推出T1、QwQ...

- **Large Model Application Algorithm Research ... - 字节跳动招聘官网** (relevance: 70%) https://jobs.bytedance.com/campus/m/position/detail/7508770413570001159?recomId=1cbb5b17-eb3d-11f0-94fe-fa163e53fcf3&sourceJobId=7508738343146178823 字节跳动 ... 为了提升推理能力，OpenAI 的o1 系列模型通过增加思维链 ... 最近deepseek r1在论文中提到通过纯强化学习的方法

- **DeepSeek“大杀四方”，大厂还有AGI梦想吗？ - 21经济网** (relevance: 70%) https://www.21jingji.com/article/20250218/herald/

06e8d2b8eed8423d01f39b3559a4d41f.html 首页 宏观 证券 金融 商业 全球市场 观点 地产 科技 汽车 新健康 创投 智库 更多). 大湾区 一带一路 文旅 数读 理财 投资通 21视频 直播 品牌活动. # DeepSeek“大杀四方”，大厂还有AGI梦想吗？. ###### 2025年02月18日 15:21 21世纪经济报道 21财经APP 白杨. DeepSeek-R1的API定价仅为OpenAI o1模型运行成本的3%，但在性能上，它又能比肩OpenAI o1，这意味着，DeepSeek实现了低成本与高性能的对齐。. 更关键的是，DeepSeek将R1模型进行了完全的开源。IDC中国副总裁周震刚向21世纪经济报道记...

- **DeepSeek 推理型AI盡顯高效訓練的小模型之威** (relevance: 70%) https://hongkong.newsroom.ibm.com/DeepSeek-AI # Blogs. 作者： Aili McConnon，IBM 2025年1月27 日發表與IBM官網Think頻道，點擊閱讀英文原文 DeepSeek-R1是中國初創公司DeepSeek... DeepSeek-R1是中國初創公司 DeepSeek 推出的人工智能模型，不久前，在人工智能開源平台 Hugging Face上發佈數小時後，便躍居下載量和活躍度最高模型的榜首。這也給金融市場帶來了震蕩，因為它促使投資者重新考慮英偉達（NVIDIA）等芯片製造商的估值，以及美國人工智能巨頭為擴大其人工智能業務規模而進行的巨額投資。. 為何掀起如此大的波瀾？DeepSeek-R1 是一款所謂 "推理模...

- **一文理解推理大模型-Understanding Reasoning LLMs - 文章 - 火山引擎** (relevance: 63%) https://developer.volcengine.com/articles/7468943743278972969 # 一文理解推理大模型-Understanding Reasoning LLMs. 今天刷到Sebastian的blog，《Understanding Reasoning LLMs》，特此翻译一下，带给大家。. `原文: https://magazine.sebastianraschka.com/p/understanding-reasoning-llms` . ## 如何定义“推理模型”？. 如果你在AI（或机器学习）领域工作，你可能对模糊且备受争议的定义很熟悉。“推理模型”这个术语也不例外。最终，会有人在论文中正式定义它，但很快就会在下一篇论文中被重新定义~. 在本文中，我将“推理”定义为回...

4.多模态模型

检索关键词: 多模态,视觉,视频生成,Sora,Seedance

Answer

ByteDance's Seedance 2.0 is a leading multi-modal AI video generation model, excelling in visual and video creation. It supports various input modalities and offers high-quality, cinematic video outputs. Seedance 2.0 competes with Sora and Kling 3.0 in the AI video market.

Sources

- **Seedance 2.0 - ByteDance Seed** (relevance: 100%) https://seed.bytedance.com/zh/seedance2_0 # Seedance 2.0. Seedance 2.0 采用统一的多模态音视频联合生成架构，支持文字、图片、音频、视频四种模态输入，集成了目前业界最全面的多模态内容参考和编辑能力。. # 极致拟真的视听体验. # 所想即所见的导演级操控. 支持音、视、图全模态参考输入，打破素材边界，赋予创作者对表演、光影、运镜的调度权，超强的可控性让创意转化为画面，真正实现“像导演一样生成”。. # 影视工业链路赋能. 深度适配广告、影视与社媒营销场景，输出质量对齐工业交付标准，大幅度降低特效制作与实拍成本，为行业带来显著的效率提升. # 模型表现. 以下是 Seedance 2.0 在内部基准测试 See...
- **Seedance：字节跳动的AI视频生成技术突破与行业变革 - 新浪财经** (relevance: 100%) https://finance.sina.com.cn/stock/roll/2026-02-13/doc-inhmrnzk2295391.shtml Seedance是字节跳动旗下Seed团队研发的多模态AI视频生成平台，是当前全球领先的AI视频生成技术之一。其核心定位是通过扩散模型（Diffusion Model
- **字节Seedance2.0引领AI视频革命，微美全息多模态AI重构IP内容生态！** (relevance: 100%) https://caifuhao.eastmoney.com/news/20260211152904680432760 获悉，近日，字节跳动正式推出新一代AI视频生成模型Seedance 2.0，该模型能够根据用户一句描述，自动生成包含多镜头切换、连贯叙事和同步音效的电影级视频。
- **如何使用Seedance 2.0 进行视频生成（含提示词） - Atlas Cloud Blog** (relevance: 100%) https://www.atlascloud.ai/zh/blog/guides/how-to-use-seedance-2.0-for-video-generation Seedance 2.0 已经针对2024 年中期以来发布的所有主流视频模型（如Kling、Sora、Veo 等）进行了严格测试。它是2026 年最强大的多模态AI 视频生成器之一。
- **Seedance 2.0 vs. Sora 2 vs. Kling 3.0：2026年终极AI 视频API 对比 ...** (relevance: 100%) https://www.atlascloud.ai/zh/blog/seedance-2-vs-sora-2-vs-kling-3-comparison 文生视频市场涌现出了三大巨头：**Seedance 2.0**（字节跳动）、**Sora 2.0**（OpenAI）和 **Kling 3.0**（快手可灵）。. 在这篇综合指南中，我们将从架构、一致性和API 可访问性方面对这三个强力模型进行对比。此外，我们还将向您展示如何通过 **Atlas Cloud** 统一平台，使用 Python 立即访问 Seedance 2.0、Kling 3.0 和 Sora 2.0。. **Atlas Cloud** 解决了这种碎片化问题。您无需管理三个独立的 API 密钥和账单账户，只需使用一个统一的端点即可。. 以下是一个生产就绪的示例，展示了如何使用...

4.算力卡

检索关键词: GPU,H100,B200,TPU,算力

Answer

ByteDance uses H100 and B200 GPUs for AI applications. B200 offers higher memory and bandwidth than H100. The B200 can handle larger models due to its advanced features.

Sources

- **[PDF] AI系列专题报告（一） - 算力** (relevance: 73%) https://pdf.dfcfw.com/pdf/H3_AP202506121689781660_1.pdf AI系列专题报告（一） 算力：算力基建景气度高，国产AI芯片发展势头良好 证券研究报告 分析师： 陈福栋S1060523070003（证券投资咨询） 分析师： 闫磊 S1060519100002（证券投资咨询） 平安证券研究所电子信息团队 2025年6月12日 请务必阅读正文后免责条款 电子行业强于大市（维持） 核心摘要 ⌧AIGC蓬勃发展，对底层智能算力产生强劲需求。行业前期，训练是算力需求的主力，大量大模型训练需要海量算力支撑。2024年末，DeepSeek重磅发 布，其轻量化、低成本、高性能特征大幅拉低了AI应用门槛，有望成为各类推理场景爆发的契机，推理算力市场需求潜力巨大。在此背景下...
- **万字长文解析：从H100 到B200，GPGPU 与大模型扩展性深度分析** (relevance: 65%) https://zhuanlan.zhihu.com/p/1985478405458788975 GPU 算力增速远超带宽提升,数据并行的临界Batch Size 从H100 的2500 tokens/GPU 激增到B200 的5625 tokens/GPU; 应对策略包括FP8/FP4 量化、MoE 稀疏
- **兆規模起飛！“平替”輝達Blackwell架構GPU！智能算力TPU產業鏈 ...** (relevance: 64%) https://hao.cnyes.com/post/212327 B200叢集：同等算力需10240卡，功耗85MW; 百萬卡規模：功耗達7.3GW ... 9.4.2 字節跳動：應用驅動的算力採購. 需求：抖音、TikTok推薦系統日訓練
- **GPU 算力与实例定价** (relevance: 48%) https://www.bitdeer.ai/zh/pricing/gpu-compute 透明的GPU 算力定价。查看NVIDIA H100、H200、B200 及新一代GB200 NVL72 GPU 费率，支持按需付费和预留定价方案。
- **11.4 硬件选型：GPU、TPU 与专用加速器| 大模型原理与架构 - GitBook** (relevance: 45%) https://yeasy.gitbook.io/llm_internals/di-san-bu-fen-tui-li-yu-bu-shu-pian/11_serving/11.4_hardware ## hashtag 11.4.1 NVIDIA GPU：当前的主流选择. NVIDIA GPU 凭借 CUDA 生态的成熟度和 Tensor Core 的强大性能，是 LLM 训练和推理的首选。关键指标对比：. 表 11-2：NVIDIA 主要 GPU 型号对比（*为 FP8 Tensor Core 算力，FP16 密集算力约为一半）. 对于推理场景，**显存带宽**通常比算力更重要（10.1 节已解释生成阶段是访存密集型的）。H200 的 141 GB 显存使其可以在单卡上运行 70B 的 INT4 量化模型，极大降低了部署复杂度。而 B200 的 192 GB 显存和 8 TB/s 带...

4.数据存储

检索关键词: HBM,显存,存储,NVLink

Answer

字节跳动在AI领域使用高带宽内存（HBM）和NVLink技术进行数据存储和处理。HBM提升数据吞吐速度，NVLink实现高效互连。这些技术支持大规模模型训练。

Sources

- **AI领域GPU研发最新进展与趋势报告 - X** (relevance: 100%) https://x.com/myfxtrader/status/1888959527883804783 整个ExaPOD系统拥有**1.3TB片上SRAM和13TB高带宽内存（HBM）**供模型数据存储(Tesla Dojo - Wikipedia)。 ... 据《华尔街日报》报道，华为已邀请字节跳动、百度
- **被卡脖子的真相：为什么造GPU算力卡这么难？（科普文章） - 新浪** (relevance: 64%) http://k.sina.com.cn/article_5953466437_162dab0450670a7go6.html 这类算力卡彻底弱化显示输出功能，重点强化并行计算效率、HBM协同能力（高带宽显存，High Bandwidth Memory，核心作用是提升数据吞吐速度）等核心特性，是AI技术
- **HBM+HBF！存储黑科技来了 - 电子工程专辑** (relevance: 54%) https://www.eet-china.com/mp/a474702.html SemiDisplayView 2026-03-12 345浏览. 中国半导体论坛 2026-03-12 293浏览. 科创板日报 2026-03-12 262浏览. 科创板日报 2026-03-12 238浏览. 趣味科技v 2026-03-12 234浏览. 52RD 2026-03-13 228浏览. 快科技 2026-03-12 197浏览. TechSugar 2026-03-12 188浏览. MrCU204 2026-03-10 465浏览. weixianghui 2026-02-24 2210浏览. 研成工业 2026-02-25 2浏览. weixia...
- **被卡脖子的真相：為什麼造GPU算力卡這麼難？（科普文章） - 华盛通** (relevance: 36%) https://www.hstong.com/news/hk/detail/26031605223548487 這類算力卡徹底弱化顯示輸出功能，重點強化並行計算效率、HBM協同能力（高帶寬顯存，High Bandwidth Memory，核心作用是提升數據吞吐速度）等核心特性，是AI技術
- **2026年AI Infra重点发展方向的深度分析** (relevance: 31%) https://zhuanlan.zhihu.com/p/1999176653281187226 节点内多路径互连（MIHF）架构将聚合PCIe、NVLink和CXL带宽，实现主机内存到GPU的高效数据供给，支撑“无限内存”训练,。 推荐系统的分层存储（HPS）： 针对推荐

4.数据加速

检索关键词: FlashAttention,量化,推理优化

Answer

ByteDance uses FlashAttention for efficient attention mechanism, along with quantization and inference optimization techniques to speed up model inference. FlashAttention reduces memory access and improves GPU efficiency. It supports asynchronous computation and low-precision FP8 for faster training.

Sources

- **端侧AI Infra开发实习生-音视频技术** (relevance: 100%) https://jobs.bytedance.com/campus/m/position/detail/7594472672476760325?recomId=5a64c401-1efc-11f1-b8f3-043f72a6392c&sourceJobId=7532098404223666450 1、负责模型推理全流程优化，低比特量化（AWQ、GPTQ、SpinQuant等）、模型剪枝、蒸馏等模型压缩技术，以及FlashAttention、KVCache高效管理、投机推理等推理优化手段
- **清华、字节提出Token Reorder，无损实现5倍稀疏、4比特量化** (relevance: 100%) https://www.sohu.com/a/909295987_129720 PAROAttention 的方案主要围绕推理效率优化设计，但是采用Token重排来更好利用特征提取局部性的思想并不局限于推理优化中。不同的注意力头自主的学习
- **4比特量化三倍加速不掉点！清华即插即用的SageAttention ...** (relevance: 100%) https://cloud.tencent.com/developer/article/2496492 此前，清华大学陈键飞团队提出的 8-Bit 的即插即用 Attention（SageAttention），将 Attention 中的 QK^T 量化至 INT8，将 PV 保持为 FP16 精度并使用 FP16 精度的矩阵乘法累加器，同时提出 Smooth K 技术保持了量化 Attention 的精度，实现了 2 倍加速于 FlashAttention2，且在各类大模型上均保持了端到端的精度表现。. SageAttention2 实现了高效的 Attention 算子，可以实现即插即用的推理加速。输入任意 Q, K, V 矩阵，SageAttention2 可以快速返回 Attention...
- **FlashAttention - 3的新优化点对AI模型意味着什么？** (relevance: 100%) https://docs.feishu.cn/v/wiki/ESWYwhmISiMOvIkU44CcIZVzntb/ad 它在FlashAttention 和 FlashAttention-2 的基础上，进一步优化了对H 系列架构的支持，通过异步计算和低精度 FP8 的使用，实现了GEMM（通用矩阵乘法）和Softmax 操作的重叠，以及
- **FlashAttention 系列技术详解：加速大模型训练的利器** (relevance: 100%) https://developer.volcengine.com/articles/7444834108175286298 # FlashAttention 系列技术详解：加速大模型训练的利器. ## FlashAttention 的解决方案. 为了解决上述问题，**FlashAttention** 提出了一种 **快速、节省内存、精确的注意力计算方法** ，通过减少内存读写次数，提高 GPU 的内存 IO 效率，加快训练速度，并增加上下文窗口长度。其核心目标是通过 **硬件感知（IO-awareness）** 的算法优化，将整个注意力计算过程在更高速的 **SRAM**（静态随机存取存储器）中完成，减少对 HBM（高带宽内存）的依赖。. 在传统的注意力机制中，首先需要将输入矩阵 从 HBM 中读取，随后计算注意...

4.Agent

检索关键词: 智能体,Agent,AutoGPT

Answer

Agent TARS is a multi-modal AI developed by ByteDance, and Auto-GPT is an open-source framework for automating complex tasks using multiple AI agents. Both focus on enhancing automation and task management through advanced AI technologies.

Sources

- **AI 工具推荐之Agent TARS：字节跳动开源的多模态AI智能体 - 腾讯云** (relevance: 100%) https://cloud.tencent.com/developer/article/2513173 Agent TARS是字节跳动开发的一款多模态AI智能体，其核心技术基于UI-TARS模型。UI-TARS是一个原生的GUI代理模型，利用视觉语言模型（Vision-Language Model,
- **Agent调研--19类Agent框架对比（上） - 阿里云开发者社区** (relevance: 100%) https://developer.aliyun.com/article/1480814 本文深入对比分析主流AI Agent框架，从核心原理到决策模型，剖析BabyAGI、AutoGPT等框架的实现特点，为技术选型提供关键决策依据。
- **AI智能体(Agent)保姆级入门指南，零基础小白也能轻松上手** (relevance: 100%) https://zhuanlan.zhihu.com/p/1995097301845309381 Coze (扣子)：由字节跳动出品，完全免费，界面友好，非常适合新手。你可以用它快速创建聊天机器人、知识库问答、工作流等各种类型的Agent，并一键发布到豆包、
- **单智能体框架AutoGPT有哪些优缺点？ - 飞书文档** (relevance: 100%) https://docs.feishu.cn/v/wiki/Uwh7wnNN0iWbwqknboocnmMlnbe/ah AI Agent 阶段性总结与创投观察 • 1. 智能体：在上面单独定义的基础上，在多智能体系统中的智能体协同工作，每个智能体都具备独特有的LLM、观察、思考、行动和记忆； • 2. 环境：
- **AI-Compass Agent智能体技术生态：整合AutoGPT、LangGraph** (relevance: 100%) https://segmentfault.com/a/1190000046915541 ## 1.modelscope-agent. ## 1.Agently. LangManus 是一个社区驱动的 AI 自动化框架，基于开源社区构建，旨在将语言模型与网页搜索、爬虫和 Python 代码执行等专业工具结合，实现复杂任务自动化。. ## 1.Refact-AI-Agent. Refact.ai 是一款开源的 AI 软件工程智能体 (AI Agent)，旨在作为 GitHub Copilot 的替代方案。它能够端到端地处理工程任务，深入理解代码库，并与开发者的工具、数据库和浏览器集成，以自动化复杂的多步骤任务，从而提升开发效率和代码质量。. Refact.ai 的核心基于先进的 AI...

五、整体技术趋势判断

5.1 战略方向

基于2026年03月18日的检索结果，字节跳动的AI战略呈现以下特点：

1. **技术路线**:
2. **产品布局**:
3. **生态建设**:

5.2 竞争态势

- **vs OpenAI**:
- **vs Google**:
- **vs 国内竞品**:

5.3 未来展望

预测字节跳动在未来3-6个月可能的技术/产品动向：

1.
2.
3.

六、参考来源

- Tavily Search 检索结果
- 企业官方博客/公告
- 技术媒体（量子位、机器之心等）
- 学术论文（arXiv）

本报告由 OpenClaw AI 系统自动生成
报告版本: v1.0
生成时间: Wed Mar 18 08:25:02 AM CST 2026