智谱AI AI技术洞察报告

报告日期: 2026年03月18日
生成时间: 08:25:46
数据来源: Tavily Search, 企业博客, 新闻媒体
洞察范围: 模型发布、技术动态、产品更新

一、公司概况

公司名称: 智谱AI
主要产品: GLM,ChatGLM
检索优先级: 高

二、最新动态检索

2.1 产品/模型发布

Answer

Zhipu released its flagship AI model GLM-5, featuring enhanced programming and agent capabilities, and a significant increase in model size and performance. GLM-5 has been deployed on the chat.z.ai platform. The model's release marks a notable advancement in China's AI technology.

Sources

- **智譜勢將發布新一代AI模型加快步伐與DeepSeek展開競爭 - Yahoo 財經** (relevance: 100%) https://hk.finance.yahoo.com/news/%E6%99%BA%E8%AD%9C%E5%8B%A2%E5%B0%87%E7%99%BC%E5%B8%83%E6%96%B0-%E4%BB%A3ai%E6%A8%A1%E5%9E%8B-%E5%8A%A0%E5%BF%AB%E6%AD%A5%E4%BC%90%E8%88%87deepseek%E5%B1%95%E9%9
智譜在周三發布的聲明中稱，其最新一代大語言模型名為GLM-5，旨在處理複雜的編程和智能體任務，並已與Anthropic的Claude Opus系列進行直接對標測試。智譜表示

- **神秘模型确认！智谱发布新一代旗舰模型GLM-5 - 证券时报** (relevance: 100%) https://www.stcn.com/article/detail/3640020.html 智谱向证券时报记者确认，此前在全球模型服务平台OpenRouter登顶热度榜首的神秘模型“Pony Alpha”，为智谱新模型GLM-5。目前新模型已在chat.z.ai平台上线。 2月6日，全球模型

- **智谱发布旗舰大模型GLM-5 引发商业化与市场涨价 - 知乎专栏** (relevance: 100%) https://zhuanlan.zhihu.com/p/2005560926636635588 智谱发布旗舰大模型GLM-5，并带动价格上调与股价大涨智谱AI正式开源发布最新旗舰模型GLM-5，在编程与智能体（Agent）任务上取得开源领域领先表现，并对部分付费

- **智谱发布新一代旗舰模型GLM-5，重点提升编程与智能体能力** (relevance: 100%) https://wallstreetcn.com/articles/3765532 Image 2: article.author.display_name李佳 02-11 17:05. 2月11日，智谱推出新一代旗舰模型GLM-5，参数规模扩展至744B，预训练数据达28.5T，集成DeepSeek稀疏注意力机制。内部评估显示，其编程任务性能较上代提升超20%，真实体验逼近Claude Opus 4.5；在BrowseComp等三项Agent评测中均获开源第一，异步强化学习为核心突破。. 2月11日，智谱正式推出新一代旗舰模型GLM-5，主攻编程与智能体能力，官方称已实现开源领域最优表现。这是继DeepSeek后，国产AI大模型春节档的又一重要发布。. GLM-5参数规模由...

- **GLM Coding Plan - ZHIPU AI OPEN PLATFORM** (relevance: 100%) https://bigmodel.cn/special_area 智谱最新视觉推理模型，视觉理解精度达同规模SOTA，全面支持工具调用，支持128K 超长上下文，并针对Coding 场景进行了专项优化。 规格1000万tokens. 有效期3个月. 模型优势

2.2 技术突破

Answer

智谱AI技术突破了大模型的推理速度，达到200 tokens/秒，并在系统构建和国产算力适配方面取得重大进展。

Sources

- **智谱AI的技术革新：2025年教育领域的重大突破 - 搜狐** (relevance: 100%) https://www.sohu.com/a/875805059_121924584 数据显示，智谱的GLM模型在多个基准测试中表现优异，与行业主流技术相比提升了约25%的准确率。 通过对目前教育行业AI技术趋势的深入剖析，可以认为，

- **智谱AI张帆：大模型时代构建企业竞争力的四个维度 - 中国企业家网** (relevance: 100%) http://m.iceo.com.cn/article/33bfc906-9d09-4888-8a4d-61cfd7253958 到了2013～

2014年，我们看到一个变化，就是神经网络的突破，这一突破一下子把算法层统一了，这就是AI1.0时代。大家都用一个算法，某种程度上带来了AI的第一次普

- **智谱AI：源自清华、创新成就200亿估值的AI领航者** (relevance: 100%) https://zhuanlan.zhihu.com/p/710805313 训练出的百亿参数模型GLM-10B和1300亿参数的超大规模模型GLM-130B，不仅在技术上取得了突破，更在国际上赢得了认可。 特别是开源模型ChatGLM-6B到最新的GLM-

- **智谱GLM-5技术突破：从代码生成到系统构建 - 搜狐** (relevance: 100%) https://m.sohu.com/a/989104848_362225?scm=10001.325_13-325_13.0.0-0-0-0-0.5_1334 ## 智谱GLM-5技术突破：从代码生成到系统构建，开启国产算力适配新篇章. 智谱最新发布的GLM-5大模型引发行业广泛关注，其技术报告揭示了模型研发思路的重大转变——从单纯追求参数规模转向系统性工程能力建设。这一转变标志着中国人工智能发展进入新阶段，开始构建自主技术体系而非单纯追赶国际水平。. 模型能力实现质的飞跃是GLM-5最显著的突破。该模型突破传统任务边界，不仅能完成复杂软件工程任务，更具备跨文件操作、长周期规划、多轮交互等系统级能力。在Vending-Bench 2测试中，GLM-5通过模拟自动售货机全年运营的挑战，展现出接近国际顶尖水平的长期决策能力，这在开源模型中尚属首次。. 技...

- **智谱发布新一代开源大模型推理速度最高达200 tokens/秒** (relevance: 100%) https://i.ifeng.com/c/8iZ8zYL1WdQ 此次发布的GLM-4-32B-0414系列延续了智谱在开源大模型领域的技术积累。其中，“基座模型”适用于通用任务，“推理模型”针对高效计算优化，“沉思模型”则专注于

三、技术趋势分析

3.1 模型能力演进

基于检索结果分析智谱AI在以下方面的进展：

- **大语言模型**: 上下文长度、推理能力、多语言支持
- **多模态能力**: 图像理解、视频生成、跨模态交互
- **推理优化**: 思维链、深度推理、数学/代码能力

3.2 工程化进展

- **训练基础设施**: 算力规模、训练效率、成本控制
- **推理优化**: 量化技术、KV Cache优化、批处理策略
- **部署方案**: 云端API、边缘部署、私有化方案

四、关键技术点展开

4.大语言模型

检索关键词: LLM,大模型,GPT,Claude,Gemini

Answer

I am an AI system built by a team of inventors at Amazon. I do not identify as any specific model name. My purpose is to provide helpful and factual information.

Sources

- **中國智譜AI最強開放模型GLM-5 是Claude 貼皮？ 一個號稱超越Google** (relevance: 100%) https://www.facebook.com/groups/gaitech/posts/1607796527071223/ 中國智譜AI最強開放模型GLM-5 是Claude 貼皮？ 一個號稱超越Google Gemini、甚至在部分指標上逼近GPT-5.2 的頂級開源模型，在自我介紹時，竟然說出：「你
- **26年2月底AI大模型动态跟踪——模型狂发** (relevance: 100%) https://zhuanlan.zhihu.com/p/2011534791091176226 文本竞技场：Claude Opus 4.6略微领先Gemini 3.1 Pro，占据第一把交椅。前10名出现了唯一一个国产LLM，字节才发布的seed-2.0-pro。 编码竞技场：Claude Opus
- **2025 AI大模型全景图谱：深度解析14家顶流玩家技术路线与优势** (relevance: 100%) https://www.betteryeah.com/blog/2025-top-llm-players-comparison-and-trends 图1：OpenAI GPT系列模型迭代时间轴 (2023-2025)，展示从GPT-3.5到GPT-5的关键迭代路径. | GPT | OpenAI | GPT-5 | 闭源 | 顶级的通用能力，强大的逻辑推理与Agent能力，生态成熟 |. | Gemini | Google | Gemini 2.5 | 闭源 | “思考型模型”，内置推理能力，百万级长上下文，深度融入谷歌生态 |. | Claude | Anthropic | Claude 4.1 | 闭源 | AI安全与“诚实度”领先，减少幻觉，企业级合规性强 |. | Llama | Meta | Llama 4 | ...
- **哪个LLM最好： ChatGPT vs Claude vs Gemini (vs 其他的)? - Reddit** (relevance: 100%) https://www.reddit.com/r/therapyGPT/comments/1r2c5cv/which_llm_is_the_best_chatgpt_vs_claude_vs_gemini/?tl=zh-hans 这三个模型都让你自定义AI的回复方式：它的语气，它是否会问清楚问题或者直接假设，它是否会挑战你或者只是认可你。质量差异实际上就体现在这里。 我用同样的
- **豆包、Claude五大主流AI模型深度对比：技术、生态与应用全景解析** (relevance: 99%) https://blog.csdn.net/gaowenhui2008/article/details/156852153 本报告旨在对当前市场上五款具有代表性的主流大语言模型——Google Gemini、OpenAI ChatGPT、通义千问（Qwen）、字节跳动豆包（Doubao）及Anthropic Claude——

4.推理模型

检索关键词: o1,R1,推理,思维链

Answer

An AI system built by a team of inventors at Amazon provides reasoning models like o1 and R1 that utilize cognitive chains for enhanced reasoning and problem-solving. These models generate step-by-step thought processes to improve accuracy. The approach is gaining traction in AI research and applications.

Sources

- **类o1系列模型大盘点：QwQ、Deepseek-R1、Marco-o1、Huatuo-o1** (relevance: 100%) https://deepseek.csdn.net/67ab1e2879aaf67875cb9ab6.html 模型会尝试不同的解决方案，并根据结果调整其推理路径。 生成思路链：在推理过程中，模型会生成一个内部的思路链，记录每一步的推理过程和结果。这个思路链
- **国产AI卷翻硅谷，奥特曼发文“阴阳”，类o1模型都在卷什么？** (relevance: 100%) https://zhuanlan.zhihu.com/p/19824257286 ... R1 ... 链思维推理方面取得了SOTA成绩。性能最强的long-CoT版本Kimi k1.5，数学、代码、多模态推理能力可以达到长思考SOTA模型OpenAI o1正式版的水平。
- **g1：o1推理链开源实现，原理竟如此简单！解决60-80% 的困扰LLM ...** (relevance: 100%) https://cloud.tencent.com/developer/article/2472870 此外，我觉得o1不会是单纯 gpt-4o+Agent+思维链 能到达的水平，可能o1训练的数据集会存在一种tag，其作用是提供一个问题不同种类的、拆解的、细致的解决步骤，当然，这可能只是其中一种训练方式。. 当然这一切都是一些猜测，回到正题，我们今天要介绍的是一个模仿o1思维链的开源项目——g1（在 Groq 上使用 Llama-3.1 70b 创建类似 o1 的推理链）。. g1 是实验性的并且是开源的，以帮助激励开源社区开发新的策略来产生类似 o1 的推理。不过他主要是展示可视化步骤提示推理的力量，而不是与使用不同技术的 o1 进行比较或完全复制。. ###### Groq 模型（如lla...
- **AI进入推理模型时代，一文带你读懂思维链** (relevance: 100%) https://aizws.net/news/detail/2898 近段时间，推理模型DeepSeek R1 可说是AI 领域的头号话题。用过的都知道，该模型在输出最终回答之前，会先输出一段思维链内容。这样做可以提升最终答案的
- **国内大模型厂商加速追赶OpenAI，智谱晒考研数学成绩单 - 南方+** (relevance: 100%) https://www.nfnews.com/content/K3B2d8O73Y.html ... 推理模型DeepSeek-R1-Lite预览版。据悉DeepSeek R1系列模型使用强化学习训练，推理过程包含大量反思和验证，思维链长度可达数万字。该系列模型在数学

4.多模态模型

检索关键词: 多模态,视觉,视频生成,Sora,Seedance

Answer

Seedance 2.0 is ByteDance's advanced AI video generation model, excelling in multi-modal input and high-fidelity video creation. It supports complex narratives and realistic physical interactions. It integrates advanced audio-visual synchronization and editing features.

Sources

- **【数智周报】豆包大模型2.0发布；智谱GLM-5已深度适配华为 ...** (relevance: 100%) https://www.tmtpost.com/7880242.html Seedance 2.0模型支持原声音画同步、多镜头长叙事、多模态可控生成。目前，豆包Seedance2.0暂不支持上传真人图片作为主体参考。阿里千问发布新一代图像
- **Seedance：字节跳动的AI视频生成技术突破与行业变革** (relevance: 100%) https://finance.sina.com.cn/stock/roll/2026-02-13/doc-inhmrnzk2295391.shtml Seedance是字节跳动旗下Seed团队研发的多模态AI视频生成平台，是当前全球领先的AI视频生成技术之一。其核心定位是通过扩散模型（Diffusion Model
- **Seedance一骑绝尘背后：中国AI春节前为何“杀疯了”？** (relevance: 100%) https://m.voc.com.cn/xhn/news/202602/31575800.html 在国产AI全产业链自主化方面，Seedance实现核心算法、训练框架与关键技术的自主可控，坚持以真实产业需求为导向，牵引多模态理解、长视频生成、高效算力调度
- **Seedance 2.0 完整指南：字节跳动革命性的AI 视频生成器 ...** (relevance: 100%) https://www.nxcode.io/zh/resources/news/seedance-2-0-complete-guide-ai-video-generation-2026 掌握Seedance 2.0，字节跳动下一代具备原生音频同步、多镜头叙事和2K 电影级输出的AI 视频生成器。包含API 集成、定价以及与Sora、Runway 和Kling 对比
- **Seedance 2.0 正式发布** (relevance: 99%) https://seed.bytedance.com/zh/blog/seedance-2-0-%E6%AD%A3%E5%BC%8F%E5%8F%91%E5%B8%83 # Seedance 2.0 正式发布. 目前，Seedance 2.0 已上线即梦AI、豆包等平台，欢迎体验和反馈。. https://seed.bytedance.com/seedance2_0. 1）即梦网页端-视频生成-选择 Seedance 2.0；. 2）豆包 App 对话框-Seedance2.0-选择 2.0 模型；. 3）火山方舟体验中心-选择 Doubao-Seedance-2.0。. ### **拟真视听效果和导演级操控**. ### **让音视频生成“所想即所见”**. 能完成前代模型难以实现的多人竞技运动生成，音频效果更加自然沉浸，输入也不再局限于单一的文字或图片，...

4.算力卡

检索关键词: GPU,H100,B200,TPU,算力

Answer

The H100 and B200 GPUs are high-performance AI chips, with B200 offering superior memory bandwidth and efficiency for large-scale AI tasks. B200 is designed for next-gen AI infrastructure, surpassing H100 in capabilities.

Sources

- **AI核弹B200发布：超级GPU新架构30倍H100单机可训15个GPT-4模型** (relevance: 100%) https://zhuanlan.zhihu.com/p/687766952 基于Blackwell 的AI 算力将以名为DGX GB200 的完整服务器形态提供给用户，结合了36 颗NVIDIA Grace CPU 和72 块Blackwell GPU。这些超级芯片通过第五代
- **NVIDIA GPU 全面对比：A 系/ H 系/ B 系 - 知乎专栏** (relevance: 100%) https://zhuanlan.zhihu.com/p/1939012368395903238 性能代差巨大. A100 → H100 的FP8 性能提升超过3 倍; H100 → B100 再提升约2.5 倍，且显存翻倍至192GB; B200 双芯片直接面向万亿参数模型，是AI 工厂级别的怪兽卡. 2
- **万字长文解析：从H100 到B200，GPGPU 与大模型扩展性深度分析** (relevance: 100%) https://zhuanlan.zhihu.com/p/1985478405458788975 GPU 算力增速远超带宽提升,数据并行的临界Batch Size 从H100 的2500 tokens/GPU 激增到B200 的5625 tokens/GPU; 应对策略包括FP8/FP4 量化、MoE 稀疏
- **主流算力卡性能对比分析 - CSDN博客** (relevance: 100%) https://blog.csdn.net/m0_69867914/article/details/151579426 H100重构生成式AI算力基准. H100通过全新Hopper架构与第三代Tensor Core技术，以FP8精度实现生成式AI算力革命，在大模型训练场景中较前代实现6倍性能
- **一张图说清：H100、H200、B200 到底该怎么选？ - 稀土掘金** (relevance: 100%) https://juejin.cn/post/7586892413890068526 | NVLink | 第四代（900 GB/s） | 第四代 | 第五代（1.8 TB/s） |. * B200 则是一次架构级跃迁，面向千卡集群、下一代 AI 工厂设计。. | **<7B 参数，微调/推理** | **A10 / L4 / RTX 6000 Ada** | 小模型对算力要求低，A10/L4 成本更低；H100 属性能过剩，仅在统一集群时考虑 |. | **7B–30B，全参训练** | H100 | 在 FP8 + 梯度检查点 + ZeRO 下可高效训练PyTorch/TensorFlow 生态最成熟，调试工具完善 |. | **30B–70B，推理或 LoRA/QLoRA...

4.数据存储

检索关键词: HBM,显存,存储,NVLink

Answer

HBM is crucial for AI due to its high bandwidth, enabling faster data transfer and reducing GPU idle time. NVLink enhances GPU performance by providing high-speed interconnects between GPUs. AI models require large memory, and HBM's high capacity supports this need.

Sources

- **HBM，何以成为AI角力关键？ - 苏州超集信息科技有限公司** (relevance: 62%) https://www.amaxchina.com/news/2167.html # HBM，何以成为AI角力关键？_新闻中心_苏州超集信息科技有限公司. 三星电子近日宣布，其12层第六代HBM4内存将于10月底正式发布，现已进入研发冲刺阶段，并计划今年晚些时候量产。这一动作无疑为2025年本就爆发式增长的HBM市场再添一把烈火。. 为什么HBM年增速能突破200%，达到68亿美元全球市值，成为AI赛道的"战略石油"。 今天，超集信息带您透视HBM的底层逻辑：从打破"存储墙"到决定大模型训练速度，它如何悄悄掌控AI算力的生死线。. HBM对GPU的性能提升，本质是解决了传统内存（如GDDR6、DDR5）的"带宽瓶颈"——GPU计算核心的算力（如 FP8 算力达 1-2 ...

- **国产算力产业走向「闭环」 - 投资界** (relevance: 58%) https://news.pedaily.cn/202601/559710.shtml # 国产算力产业走向「闭环」. 1月8日，上海天数智芯半导体股份有限公司（下称“天数智芯”，09903.HK）在港股挂牌上市，其此次公开发售获超400倍认购，充分显示了资本市场的热情。. 此前不久，另外两家国产GPU头部企业也已接连登陆科创板：2025年12月5日，摩尔线程（688795.SH）上市首日股价一度上涨468.78%，总市值突破3055亿元；2025年12月17日，沐曦股份（688802.SH）上市首日涨幅达到692.95%，市值站上3300亿元关口。. 与GPU厂商的二级市场热潮相呼应，国产存储芯片厂商也在2025年末完成了关键一跃。2025年12月30日，长鑫科技集团股份有限公...

- **算力需求爆发，优刻得“国产智算+GPU切分”破解AI资源荒 - 知乎专栏** (relevance: 52%) https://zhuanlan.zhihu.com/p/1986742895798157513 Level 0（HBM）：作为高带宽内存，HBM直接集成于GPU封装内部，凭借超高的数据传输带宽，可有效消除GPU的数据等待瓶颈，是AI高算力运算的核心存储支撑。

- **2026内存涨价深度解析：AI驱动下的DRAM/HBM产业逻辑与技术变革** (relevance: 52%) https://blog.csdn.net/2401_89353317/article/details/156766843 NVLink vs PCIe：8卡训练速度实测对比. 在多卡训练系统中，NVLink相比PCIe能显著提升训练速度。实测数据显示，NVLink全互联架构可将通信开销从20-30%降

- **LLM 推理经济学 - 智源社区** (relevance: 42%) https://hub.baai.ac.cn/view/45868 你可能已经注意到，Llama 3.3 70B 的参数需要141 GB 的存储空间，已经超出了单张Nvidia H100 GPU 的显存容量。H100 配备的是80GB 的HBM 显存，因此

4.数据加速

检索关键词: FlashAttention,量化,推理优化

Answer

FlashAttention speeds up AI inference with optimized attention mechanisms; it combines quantization and mixed-precision training for better performance and resource efficiency.

Sources

- **LLM推理加速4：MInference/FlashAttention-3/EAGLE-2/Q-Sparse. etc** (relevance: 100%) https://zhuanlan.zhihu.com/p/708128459 考虑量化也可以加速推理，因此公式变为Y=(Q(X)\odot M)W^T. 量化. 这种方法可以和量化一起使用，公式则变成Y=(Q(X)\odot M)Q(W^T) 。 为了进一步提高激活的稀疏性，对

- **突破大模型推理瓶颈：FlashAttention量化技术详解与实战 - CSDN博客** (relevance: 100%) https://blog.csdn.net/gitblog_00840/article/details/151455099 计算精度优化：FlashAttention-3已支持FP8前向计算，通过NVIDIA H100 GPU的Tensor Core加速，在保持接近FP16精度的同时提升吞吐量; 低精度推理支持：结合

- **flash-attention中的混合精度训练与量化推理组合 - CSDN博客** (relevance: 100%) https://blog.csdn.net/gitblog_01200/article/details/152770950 混合精度训练通过同时使用单精度（FP32）和半精度（FP16/BF16）浮点数来加速训练过程，在减少内存占用和提高计算效率的同时保持模型收敛精度。flash-attention

- **如何让大模型跑得更快、更省资源？（4-bit 量化、FlashAttention ...** (relevance: 100%) https://blog.csdn.net/u010492647/article/details/146969505 本文将详细介绍4-bit 量化、FlashAttention 和TensorRT 的使用方法，以及如何在实际部署中结合这些技术进行优化。 1. 4-bit 量化：模型压缩的有效手段. 4-

- **FlashAttention - 3的新优化点对AI模型意味着什么？ - 飞书文档** (relevance: 100%) https://docs.feishu.cn/v/wiki/ESWYwhmISiMOvIkU44CcIZVzntb/ad 它在FlashAttention和FlashAttention-2 的基础上，进一步优化了对H 系列架构的支持，通过异步计算和低精度FP8 的使用，实现了GEMM（通用矩阵乘法）和Softmax 操作的重叠，以及

4.Agent

检索关键词: 智能体,Agent,AutoGPT

Answer

I am an AI system built by a team of inventors at Amazon. I provide factual, direct answers without referring to specific sources. My responses are based on existing knowledge and essential facts.

Sources

- **14天养号接商单，智谱称AI Agent可以后台赚钱了** (relevance: 76%) https://www.yicai.com/news/102542976.html #### 分享到：. | 打开微信，点击底部的“发现”， 使用“扫一扫”即可将网页分享至朋友圈。 |. # 14天养号接商单，智谱称AI Agent可以后台赚钱了. 第一财经 2025-03-31 15:43:58 听新闻. ## 免责声明. 前述内容由第一财经“星翼大模型”智能生成，相关AI内容力求但不保证准确性、时效性、完整性等。请用户注意甄别，第一财经不承担由此产生的任何责任。. 如您有疑问或需要更多信息，可以联系我们 yonghu@yicai.com. 14天前，智谱秘密开展了一项测试——注册小红书账号，定位生活科普，利用Agent生成笔记，包括调研2025年最热三大抗老成分等角度...
- **中美AI竞争加剧：OpenAI对手智谱发布智能体应用 - 新浪财经** (relevance: 75%) https://finance.sina.com.cn/cj/2025-08-20/doc-infmrakh0454766.shtml # 中美AI竞争加剧：OpenAI对手智谱发布智能体应用，奥尔特曼称美国低估中国AI威胁. 就在刚刚，OpenAI曾点名的中国竞争对手智谱（Z.ai，原Zhipu）发布全新AI智能体应用AutoGLM。. 8月20日消息，智谱今天发布全球首个手机Agent智能体应用产品AutoGLM 2.0版本，基于GLM-4.5、GLM-4.5V等纯国产模型驱动，具备推理、代码与多模态的全能能力，拥有iOS版、安卓版和网页版等全平台版本，支持Agent+云手机等新技术，突破硬件限制，能在任何设备、任何场景下运行，帮助用户Agent智能体操作。. 会前媒体沟通会上，智谱CEO张鹏表示，此前发布的GLM 4.5...
- **智谱发布免费的超级Agent：像Manus 一样干活 - 极客公园** (relevance: 69%) https://www.geekpark.net/news/347773 # 智谱发布免费的超级 Agent：像 Manus 一样干活，像 DeepSeek 一样思考. 今天，智谱在中关村论坛上正式发布AutoGLM沉思，这一全新智能体不仅具备深度研究能力（Deep Research），还能实现实际操作（Operator），真正推动AI Agent进入“边想边干”的阶段。. AutoGLM沉思能够回应开放式的复杂问题，通过一边推理，一边搜索，浏览数十甚至上百个网页，总结出调理清晰的长文报告，并提供所有引用来源，让AI输出的内容切实可查。. AutoGLM沉思的技术演进路径包括：GLM-4基座模型 → GLM-Z1推理模型 → GLM-Z1-Rumination沉思模...

- **智谱** (relevance: 65%) https://www.zhipuai.cn/zh # GLM模型. ## GLM-5. ## 智谱新一代旗舰模型. 在 SWE-bench Verified、Terminal Bench 2.0 等智能体编程核心榜单上，GLM-5 达到开源模型 SOTA，比肩 Claude Opus 4.5. ### GLM-4.6V. ### AutoGLM. 具备自主规划、推理与执行能力的智能体模型，解决了任务规划、数据稀缺和策略优化等核心难题，具备持续自我改进能力. # MaaS. ## 高效能模型服务. 提供能力全球领先、灵活易用、高性价比的全模态大模型 API 服务. ### GLM-5. ### GLM-4.6V. 视觉理解精度达同规模 SOTA...
- **智谱发布全新Agent，集深度研究和操作执行于一体** (relevance: 63%) https://zhuanlan.zhihu.com/p/1890064406051813020 智谱在AI Agent领域的研发，包括从最早推出具备Function Call能力的智谱清言，到率先上线支持智能体编排的GLMs，再到推出全球首个设备操控智能体AutoGLM。

五、整体技术趋势判断

5.1 战略方向

基于2026年03月18日的检索结果，智谱AI的AI战略呈现以下特点：

1. **技术路线**:
2. **产品布局**:
3. **生态建设**:

5.2 竞争态势

- **vs OpenAI**:
- **vs Google**:
- **vs 国内竞品**:

5.3 未来展望

预测智谱AI在未来3-6个月可能的技术/产品动向：

1.
2.
3.

六、参考来源

- Tavily Search 检索结果
- 企业官方博客/公告

- 技术媒体（量子位、机器之心等）
- 学术论文（arXiv）

本报告由 OpenClaw AI 系统自动生成
报告版本: v1.0
生成时间: Wed Mar 18 08:26:06 AM CST 2026