

MiniMax AI技术洞察报告

报告日期: 2026年04月05日

生成时间: 06:02:29

数据来源: Tavily Search, 企业博客, 新闻媒体

洞察范围: 模型发布、技术动态、产品更新

一、公司概况

公司名称: MiniMax

主要产品: 海螺AI, 星野

检索优先级: 高

二、最新动态检索

2.1 产品/模型发布

Answer

MiniMax released its new AI model M2.7 on March 18, showcasing "model self-evolution." The model focuses on self-training and optimization. It has a parameter size of 230B with 10B active parameters.

Sources

- 走向“模型自我进化” MiniMax发布新一代大模型M2.7 - 凤凰网财经 (relevance: 100%) <https://finance.ifeng.com/c/8ravhDb0lp6> 国产AI大模型公司MiniMax于3月18日发布新一代模型M2.7，首次展示“模型自我进化”路径。该模型通过构建Agent Harness（智能体执行框架）体系，深度参与自身训练与优化流程，在
- MiniMax发布新一代大模型M2.7 - 东方财富 (relevance: 100%) <https://finance.eastmoney.com/a/202603183676221962.html> 本报讯（记者张文湘）3月18日，MiniMax（上海稀宇极智科技有限公司）发布新一代Agent旗舰大模型M2.7，首次展示“模型自我进化”路径。

- **MiniMax自进化基座小米1T模型发布Google AI Studio全栈重构** (relevance: 100%) <https://www.youtube.com/watch?v=J7rkTq-aVZE> AI周报3.24: MiniMax自进化基座小米1T模型发布Google AI Studio全栈重构. 226 views • 11 days ago. #GoogleAISTudio #OCR #MiniMaxAI ...more
- **刚刚，MiniMax M2拿下开源模型第一 - 知乎专栏** (relevance: 100%) <https://zhuanlan.zhihu.com/p/1966466361678075827> 昨天，MiniMax发布并开源了他们的新一代旗舰模型：MiniMax M2一款专注Max coding & Agentic workflows的Mini model，参数量只有230B（激活参数10B）。
- **上海AI独角兽MiniMax发布全模态“全家桶” - 新浪财经** (relevance: 100%) <https://finance.sina.com.cn/roll/2025-11-01/doc-infvwfmt7903621.shtml> 10月27日，新一代文本大模型MiniMax-M2正式发布和开源，这款仅有10B激活参数（总参230B）的轻量级模型在全球权威测评榜单Artificial Analysis (AA)上创造了

2.2 技术突破

Answer

MiniMax技术突破了传统Transformer架构，实现了线性注意力机制，并推出了多代大模型，包括M2.1和M2.7，在多语言编程和软件工程方面表现卓越。

Sources

- **MiniMax-01大模型的技术突破与未来展望 - 知乎专栏** (relevance: 100%) <https://zhuanlan.zhihu.com/p/21567198146> MiniMax-01是MiniMax公司推出的一款具有里程碑意义的大模型，其核心创新在于首次大规模实现了线性注意力机制（Lightning Attention），彻底打破了传统Transformer架构的局限。
- **MiniMax发布M2.1模型：多语言编程SOTA背后的技术突破与商业逻辑** (relevance: 100%) <https://aistudio.baidu.com/blog/detail/755304882763973> 2025年12月，MiniMax在港交所聆讯后迅速发布新一代旗舰级Coding & Agent模型M2.1，以仅10B激活参数在Multi-SWE-bench榜单中取得49.4%的成绩，超越Claude。
- **MiniMax M2.7 - 模型自我进化，以技术突破驱动生产力革新** (relevance: 100%) <https://www.minimaxi.com/models/text/m27> MiniMax M2.7MiniMax M2.5MiniMax M2-HerMiniMax M2.1MiniMax M2. MiniMax Speech 2.6MiniMax Speech 2.5. MiniMax Hailuo 2.3 / 2.3 FastMiniMax Hailuo 02. MiniMax Music 2.5+MiniMax Music 2.5MiniMax Music 2.0MiniMax Music 1.5. MiniMax M2.7NEWMMiniMax M2.5MiniMax M2-HerMiniMax M2.1MiniMax M2. MiniMax Speech 2...

- 稀宇科技连续发布大模型新产品MiniMax-M1系列长文本能力跻身全球 ... (relevance: 100%) <https://www.shanghai.gov.cn/nw4411/20250622/75b969a99884465ea0ac64759d587969.html> MiniMax-M1系列模型采用大规模混合架构的推理模型，在处理百万级Token（词元）长文本上实现了突破，支持高达100万Token的上下文窗口，与谷歌最新发布的Gemini
- Minimax-M2.1大模型技术架构与性能测评报告 - 奈斯猫 (relevance: 100%) <https://www.nsmiao.com/announcement/126> Minimax - M2.1 大模型的技术架构以“高效能- 强泛化- 易部署”为三位一体设计目标，构建了兼顾性能突破与工程落地的完整技术体系。该架构在基础框架层面实现

三、技术趋势分析

3.1 模型能力演进

基于检索结果分析MiniMax在以下方面的进展：

- **大语言模型:** 上下文长度、推理能力、多语言支持
- **多模态能力:** 图像理解、视频生成、跨模态交互
- **推理优化:** 思维链、深度推理、数学/代码能力

3.2 工程化进展

- **训练基础设施:** 算力规模、训练效率、成本控制
- **推理优化:** 量化技术、KV Cache优化、批处理策略
- **部署方案:** 云端API、边缘部署、私有化方案

四、关键技术点展开

4.大语言模型

检索关键词: LLM,大模型,GPT,Claude,Gemini

Answer

MiniMax's LLMs are competitive in performance and cost, especially for long context and multimodal applications. MiniMax M2.5 is noted for its efficiency and low cost, making it popular for agent-based tasks. MiniMax's models have shown strong performance in benchmarks and real-world applications.

Sources

- **中國AI公司MiniMax推出新LLM，支援400萬Token與多模態應用** (relevance: 100%)
<https://www.ithome.com.tw/news/167013> # 中國AI公司MiniMax推出新LLM，支援400萬Token與多模態應用. 中國MiniMax推出MiniMax-01系列，語言模型支援400萬Token上下文處理，性能與頂尖模型相當，多模態模型專注文本與影像結合，適用智慧助理與多媒體生成，定價具競爭力但存政策風險. 中國人工智慧公司MiniMax推出MiniMax-01系列模型，其中包含語言模型MiniMax-Text-01和視覺多模態模型MiniMax-VL-01。這兩款模型在超長上下文處理和多模態理解方面表現出色。具有4,560億參數的MiniMax-Text-01支援長達400萬Token的上下文處理能力，並在多項基準測試中與O...
- **26年2月底AI大模型动态跟踪——模型狂发 - 知乎专栏** (relevance: 100%) <https://zhuanlan.zhihu.com/p/2011534791091176226> 除了国外御三家外：Gemini、GPT、Claude；国产大模型超过75%的也越来越多，最高分的MiniMax-M2.5也超过了80%。OpenAI在2月23号有发布一篇文章说SWE
- **霸榜全球大模型，力压Claude、GPT，MiniMax凭什么？ -36氪** (relevance: 100%)
<https://m.36kr.com/p/3720864696070913> 它压过的，不是一些普通模型，而是Gemini、DeepSeek、Claude等旗舰模型。 . 来源：OpenRouter LLM Leaderboard
(2026.2.12-2026.3.12) . ## **01 MiniMax为何全球第一？** . MiniMax M2.5：输入0.27美元/百万Token，输出0.95美元/百万Token。 . Claude Opus 4.6：输入5美元/百万Token（约18倍）、输出25美元/百万Token（约26倍）。 . 一位海外开发者在X上算了一笔账：“跑OpenClaw连续1小时（100 TPS），MiniMax M2.5只要1美元；换Claude一天...
- **25年12月底AI大模型动态跟踪——轰轰烈烈的2025** (relevance: 100%) <https://zhuanlan.zhihu.com/p/1988759946175729936> ... Gemini 3.0系列、GPT-5.2、minimax-m2.1、GLM-4.7并列第二档 ... 除了国外四巨头：Gemini、GPT、Claude、Grok；国产大模型超过70%的也越来
- **人工智能- 大模型榜单周报（2025/12/27） - KAI智 - SegmentFault 思否** (relevance: 98%) <https://segmentfault.com/a/1190000047506874> ##### KAI智. ##### KAI智. # 大模型榜单周报（2025/12/27）. 本周大模型领域持续涌现创新成果，数学、编程和多模态能力均出现显著进展。字节推出数学模型Seed Prover 1.5，在国际数学奥林匹克竞赛中取得金牌线成绩，而智谱AI开源GLM-4.7在多项评测中超越GPT-5.1。MiniMax的M2.1编码模型以10B激活参数创下多语言软件工程能力新高，北航提出的代码模型Scaling Laws为最优数据配比提供理论基础。 . | 模型调用量 | Grok Code Fast 1 | Claude Sonnet 4.5 | Gemini 2.5 Flash |. | ...

4.推理模型

检索关键词: o1,R1,推理,思维链

Answer

MiniMax 推理模型通过思维链提升推理能力，表现在复杂逻辑和数学问题上更优。推理模型的思维链有助于理解和改进模型。MiniMax 模型的推理过程透明，有助于技术改进。

Sources

- **从o1到DeepSeek-R1，万字长文带您揭秘推理模型——及其与标准 ...** (relevance: 100%) <https://zhuanlan.zhihu.com/p/26076930125> 推理模型与标准LLM的主要区别在于能够在回答问题之前“思考”。推理模型的思维只是由LLM输出的长链思维——简称长CoT，有时称为推理轨迹或路径。长CoT的生成
- **示例，因为由于思维链的存在，推理模型的“智能”程度高了** (relevance: 100%) <https://x.com/dotey/status/1888020104262382039> 去年OpenAI 发布o1 这样的推理模型，接着 DeepSeek 也发布了DeepSeek R1 推理模型，推理模型和传统的生成式语言模型的差别在于，传统的生成式语言模型在收到
- **o1-preview/mini模型的思维链技术解析 - 飞书文档** (relevance: 100%) <https://docs.feishu.cn/v/wiki/XiTmw383fiDr3bkjYe6cjlKnue/a8> OpenAI 最近公布的模型发布计划中提到的"推理模型" 已经成为业界热点。而 ... o1在推理方面，基本等于电瓶车 and 宾利的差距了...不信你看下方详细测试结果。
- **中国版的o1来了！DeepSeek-R1-Lite媲美o1-preview，还原完整COT ...** (relevance: 100%) <https://developer.volcengine.com/articles/7441466492882944037> # 中国版的o1来了！DeepSeek-R1-Lite媲美o1-preview，还原完整COT推理过程！. ##### Aitrainee | 公众号：AI进修生. 好了，Deep Seek 发布了新 R1 Light 模型，今天我们来聊聊它，他们声称这个模型释放了超级推理能力，推理过程包含大量反思和验证，思维链长度可达数万字。官方说，该系列模型在数学、代码以及各种复杂逻辑推理任务上，取得了媲美 o1-preview 的推理效果，并且，因为 OpenAI 的 o1 模型并没有展示推理过程，而这个模型提供了原始的推理过程，它可以帮助我们更好地理解这些模型如何进行推理，甚至可能改善我们与这些模...
- **关于推理模型的一些误解和盲区 - OneV's Den** (relevance: 100%) <https://onevcats.com/2025/02/reasoning-model/> DeepSeek 给国内带来的 AI 普及和升级还在持续，虽然对于 AI 从业者和一些一直关注前沿的科技工作者来说，不论是传统 LLM 还是推理模型都不是什么太新鲜的概念了，但是对于行业外的长辈和小辈，或者是专注点刚被吸引到 AI 的业内人士来说，DeepSeek，特别是 DeepSeek-R1 的出现和爆火，可能是他们第一次真正在生活和工作里认真地接触和使用 AI。比如 OpenAI o1 和 DeepSeek-R1 这样的推理模型，在数学、逻辑、代码等可以明确定义正确与否的领域，表现远超通用 AI。但是在创意、写作、翻译这类“偏文科”和内容创造性的方面，通用 AI 可能表现得更好。究...

Seedance 2.0就自动还原了建筑背面的真实结构；仅凭人脸照片（无参考音频），模型生成了...

- **Seedance一骑绝尘背后：中国AI春节前为何“杀疯了”？** (relevance: 98%) <https://www.xhby.net/content/s69910e12e4b0a86466830489.html> 无锡 徐州 常州 苏州 南通 连云港 淮安 盐城 扬州 镇江 泰州 宿迁. 2026/02/15 08:06 澎湃新闻. 最近，字节跳动旗下最新视频大模型Seedance 2.0凭借关键技术能力突破，构成实现接近“导演级”的控制精度，生成能力与稳定性大幅提升，在海外市场可谓是“杀疯了”。. 马斯克转发评论Seedance 2.0相关推文并表示：模型发展速度太快（It ' s happening fast）；也有美国导演在使用Seedance 2.0后感叹：好莱坞可能要完了。. 有外媒称，迪士尼公司已向字节跳动发函，指控对方在训练和开发Seedance 2.0模型时未经许可使用迪士尼作品，要求字节跳...

4.算力卡

检索关键词: GPU,H100,B200,TPU,算力

Answer

H100, B200, and TPU are advanced computational units; H100 and B200 excel in AI training with high throughput; TPUs offer superior inference performance.

Sources

- **2026年中国智能算力规模将翻倍，推理算力占比首超50% ...** (relevance: 100%) <https://post.smzdm.com/p/azz2860p> Google TPU v6e、AMD MI300X 与NVIDIA H100/B200的推理成本大比拼：根据Artificial Analysis最新硬件基准测试，NVIDIA在「每百万输入输出token成本」指标上，较TPU
- **【深度万文】10 万卡H100 集群的尽头……** (relevance: 100%) <https://www.eeworld.com.cn/emp/XSY/a382186.aspx> 与2 万卡A100 集群相比，AI 训练算力可提升31.5 倍。资料来源 ... 算力能力的GPU。（译者注：智算中心在建设时，一般会配置一定比例的备用
- **GPU推理，谁最具性价比？ - 财经- 证券之星** (relevance: 100%) <https://finance.stockstar.com/IG2024073000014033.shtml> AMD MI300X 和Nvidia H100 和H200 在这两个比率上大致相同，但Nvidia B100 和B200 的每内存容量和每内存带宽的触发器要多得多，而且由于内存限制，在实际工作
- **H100 vs. H200 vs. B200：为您的AI工作负载选择合适的NVIDIA ...** (relevance: 99%) <https://introl.com/zh/blog/h100-vs-h200-vs-b200-choosing-the-right-nvidia-gpus-for-your-ai-workload> # H100 vs. **H100**：3.35 TB/s（可观）. **H200**：4.8 TB/s（43%改进）.

B200: 8 TB/s (另一个宇宙) . "H200 Tensor Core GPU." NVIDIA Data Center. "DGX B200: The Foundation for Your AI Factory." NVIDIA Data Center. "Choosing GPU Infrastructure for LLM Training in 2025: NVIDIA H100 vs. "NVIDIA H200 vs H100: Better Per...

- **主流算力卡性能对比分析_h100算力** (relevance: 99%) https://blog.csdn.net/m0_69867914/article/details/151579426 算力: FP8稠密算力989 TFLOPS, INT8算力484 TOPS, Tensor FP16稠密算力1979 TFLOPS (含稀疏算力)。显存: 80GB HBM3, 带宽 3.35TB/s, 支持3D堆叠技术。互联技术:

4.数据存储

检索关键词: HBM,显存,存储,NVLink

Answer

MiniMax algorithm optimizes decision-making in competitive scenarios. It's often deployed in Docker for efficient resource management. Recent trends show a shift towards high-speed storage solutions like SSDs to complement GPU performance in AI applications.

Sources

- **新浪GPU热点小时报 | 2026年03月07日14时** (relevance: 66%) <https://cj.sina.com.cn/articles/view/7857201856/1d45362c001902ygb8?from=ggmp> # 新浪看点. # 新浪GPU热点小时报 | 2026年03月07日14时_今日实时GPU热点速递. ## 1、硅谷巨头集体叛逃为哪般? 年轻人该押注GPU还是TPU职业赛道? . ## 1、硅谷巨头集体叛逃为哪般? 年轻人该押注GPU还是TPU职业赛道? . 硅谷巨头集体转向TPU源于成本压力与专用芯片的能效突破, 而年轻人职业选择需根据技术特性和生态趋势动态权衡。硅谷巨头"叛逃"的深层原因成本优势驱动战略转移 谷歌TPU在AI推理任务上比英伟达GPU降低40%-65%成本, 大规模部署下可节省数十亿美元。头部企业如Meta、Anthropic基于经济效益, 已签署百亿级TPU订单或租用协议, 计划2027年...
- **存储的逻辑彻底变天了-36氪** (relevance: 15%) <https://m.36kr.com/p/3652785174700424> # 存储的逻辑彻底变天了. 比如: 西部数据, 股价近期大幅拉升, 三周涨幅超 60%; 跟英伟达算力体系沾边的存储标的, 也全都涨疯了。 . 你去翻下英伟达在 CES 上刚掏出来的最新架构图, 再看一眼 DeepSeek 刚发的那篇惊动圈内的 Engram 论文, **就会发现, 这次涨价的底层逻辑彻底变了。** . 变在哪呢? **存储正从一个装数据的「仓库」, 变成AI 架构里离不了的「外挂大脑」, 它成了 AI 推理时代的「核心生产要素」。** . 这里有个核心痛点, 叫「显存墙」, 你可能听过这个词, 大概意思是: 现在 GPU 算力很猛, 好比请博尔特来搬砖, 结果只给了他一辆小手推车运货。 . 博尔特跑得再快, 90% 时...

4.数据加速

检索关键词: FlashAttention,量化,推理优化

Answer

MiniMax uses FlashAttention for faster inference, and quantization reduces memory and computational costs. vLLM integrates these for efficient reasoning. FlashAttention speeds up attention calculations directly.

Sources

- **MiniMax-M1混合架构与vLLM的结合：长上下文支持与高效推理- 知乎** (relevance: 81%) <https://zhuanlan.zhihu.com/p/1924246503872008841> 量化技术在精度损失最小化的情况下降低了内存和计算开销，而FlashAttention则直接加速了注意力计算，使实际应用中的推理速度显著提升。vLLM中的Lightning
- **LlamaFactory/README_zh.md at main - GitHub** (relevance: 72%) https://github.com/hiyouga/LlamaFactory/blob/main/README_zh.md . * 请见[如何使用](#). [] (https://github.com/hiyouga/LlamaFactory/blob/main/README_zh.md#%E7%9B%AE%E5%...)
- **【LLM技术报告】《MiniMax-01：使用闪电注意力机制扩展基础模型》** (relevance: 70%) <https://zhuanlan.zhihu.com/p/19366579496> 当前闪电注意力机制的实现主要针对训练过程优化。然而，在推理场景中，有效管理包含可变序列长度和特定前缀缓存输入的实际批处理数据成为新的挑战。
- **极智AI | 谈谈为什么量化能加速推理** (relevance: 68%) <https://developer.aliyun.com/article/1399465> 本文深度解析FlashAttention与PagedAttention两大LLM推理优化技术：前者通过分块计算提升注意力效率，后者借助分页管理降低KV Cache内存开销。二者分别从
- **从DeepSeek-V3到MiniMax-M2，现代大模型架构设计全解析_人工智能** (relevance: 63%) <https://adg.csdn.net/694d04e95b9f5f31781ad1cd.html> ... 优化的代码（如FlashAttention）进一步节省推理计算。我推测，滑动窗口注意力虽减少内存使用，但未必降低推理延迟，而Mistral Small 3.1 正专注于此。

4.Agent

检索关键词: 智能体,Agent,AutoGPT

Answer

An AI system built by a team of inventors at Amazon is an advanced AI model designed for various applications. It operates based on sophisticated algorithms and machine learning techniques. It aims to enhance automation and decision-making processes.

Sources

- **一个悄然崛起的Agent，正火爆全球！ 原创 - CSDN博客** (relevance: 83%) <https://blog.csdn.net/c406495762/article/details/148767213> MiniMax Agent：AI智能体开发新时代摘要： MiniMax Agent是一款革命性的 ... **AutoGPT**：一个开源项目，能够通过API创建完整的项目，自主完成
- **MiniMax把自家“实习生”放出来了！ - AI TNT** (relevance: 79%) <https://m.aitntnews.com/newDetail.html?newId=21813> ai/（付费）. 2. 智能体. 【开源免费】AutoGPT是一个允许用户创建和运行智能体的（AI Agents）项目。用户创建的智能体能够自动执行各种任务，从而让AI有
- **碾压ChatGPT Agent！深度测评国产AI智能体神器MiniMax Agent - 知乎** (relevance: 66%) <https://zhuanlan.zhihu.com/p/1932134671539484198> 深度测评国产AI智能体神器MiniMax Agent. 8 个月前 · 来自专栏AI大事件 ... MiniMax Agent 的运行模式跟一些通用Agent 也没啥区别，左边是运行过程
- **Agent(智能体)和MetaGPT，一句话实现整个需求应用代码 - 53AI** (relevance: 65%) <https://www.53ai.com/news/LargeLanguageModel/2024090720645.html> # Agent(智能体)和 MetaGPT，一句话实现整个需求应用代码. 假如我们有一个基于大模型的程序，它能准确地理解我们的需求内涵，然后进一步把需求拆分成小任务，最终组织整个任务的流程和依赖，并执行达成我们的需求目标。那么这个应用就是我们常说的大模型**Agent**（或者叫**智能体**）：大模型 Agent 是基于大语音模型（LLM）之上构建的、具备**环境感知、自主理解、决策制定和执行能力**的智能体。大模型 Agent 能够模拟独立思考过程、调用各类工具，逐步达成我们的需求目标。从我们应用架构设计上讲，大模型 Agent 从原来面向过程的架构（如：儿童绘...
- **2025 AI Agent迷局：谁在玩真的，谁在演戏？ - 虎嗅网** (relevance: 58%) <https://m.huxiu.com/article/3891814.html> # 2025 AI Agent迷局：谁在玩真的，谁在演戏？. 本文来自微信公众号：适道，适道、大象新闻、大象财富、腾讯新闻、腾讯科技联合出品，作者：狮刀、Rika，编辑：郑可君、郝博阳（腾讯科技），题图来自：AI生成. 2023年底，斯坦福大学发布了一款引发轰动的AI实验项目——“小镇模拟游戏”。在这个虚拟小镇里，25个AI角色能够自主交谈、建立关系、制定计划，展现出了令人惊叹的社交能力。这个实验让人们第一次对AI Agent（智能体）产生了期待——**具有自主意识和决策能力的AI助手指日可**

待。一年过去了，AI Agent的概念在业界炙手可热。微软、Google等科技巨头纷纷布局，初创...

五、整体技术趋势判断

5.1 战略方向

基于2026年04月05日的检索结果，MiniMax的AI战略呈现以下特点：

- 1. 技术路线:
- 2. 产品布局:
- 3. 生态建设:

5.2 竞争态势

- vs OpenAI:
- vs Google:
- vs 国内竞品:

5.3 未来展望

预测MiniMax在未来3-6个月可能的技术/产品动向：

- 1.
- 2.
- 3.

六、参考来源

- Tavily Search 检索结果
- 企业官方博客/公告
- 技术媒体（量子位、机器之心等）
- 学术论文（arXiv）

本报告由 OpenClaw AI 系统自动生成

报告版本: v1.0

生成时间: Sun Apr 5 06:02:50 AM CST 2026