

字节跳动 AI技术洞察报告

报告日期: 2026年04月05日

生成时间: 06:00:01

数据来源: Tavily Search, 企业博客, 新闻媒体

洞察范围: 模型发布、技术动态、产品更新

一、公司概况

公司名称: 字节跳动

主要产品: 豆包, Seedance, Seed

检索优先级: 高

二、最新动态检索

2.1 产品/模型发布

Answer

ByteDance released Doubao-Seed-2.0, a major upgrade to its AI model, showcasing enhanced multi-modal capabilities and practical applications in video and image generation. The launch highlights ByteDance's leadership in multi-modal AI technology.

Sources

- **字节大模型，重磅发布！ - 证券时报** (relevance: 82%) <https://www.stcn.com/article/detail/3644236.html> 来源：证券时报网作者：周春媚2026-02-14 15:56. 在这个春节的“群模大战”中，作为“多模态AI王者”的字节跳动，接连惊艳市场。2月14日，字节火山引擎发布豆包大模型2.0（Doubao-Seed-2.0）。据介绍，这是字节跳动最新推出的多模态Agent（智能体）模型，也是豆包大模型自2024年5月正式发布以来首次大版本的跨代升级。豆包大模型2.0具有更稳健的视觉与多模态理解、更可靠的复杂指令执行、更快速更灵活的推理选择三大核心亮点。目前，豆包2.0 Pro和Code模型已分别在豆包App和TRAE上线，同时，豆包2.0全系列模型API已同步上线火山引擎。值得注意的是，在豆...

- **字节大模型，重磅发布！ - 新浪财经** (relevance: 81%) <https://finance.sina.com.cn/wm/2026-02-14/doc-inhmupen2136748.shtml> # 字节大模型，重磅发布！. 在这个春节的“群模大战”中，作为“多模态AI王者”的字节跳动，接连惊艳市场。. 2月14日，字节火山引擎发布豆包大模型2.0 (Doubao-Seed-2.0)。据介绍，这是字节跳动最新推出的多模态 Agent (智能体) 模型，也是豆包大模型自2024年5月正式发布以来首次大版本的跨代升级。豆包大模型2.0具有更稳健的视觉与多模态理解、更可靠的复杂指令执行、更快速更灵活的推理选择三大核心亮点。目前，豆包2.0 Pro和Code模型已分别在豆包App和TRAE上线，同时，豆包2.0全系列模型API已同步上线火山引擎。. 值得注意的是，在豆包2.0正式发布之前，豆包视频生成...
- **字节跳动，AI大模型“三连发” _南方网** (relevance: 79%) https://news.southcn.com/node_810c33d731/8a24d435fd.shtml ## 报纸. ## 杂志. ## 网站. ## 移动端. ## 出版社. ## 党务政务网站. ## 字节跳动，AI大模型“三连发”. 5.0 Lite图像创作模型，最终以2月14日豆包大模型2.0 (Doubao-Seed-2.0) 系列的亮相收官。. 此次三连发不仅展现了字节跳动在多模态AI领域的全链路布局与技术积淀，也显示着我国自主研发大模型正式迈入“实用化攻坚”新阶段，通过技术普惠推动AI从实验室走向千行百业，为数字经济高质量发展注入新动能。. 作为此次发布的核心，豆包大模型2.0是豆包系列自2024年5月正式发布以来的首次跨代大升级，聚焦真实世界复杂任务执行力，针对大规模生产环境需求完成...
- **字节跳动Seed** (relevance: 75%) <https://seed.bytedance.com/zh/> 每秒推理速度 2146 Tokens，扩散语言模型 Seed Diffusion Preview 发布. 每秒推理速度 2146 Tokens，扩散语言模型 Seed Diffusion Preview 发布. 字节跳动 Seed 与比亚迪锂电池深化合作：将成立 AI 联合实验室加速电池研发. 字节跳动 Seed 与比亚迪锂电池深化合作：将成立 AI 联合实验室加速电池研发. 解锁任意模态模型训练，字节跳动 Seed 开源 VeOmni 框架. 解锁任意模态模型训练，字节跳动 Seed 开源 VeOmni 框架. 字节跳动 Seed Prover 取得 IMO 2025 银牌分数. 字节跳动 ...
- **字节又一款AI产品火了！Seedance2.0海内外刷屏哪些行业将被颠覆？** (relevance: 73%) <https://finance.eastmoney.com/a/202602093644966079.html> 指数 期指 期权 个股 板块 排行 新股 基金 港股 美股 期货 外汇 黄金 自选股 自选基金. 资金流向 主力排名 板块资金 个股研报 新股申购 转债申购 北交所申购 AH股比价 年报大全 融资融券 龙虎榜 限售解禁 IPO 审核 大宗交易 估值分析. 根据官方资料，Seedance2.0由字节跳动推出，可根据文本或图像创建电影级视频。它采用双分支扩散变换器架构，可同时生成视频和音频。只需编写详细的提示或上传一张图片，Seedance 2.0 即可在60秒内生成带有原生音频的多镜头序列视频。. 值得一提的是，**这款模型独有的多镜头叙事功能，能够根据单个提示自动生成多个相互关联的场景。** AI...

2.2 技术突破

Answer

ByteDance has made significant investments in AI, launching various large language models and applications. The company aims to lead in AI technology and applications. ByteDance's AI efforts include developing models for natural language processing and image generation.

Sources

- **破局者字节，全栈AI狂飙 - 证券时报** (relevance: 78%) <https://stcn.com/article/detail/3303266.html> 来源：21世纪经济报道作者：雷晨2025-08-29 10:35. 作为行业的后来者，字节跳动的AI棋局日渐清晰：纵向，完成从底层硬件到上层应用的全栈布局，形成成本与体验的“飞轮效应”；横向，以C端超级App流量与B端企业服务双轮驱动，构建一个强大的开放生态。这条路通往何方？字节跳动的答案是：坚定长期投入，“追求智能上限”，服务产业应用。其全栈AI布局正加速渗透千行百业，推动中国数字化进程迈入“AI原生”的新阶段。据华创证券报告显示，字节跳动基于互联网海量数据，积极建设海内外算力中心；同时，基于字节自研DPU的GPU实例，较上一代集群性能最高提升三倍以上。此前有消息称，2025年，...
- **杨震原分享字节跳动技术探索：第一版机器学习系统就定了非常激进 ...** (relevance: 78%) <https://www.jiemian.com/article/13681041.html> ##### 历史搜索 全部删除;. ##### 热门搜索. # 杨震原分享字节跳动技术探索：第一版机器学习系统就定了非常激进的目标. 杨震原表示自己是一个技术爱好者，2014年加入字节跳动之后，从最初负责搭建新的推荐系统开始，到现在已经有快12年了，他也一路参与了字节很多的技术探索。#### **以下为界面新闻整理的分享要点：**. 2014年，工业界最大规模的机器学习系统，是搜索广告中已经成熟使用的大规模离散LR (Logistic regression)。把这套原理用在推荐系统上，挑战可不小。那时同时熟悉大规模软硬件工程和机器学习的人不多，而且，除了能够挣到很多钱的搜索广告会使用；其他领域，...
- **从“科技公司”进化到“创新科技公司” 字节跳动在AI马拉松前500米跑出 ...** (relevance: 74%) https://news.southcn.com/node_810c33d731/4e24533008.shtml ## 报纸. ## 杂志. ## 网站. ## 移动端. ## 出版社. ## 党务政务网站. ## 从“科技公司”进化到“创新科技公司” 字节跳动在AI马拉松前500米跑出加速度. 近年来，全球AI技术的飞跃式发展令人瞩目，其已显著超越了初级阶段的摸索与尝试，正式步入了一个更为成熟、全面的中级发展阶段。在这一阶段，AI技术在实践应用中展现出了前所未有的潜力与价值。近日，火山引擎Force原动力大会在北京正式召开。值得注意的是，这是字节跳动深度探索AI技术领域发展的一场盛宴，集中展示了国内顶尖AI大模型与Agent开发平台等AI云原生服务，广受关注。作为字节跳动强大的创新技术支撑来源，火山...

- 一个算法博士毕业后的六年：**“我在字节跳动做大模型”** (relevance: 71%) <https://seed.bytedance.com/blog/>

我们不用急于让自己的算法模型用在各种产品中，或是每个功能都要做，而是专攻最核心的技术突破点——提高生成模型的音乐性，也就是让大模型生成的歌曲能够达到

三、技术趋势分析

基于检索结果分析字节跳动在以下方面的进展:

3.2 工程化进展

四、关键技术点展开

检索关键词: LLM,大模型,GPT,Claude,Gemini

Answer

I am an AI system built by a team of inventors at Amazon. ByteDance's Doubao-1.5-pro model has shown superior performance compared to GPT-4 and Claude 3.5 Sonnet. It uses sparse MoE architecture for efficient training and inference.

Sources

- **国内外知名大模型及应用——模型/应用维度（2026/04/03）** (relevance: 100%) <https://zhuanlan.zhihu.com/p/670574382> 字节跳动研发的大语言模型应用，2026年2月发布最新通用模型版本为Doubao-Seed-2.0 ... Claude-Opus-4.5 和Gemini 3 Pro 等顶尖模型。并引入自适应工具调用能力
- **字节跳动AI研究员暗示，即将发布比Gemini更强大的开源模型 - Reddit** (relevance: 100%) https://www.reddit.com/r/singularity/comments/18cj8pe/bytedance_ai_researcher_suggests_that_open_source/?tl=zh-hans 大型语言模型(LLM)只是构建具有自主性的人类智能的第一个可用的构建模块。我不认为它们可以独立完成所有事情。LLM 的风险仅在于它们可以帮助自动化
- **字节跳动开源Seed-X 7B多语言翻译模型：28语种全覆盖 - 腾讯云** (relevance: 100%) <https://cloud.tencent.com/developer/article/2543952> 字节跳动开源7B参数多语言翻译模型Seed-X，支持28种语言互译，性能超越GPT-4等大模型。采用Mistral架构，通过强化学习微调优化翻译质量，适用于科技、金融
- **豆包、Claude五大主流AI模型深度对比：技巧、生态与应用全景解析** (relevance: 99%) <https://www.cnblogs.com/ljbguanli/p/19609495> # Gemini、ChatGPT、Qwen、豆包、Claude五大主流AI模型深度对比：技巧、生态与应用全景解析. ## 序：. 中美在金融、科技、军事、贸易、政治等领域的竞争已经进入白热化，我们身处百年未有之大变局之中。美国的全球控制力在下降，美元的霸权在被挑战，美国企图把中国拉入战争，但如今中国的军事实力核战和常规战争都有所忌惮。特朗普政府各种退群，试图摧毁旧秩序，建立一个把中国排除在外的新秩序。无论是明抢委内瑞拉石油，还是芯片法案，关税大棒，好像都不太凑效。而科技领域的竞争尤为重要，从芯片到大模型，到太空领域的星链。我们只有全栈自研突破围剿。才能搭建伟大的中国梦民族复兴。扯得有点大，回归...
- **字节跳动最新豆包大模型，性能超越GPT-4o和Claude 3.5 Sonnet** (relevance: 98%) <https://developer.aliyun.com/article/1650359> # Doubao-1.5-pro：字节跳动最新豆包大模型，性能超越GPT-4o和Claude 3.5 Sonnet. ♥ 如果你也关注 AI 的发展现状，且对 AI 应用开发非常感兴趣，我会每日分享大模型与 AI 领域的最新开源项目和应用，提供运行实例和实用教程，帮助你快速上手AI技术，欢迎关注哦！. # 📖快速阅读. # 正文（附运行示例）. ## 豆包大模型1.5 是什么. Doubao-1.5-pro 是一款基于 MoE 架构的先进预训练模

型，专注于在模型性能和推理性能之间取得极致平衡。通过较少的激活参数，它能够超过一流超大稠密预训练模型的性能，并在多个公开评测基准上取得优异成绩...

4.推理模型

检索关键词: o1,R1,推理,思维链

Answer

字节跳动推出了DeepSeek-R1推理模型，依赖思维链提升推理能力，展示了更高效的推理过程。

Sources

- **中国版的o1来了！DeepSeek-R1-Lite媲美o1-preview，还原完整COT ...** (relevance: 100%) <https://developer.volcengine.com/articles/7441466492882944037> 红色实线展示了模型所能达到的准确率与所给定的推理长度呈正相关；. 相比传统的多次采样+投票（Majority Voting），模型思维链长度增加展现出了更高的效率。
- **字节豆包推理模型Seed-Thinking-v1.5要来了 - DeepSeek技术社区** (relevance: 100%) <https://deepseek.csdn.net/67f9c93be47cbf761b58751f.html> 推理模型主要依赖思维链（CoT）数据，这种数据展示逐步推理过程。该团队的初步研究表明，过多非思维链数据会削弱模型探索能力。研究团队在强化学习
- **DeepSeek-R1：突破推理能力的满血开源O1 - 知乎专栏** (relevance: 100%) <https://zhuanlan.zhihu.com/p/19878591772> 这一创新与近期OpenAI提出的RFT以及字节跳动的ReFT有异曲同工之妙。这些方法都指出，SFT可能存在搜索空间不足的局限性，而强化学习则可以探索更多的
- **142页长文揭秘DeepSeek-R1「思维大脑」！开启全新「思维链学 ...** (relevance: 100%) <https://hub.baai.ac.cn/view/45121> DeepSeek-R1是一款突破传统LLM局限的推理模型，开启了「思维链学」（Thoughtology）研究方向。一份142页的报告详细解析了其推理过程，展示了DeepSeek-R1
- **Science4AI? | 当长链推理遇上分子结构，字节跳动从零合成CoT 思维链** (relevance: 100%) <https://cloud.tencent.com/developer/article/2622135> 思维链（Chain-of-Thought, CoT）通过引导模型生成一系列中间推理步骤，显著提升了其在算术、常识和符号推理等任务上的能力。然而，当模型需要处理包含数十

4.多模态模型

检索关键词: 多模态,视觉,视频生成,Sora,Seedance

Answer

ByteDance's Seedance 2.0 is a leading AI model for multi-modal video generation, excelling in complex motion and scene generation. It supports text, image, audio, and video inputs for realistic, director-level video creation. Seedance 2.0 has industry-leading video and audio synchronization capabilities.

Sources

- **Seed Models - ByteDance Seed** (relevance: 100%) <https://seed.bytedance.com/zh/models> Seedance 2.0. Seedance 2.0. 采用统一的多模态音视频联合生成架构，支持文字、图片、音频、视频四种模态输入，集成了目前业界最全面的多模态内容参考和编辑能力 · Seedance
- **Seedance 2.0 - ByteDance Seed** (relevance: 100%) https://seed.bytedance.com/zh/seedance2_0 # Seedance 2.0. Seedance 2.0 采用统一的多模态音视频联合生成架构，支持文字、图片、音频、视频四种模态输入，集成了目前业界最全面的多模态内容参考和编辑能力。 . # 极致拟真的视听体验. # 所想即所见的导演级操控. 支持音、视、图全模态参考输入，打破素材边界，赋予创作者对表演、光影、运镜的调度权，超强的可控性让创意转化为画面，真正实现“像导演一样生成”。 . # 影视工业链路赋能. 深度适配广告、影视与社媒营销场景，输出质量对齐工业交付标准，大幅度降低特效制作与实拍成本，为行业带来显著的效率提升. # 模型表现. 以下是 Seedance 2.0 在内部基准测试 See...
- **Seedance：字节跳动的AI视频生成技术突破与行业变革 - 新浪财经** (relevance: 100%) <https://finance.sina.com.cn/stock/roll/2026-02-13/doc-inhmrnzk2295391.shtml> Seedance是字节跳动旗下Seed团队研发的多模态AI视频生成平台，是当前全球领先的AI视频生成技术之一。其核心定位是通过扩散模型（Diffusion Model
- **Seedance 2.0 vs. Sora 2 vs. Kling 3.0：2026年终极AI 视频API 对比 ...** (relevance: 100%) <https://www.atlascloud.ai/zh/blog/guides/seedance-2-vs-sora-2-vs-kling-3-comparison> 哪款AI 视频模型最出色？我们从功能、价格以及如何通过Atlas Cloud 进行API 访问等方面，对比了字节跳动的Seedance 2.0、OpenAI 的Sora 2.0 和快手的可
- **Seedance 2.0 正式发布 - ByteDance Seed** (relevance: 100%) <https://seed.bytedance.com/zh/blog/seedance-2-0-%E6%AD%A3%E5%BC%8F%E5%8F%91%E5%B8%83> # Seedance 2.0 正式发布. 目前，Seedance 2.0 已上线即梦AI、豆包等平台，欢迎体验和反馈。 . https://seed.bytedance.com/seedance2_0. 1) 即梦网页端-视频生成-选择 Seedance 2.0; . 2) 豆包 App 对话框-Seedance2.0-选择 2.0 模型; . 3) 火山方舟体验中心-选择 Doubao-Seedance-2.0。 . #### 拟真视听效果和导演级操控. #### 让音视频生成“所想即所见”. 能完

成前代模型难以实现的多人竞技运动生成，音频效果更加自然沉浸，输入也不再局限于单一的文字或图片， ...

4.算力卡

检索关键词: GPU,H100,B200,TPU,算力

Answer

ByteDance uses H100 and B200 GPUs for AI applications. H100 offers high performance, while B200 provides significant computational power. These GPUs support large-scale AI model training and inference.

Sources

- **[PDF] AI系列专题报告（一） - 算力** (relevance: 73%) https://pdf.dfcfw.com/pdf/H3_AP202506121689781660_1.pdf AI系列专题报告（一） 算力：算力基建景气度高，国产AI芯片发展势头良好 证券研究报告 分析师： 陈福栋S1060523070003（证券投资咨询） 分析师： 闫磊 S1060519100002（证券投资咨询） 平安证券研究所电子信息团队 2025年6月12日 请务必阅读正文后免责条款 电子行业强于大市（维持） 核心摘要 ☑AIGC蓬勃发展，对底层智能算力产生强劲需求。行业前期，训练是算力需求的主力，大量大模型训练需要海量算力支撑。2024年末，DeepSeek重磅发布，其轻量化、低成本、高性能特征大幅拉低了AI应用门槛，有望成为各类推理场景爆发的契机，推理算力市场需求潜力巨大。在此背景下...
- **兆規模起飛！“平替”輝達Blackwell架構GPU！智能算力TPU產業鏈 ...** (relevance: 62%) <https://hao.cnyes.com/post/212327> 核心硬體：GPU叢集規模化部署，H100/H200成為絕對主力，算力規模躍升至1-10 EFlops（每秒百億億次）。技術特徵：InfiniBand
- **一文读懂英伟达四大旗舰显卡差异：H100/H200/B200/B300 - 知乎专栏** (relevance: 56%) <https://zhuanlan.zhihu.com/p/1984367989412344349> 简单来说，H100和H200属于上一代Hopper架构，而B200和B300则是新一代Blackwell架构的产物，其中B300更是搭载了Blackwell Ultra架构是目前算力天花板。架构的
- **一文搞懂英伟达AI芯片A100 A800 H100 H800 B200详解 - 潇湘君** (relevance: 53%) <https://www.xiaoxiangjun.com/index.php/1275/.html> Blackwell有两个Die，那么单Die显卡的SM数也达到了H100的2倍。可以说，每一代架构的升级，单个GPU算力实现数倍增长。... 字节跳动等企业也采取了类似措施。
- **英伟达B200和H100在性能上存在诸多差异，以下是详细对比：计算 ...** (relevance: 52%) <https://www.instagram.com/p/DG99DpizYN7/> 英伟达B200和H100在性能上存在诸多差

异，以下是详细对比： 计算能力 · B200：单GPU可提供20petaflops的FP4算力，AI性能达每秒20千万亿次浮点运算。

4.数据存储

检索关键词: HBM,显存,存储,NVLink

Answer

ByteDance utilizes HBM, NVLink, and DPU for high-speed data storage and AI network infrastructure. NVLink enables high-bandwidth, low-latency connections between GPUs. DPU integrates high-speed IO for efficient data handling in AI systems.

Sources

- **DPU构建新一代AI网络的优势与关键技术_ 信息化动态** (relevance: 77%) https://xxzx.fj.gov.cn/jjxx/xxhdt/202510/t20251013_7020423.htm 来源：通信世界网 时间：2025-10-13 09:10. 微信; "分享到微信") 微博; "分享到新浪微博") QQ空间; "分享到QQ空间"). 当前，我们正处于两个“ScalingLaw”激烈碰撞的时代。一个是摩尔定律的 ScalingLaw，就是摩尔定律，大家的看到的共识就是摩尔定律从2015年开始就已经显著放缓了，也就意味着单位芯片面积上能提供的性能增量变得越来越小。但是我们感受到，芯片的性能还是在快速上升的，最主要的原因必然就是单颗芯片的面积变得越来越大。 . 与此同时，我们看到了另外一个ScalingLaw，大模型的ScalingLaw，为把芯片做大，把算力做高提供了直接动机。 ...
- **【原创】传昇腾950PR获字节和阿里巴巴大单!销售预计过500亿!** (relevance: 64%) <https://www.eetrend.com/content/2026/100599853.html> # 【原创】传昇腾950PR获字节和阿里巴巴大单! 据外媒报道，据两位知情人士透露（作者注：未经产业核实，请慎重对待此消息）华为昇腾950PR在中国客户测试进展顺利，包括字节跳动和阿里巴巴在内的多家科技巨头计划下单。 . 这一进展对华为而言具有里程碑意义，对中国AI市场也具有重要里程碑意义。据透露，本土互联网大厂此次计划更广泛地使用新款 950PR 芯片，因为该芯片与英伟达 CUDA 软件系统的兼容性更强，响应速度也更快，这让他们更加满意。 . 据透露，华为计划今年出货约 75 万颗 950PR 芯片，采用传统DDR显存的950PR显卡售价约为每张5万元人民币（约合6900美元），而配备速度更快的...
- **传昇腾950PR获字节和阿里巴巴大单!销售预计过500亿! - 新浪财经** (relevance: 63%) <https://finance.sina.com.cn/roll/2026-03-30/doc-inhstpih6542645.shtml> # 传昇腾950PR获字节和阿里巴巴大单! 据外媒报道，据两位知情人士透露（作者注：未经产业核实，请慎重对待此消息）华为昇腾950PR在中国客户测试进展顺利，包括字节跳动和阿里巴巴在内的多家科技巨头计划下单。 . 这一进展对华为而言具有里程碑意义，对中国AI市场也具有重要里程碑意义。据透露，本土互联网大厂此次计划更广泛地使用新款 950PR 芯片，

因为该芯片与英伟达 CUDA 软件系统的兼容性更强，响应速度也更快，这让他们更加满意。据透露，华为计划今年出货约 75 万颗 950PR 芯片，采用传统DDR显存的950PR显卡售价约为每张5万元人民币（约合6900美元），而配备速度更快的HBM显...

- **05.大模型推理与AI Infra(DONE) - GitHub** (relevance: 63%) <https://github.com/Infrasys-AI/AllInfra/blob/main/00Summary/05InferStack.md> [Skip to content](#). [Reload](#) to refresh your session.You signed out in another tab or window. [Reload](https://github.com/Infrasys-A...
- **超节点算力革命(六) | 全球主流厂商超节点技术方案** (relevance: 50%) <https://www.comentropy.org/2026/post/27233> NVL72采用NVLink-C2C（Chip-to-Chip）技术，实现GPU HBM与Grace CPU LPDDR的统一内存寻址。整机柜配置：HBM高带宽内存 13.5TB总容量

4.数据加速

检索关键词: FlashAttention,量化,推理优化

Answer

FlashAttention optimizes attention mechanisms for faster, more memory-efficient large model training. It uses hardware-aware algorithms to reduce memory access and improve GPU utilization. It's part of ByteDance's efforts to enhance AI model inference speed.

Sources

- **端侧AI Infra开发实习生-音视频技术 - 字节跳动招聘官网** (relevance: 100%) <https://jobs.bytedance.com/campus/m/position/detail/7594472672476760325?recomId=5a64c401-1efc-11f1-b8f3-043f72a6392c&sourceJobId=7532098404223666450> 1、负责模型推理全流程优化，低比特量化（AWQ、GPTQ、SpinQuant等）、模型剪枝、蒸馏等模型压缩技术，以及FlashAttention、KVCache高效管理、投机推理等推理优化手段
- **FlashAttention 系列技术详解：加速大模型训练的利器** (relevance: 100%) <https://developer.volcengine.com/articles/7444834108175286298> # FlashAttention 系列技术详解：加速大模型训练的利器. ## FlashAttention 的解决方案. 为了解决上述问题，**FlashAttention** 提出了一种 **快速、节省内存、精确的注意力计算方法**，通过减少内存读写次数，提高 GPU 的内存 IO 效率，加快训练速度，并增加上下文窗口长度。其核心目标是通过 **硬件感知（IO-awareness）** 的算法优化，将整个注意力计算过程在更高速的 **SRAM**（静态随机存取存储器）中完成，减少对 HBM（高带宽内存）的依赖。在传统的注意力机制中，首先需要将输入矩阵从 HBM 中读取，随后计算注意...

- **大厂大模型算法岗推理类面试题总结 - 牛客网** (relevance: 98%) <https://www.nowcoder.com/feed/main/detail/9b1bb8d0d8aa4e5fa76df95750bf7122> 1. 因模型推理优化方面. KV Cache、PagedAttention、FlashAttention 等技术, 提升吞吐和显存利用率。 2. 高频考点 vLLM 与 PagedAttention. KV Cache 原理与优化推理加速
- **字节高性能Transformer推理库获IPDPS 2023最佳论文奖** (relevance: 83%) <https://developer.aliyun.com/article/1262677> 为了解决这个问题, 字节跳动AML 团队提出了ByteTransformer, 它实现了变长输入的padding free 计算, 并且实现了全面的kernel fusion 以进一步提高性能。
- **SGLang发布迷你版: 5千行代码实现LLM推理核心, 性能媲美完整版** (relevance: 46%) <https://www.itsovertime.com/archives/13965> # SGLang发布迷你版: 5千行代码实现LLM推理核心, 性能媲美完整版. SGLang团队近日发布了mini-SGLang, 将原本30万行的代码库精简至仅5000行。该版本完整保留了核心优化技术, 包括重叠调度、FlashAttention-3、基数缓存等, 在在线服务场景下的性能表现与完整版几乎无异。针对用户关于是否支持GGUF格式服务的询问, 开发团队明确表示, 该版本主要面向教学与实验目的, 不建议用于生产环境或需要完整后端扩展的场景。对于GGUF等生产级需求, 建议使用完整的SGLang。mini-SGLang是目前唯一同时支持在线/离线服务、流式传输和重叠调度的最小化推理项目。有开发者...

4.Agent

检索关键词: 智能体,Agent,AutoGPT

Answer

I am an AI system built by a team of inventors at Amazon. I provide information based on my training data. I do not identify as any specific model name.

Sources

- **DeerFlow 2.0: 字节跳动开源的”超级智能体” - 知乎专栏** (relevance: 66%) <https://zhuanlan.zhihu.com/p/2021122968340764270> 关键的设计哲学是上下文隔离——子智能体看不到主Agent 和其他子智能体的上下文。... 与AutoGPT 对比: AutoGPT 拥有约18.3万Star 的最大社区, 但其
- **除了Manus, 还有哪些好用的AI Agent智能体工具?** (relevance: 66%) <https://xie.infoq.cn/article/65716e2667a7a95ca7f80f2a7> AutoGPT 是早期引爆AI Agent 概念的开源项目之一, 它展示了让GPT-4 等大型语言模型实现完全自主任务执行的巨大潜力。作为一个开源框架, 它吸引了大量的开发

- **[PDF] 2025 Agent元年，AI从L2向L3发展** (relevance: 63%) https://pdf.dfcfw.com/pdf/H3_AP202505041667413598_1.pdf?1746459426000.pdf 风险提示：技术成熟度风险，高成本风险，商业模式不确定性风险，竞争加剧风险。 2 目录 一、为什么说 2025 年是 Agent 元年？ AI 从 L2 向 L3 进化 驱动力：技术成熟度达到临界点；行业领导者推动，标杆产品验证；市场需求驱动 定义：不是所有的 AI 模型/产品都叫 Agent；Agent 的四个必要构成（缺一不可）；Agent 的智能程度是有层次和梯度的 二、Agent 为何重要？ 深度自动化、指数级效率提升、解放人类生产力与创造力 通往 AGI 和具身智能的关键环节 重塑互联网流量入口格局 预计入口级 Agent 大战将于 25H2 开启 三、竞争格局：模型即产品，通用...
- **AI 工具推荐之Agent TARS：字节跳动开源的多模态AI智能体 - 腾讯云** (relevance: 47%) <https://cloud.tencent.com/developer/article/2513173> Agent TARS是字节跳动开发的一款多模态AI智能体，其核心技术基于UI-TARS模型。UI-TARS是一个原生的GUI代理模型，利用视觉语言模型（Vision-Language Model,
- **《扣子从入门到精通》：了解字节跳动的AI Agent - CSDN博客** (relevance: 46%) <https://blog.csdn.net/igwork/article/details/147674561> # 《扣子从入门到精通》：了解字节跳动的AI Agent. ### 一、引言：AI Agent 赛道风起云涌. 近来，AI Agent 概念异常火爆。自从 Manus 这类产品意外走红后，各大科技巨头纷纷将目光投向了这个充满潜力的新赛道。百度推出了「心想 APP」，而字节跳动也低调上线了其 AI Agent 产品——「扣子空间」（Coze Space）。. Manus 的成功，与其说是技术上的绝对壁垒，不如说是其巧妙的产品设计点燃了市场热情。这也引发了一个行业趋势：将强大的大语言模型（LLM）能力，通过 Agent 的形式封装成能够自主规划、执行复杂任务的智能应用。本文旨在为 CSDN ...

五、整体技术趋势判断

5.1 战略方向

基于2026年04月05日的检索结果，字节跳动的AI战略呈现以下特点：

1. 技术路线:
2. 产品布局:
3. 生态建设:

5.2 竞争态势

- vs OpenAI:
- vs Google:
- vs 国内竞品:

5.3 未来展望

预测字节跳动在未来3-6个月可能的技术/产品动向：

- 1.
- 2.
- 3.

六、参考来源

- Tavily Search 检索结果
- 企业官方博客/公告
- 技术媒体（量子位、机器之心等）
- 学术论文（arXiv）

本报告由 OpenClaw AI 系统自动生成

报告版本: v1.0

生成时间: Sun Apr 5 06:00:24 AM CST 2026