

智谱AI AI技术洞察报告

报告日期: 2026年04月05日

生成时间: 06:01:07

数据来源: Tavily Search, 企业博客, 新闻媒体

洞察范围: 模型发布、技术动态、产品更新

一、公司概况

公司名称: 智谱AI

主要产品: GLM, ChatGLM

检索优先级: 高

二、最新动态检索

2.1 产品/模型发布

Answer

ZhipuAI released its latest GLM-5 model, aiming to compete with Anthropic's Opus series. The company also opened its GLM models under MIT license and launched Z.ai for global access. ZhipuAI's GLM-Z1 model offers eight times faster inference speed than DeepSeek-R1.

Sources

- 智譜勢將發布新一代AI模型加快步伐與DeepSeek展開競爭 - Yahoo 財經 (relevance: 100%) <https://hk.finance.yahoo.com/news/%E6%99%BA%E8%AD%9C%E5%8B%A2%E5%B0%87%E7%99%BC%E5%B8%83%E6%96%B0-%E4%BB%A3ai%E6%A8%A1%E5%9E%8B-%E5%8A%A0%E5%BF%AB%E6%AD%A5%E4%BC%90%E8%88%87deepseek%E5%B1%95%E9%9>
智譜在周三發布的聲明中稱，其最新一代大語言模型名為GLM-5，旨在處理複雜的編程和智能體任務，並已與Anthropic的Claude Opus系列進行直接對標測試。智譜表示
- 智谱.AI ZhipuAI - 组织详情 (relevance: 100%) <https://modelscope.cn/organization/ZhipuAI> 智谱AI由清华大学计算机系的技术成果转化而来。公司主导研发了多语言千亿级超

大规模预 ... 已发布. GLM系列模型, 包括预训练模型, 对话模型, 多模态模型以及代码生成模型.

- **GLM Coding Plan - 智谱AI** (relevance: 100%) https://bigmodel.cn/special_area 智谱最新视觉推理模型, 视觉理解精度达同规模SOTA, 全面支持工具调用, 支持128K 超长上下文, 并针对Coding 场景进行了专项优化. 规格5亿tokens. 有效期4个月. 模型优势
- **智谱开源9B/32B 系列模型, 上线Z.ai - 知乎专栏** (relevance: 100%) <https://zhuanlan.zhihu.com/p/1895449861966505786> 智谱将开源32B/9B 系列GLM 模型, 涵盖基座、推理、沉思模型, 均遵循MIT 许可协议. 该系列模型现已通过全新平台Z.ai免费开放体验, 并已同步上线智谱MaaS
- **智谱AI开源GLM模型: 8倍加速推理与全球布局 - 腾讯云** (relevance: 100%) <https://cloud.tencent.com/developer/article/2647436> ## 智谱AI开源GLM模型: 8倍加速推理与全球布局. # 智谱AI开源GLM模型: 8倍加速推理与全球布局. 中国北京 - 2025年4月15日 - 作为一项彰显其技术实力和全球雄心的战略举措, 并为潜在的未来IPO铺平道路, 中国人工智能公司智谱AI宣布全面开源其下一代通用语言模型 (GLM). 此次发布包括先进的GLM-4系列和突破性的GLM-Z1推理模型, 这些模型拥有前所未有的推理速度, 并推出了专用的国际域名Z.ai. . 其中亮点是GLM-Z1推理模型, 据称其推理速度比DeepSeek-R1快八倍. 通过优化GQA参数、采用量化技术和推测采样, GLM-Z1-32B-0414模型在消费级GPU上实现...

2.2 技术突破

Answer

智谱AI技术突破在大模型参数效率和多能力融合方面, 推出了高效的GLM-4.5模型, 实现了快速推理和代码生成. 智谱AI通过开源其模型, 展示了技术领先和全球影响力.

Sources

- **智谱冲破2000亿的秘密: 为什么中国AI终于敢涨价了? - DoNews** (relevance: 100%) <https://www.donews.com/article/detail/5458/97228.html> 当OpenAI还在为免费用户的广告位发愁, Anthropic还在和奥特曼打口水战, 智谱已经在国产算力底座上跑通了从技术突破到商业变现的完整闭环. 智谱的股价
- **智谱AI: 源自清华、创新成就200亿估值的AI领航者** (relevance: 100%) <https://zhuanlan.zhihu.com/p/710805313> 训练出的百亿参数模型GLM-10B和1300亿参数的超大规模模型GLM-130B, 不仅在技术上取得了突破, 更在国际上赢得了认可. 特别是开源模型ChatGLM-6B到最新的GLM-

- **赛道Hyper | 智谱GLM-4.5：技术突破成因与行业价值 - 华尔街见闻** (relevance: 100%)
<https://wallstreetcn.com/articles/3752410> # 赛道Hyper | 智谱GLM-4.5：技术突破成因与行业价值. 7月28日，智谱AI发布旗舰模型GLM-4.5并开源。GLM-4.5是一款专为智能体应用研发的基础模型，在性能、成本控制与多能力融合等方面均有出色表现。智谱AI核心团队主要来自清华大学KEG（知识工程）实验室：董事长刘德兵、CEO张鹏和总裁王绍兰均为KEG实验室核心成员，张鹏和王绍兰同为清华创新领军工程博士，首席科学家唐杰曾任清华大学计算机系教授。早期（2021年）GLM模型（10B）就已探索了Transformer架构的优化，2022年推出参数规模达130B的GLM-130B，2023年推出的GLM-3尝试了混合专...
- **国产大模型登顶全球榜，凌云光接入智谱GLM-4.5加速AI应用新突破** (relevance: 100%)
<https://xueqiu.com/9587409166/346035966> GLM-4.5 是智谱专为智能体应用打造的基础模型，首次在单个模型中实现将推理、编码和智能体能力原生融合的技术突破，综合测试性能已跻身全球领先行列，在涵盖MMLU Pro
- **智谱AI开源GLM模型：8倍加速推理与全球布局 - 腾讯云** (relevance: 100%) <https://cloud.tencent.com/developer/article/2647436> ## 智谱AI开源GLM模型：8倍加速推理与全球布局. # 智谱AI开源GLM模型：8倍加速推理与全球布局. 中国北京 - 2025年4月15日 - 作为一项彰显其技术实力和全球雄心的战略举措，并为潜在的未来IPO铺平道路，中国人工智能公司智谱AI宣布全面开源其下一代通用语言模型（GLM）。此次发布包括先进的GLM-4系列和突破性的GLM-Z1推理模型，这些模型拥有前所未有的推理速度，并推出了专用的国际域名Z.ai。其中亮点是GLM-Z1推理模型，据称其推理速度比DeepSeek-R1快八倍。通过优化GQA参数、采用量化技术和推测采样，GLM-Z1-32B-0414模型在消费级GPU上实现...

三、技术趋势分析

3.1 模型能力演进

基于检索结果分析智谱AI在以下方面的进展：

- **大语言模型**: 上下文长度、推理能力、多语言支持
- **多模态能力**: 图像理解、视频生成、跨模态交互
- **推理优化**: 思维链、深度推理、数学/代码能力

3.2 工程化进展

- **训练基础设施**: 算力规模、训练效率、成本控制
 - **推理优化**: 量化技术、KV Cache优化、批处理策略
 - **部署方案**: 云端API、边缘部署、私有化方案
-

四、关键技术点展开

4.大语言模型

检索关键词: LLM,大模型,GPT,Claude,Gemini

Answer

智谱AI的GLM-5.1模型在性能和成本上接近顶尖的Claude Opus 4.6和GPT-5.2。Gemini和Claude也是知名的大型语言模型。

Sources

- **GLM-5.1 与Claude、GPT - 智谱AI新模型表现如何？ - CSDN博客** (relevance: 68%) <https://blog.csdn.net/Joshkhh/article/details/159787524> 资源文件中包括了编程语言模型如GPT-Chat、Dify、Claude、Gemini、Ollama、GLM、xAI以及LLM，显示出这个聊天机器人可能会使用当前流行的多种语言模型来理解
- **GLM-5.1 vs Claude、GPT、Gemini、DeepSeek：智谱AI最新模型的 ...** (relevance: 65%) <https://wavespeed.ai/blog/zh-tw/posts/glm-5-1-vs-claude-gpt-gemini-deepseek-llm-comparison/> # GLM-5.1 vs Claude、GPT、Gemini、DeepSeek：智谱AI最新模型的實力評測. 智谱AI於2026年3月27日正式發布 **GLM-5.1**，其亮眼數據引發廣泛關注。這家中國AI實驗室於今年1月以313億美元估值在香港聯交所掛牌上市，聲稱其最新模型的程式設計能力達到 **Claude Opus 4.6**的**94.6%**，且採用開放權重，並完全在非Nvidia硬體上完成訓練。 . ## GLM-5.1 是什麼？ . * 達到 **Claude Opus 4.6**程式設計分數的**94.6%** (45.3 vs 47.9) . | **Claude Opus 4.6** (Anth...
- **大型語言模型列表- 維基百科，自由的百科全書** (relevance: 57%) <https://zh.wikipedia.org/zh-tw/%E5%A4%A7%E5%9E%8B%E8%AF%AD%E8%A8%80%E6%A8%A1%E5%9E%8B%E5%88%97%E8> 大型語言模型（LLM）是一種機器學習模型，專為語言生成等自然語言處理任務而設計。LLM 是具有許多參數的語言模型，並通過對大量文本進行自監督學習進行訓練。
- **国内外知名大模型及应用——模型/应用维度（2026/04/03）** (relevance: 53%) <https://zhuanlan.zhihu.com/p/670574382> Gemini目前模型性能综合实力最强，结合搜索业务的Deep Research是行业标杆。 Claude: <https://claude.ai/>. Anthropic研发的大模型。2026年2月发布Opus
- **智谱ZCode上手：把Claude和Gemini装进桌面，编程还能这么玩？** (relevance: 45%) <https://www.51cto.com/aigc/9685.html> 以前我们用AI工具，往往被绑定在某一家厂商的

模型上。但在ZCode里，智谱做了一个很大胆的决定：它允许你集成Claude Code、Codex、Gemini这些市面上最顶级

4.推理模型

检索关键词: o1,R1,推理,思维链

Answer

The o1 model by OpenAI set a benchmark for reasoning capabilities, and DeepSeek-R1 by Chinese AI firm DeepSeek matched its performance. DeepSeek-R1 emphasizes multi-disciplinary reasoning and open-source collaboration. It uses advanced training techniques and model architectures to achieve its results.

Sources

- **RBench公布最新大模型推理能力排行榜，GPT-5以微弱优势排名第一** (relevance: 80%)
<https://cg.cs.tsinghua.edu.cn/jittor/news/2025-09-02-18-22-00-00-RBench/> # RBench公布最新大模型推理能力排行榜，GPT-5以微弱优势排名第一. ## RBench公布最新大模型推理能力排行榜，GPT-5以微弱优势排名第一. 大模型的智能正在进入一个新的衡量维度：推理。与单纯的知识记忆和复述不同，真正的智能体现在应对复杂问题时能否进行缜密的分析、严谨的推导和明智的决策——这正是推理能力的核心，也是模型在数学、编程、科学问答等高级任务中展现类人思维的关键。. 过去一年，整个行业见证了推理能力的“寒武纪大爆发”。这股浪潮由OpenAI在2024年9月推出的o1模型点燃，并迅速席卷全球。仅仅数月后，2025年1月，DeepSeek R1的横空出世，让开源大模型第一次...
- **类o1系列模型大盘点：QwQ、Deepseek-R1、Marco-o1、Huatu-o1** (relevance: 70%)
<https://deepseek.csdn.net/67ab1e2879aaf67875cb9ab6.html> 模型会尝试不同的解决方案，并根据结果调整其推理路径。生成思路链：在推理过程中，模型会生成一个内部的思路链，记录每一步的推理过程和结果。这个思路链
- **国产AI 最卷一夜！大模型黑马DeepSeek、Kimi 硬刚OpenAI o1 - 爱范儿** (relevance: 68%)
<https://www.ifanr.com/1612733> 前脚 DeepSeek-R1 正式发布，号称性能对标 OpenAI o1 正式版，后脚 k1.5 新模型也正式登场，表示性能做到满血版多模态 o1 水平。. 如果再加上此前强势登场的智谱 GLM-Zero，阶跃星辰推理模型 Step R-mini，星火深度推理模型 X1，年末上大分的国产大模型拉开了真刀真枪的帷幕，也给以 OpenAI 为代表的海外模型狠狠上了一波压力。.* DeepSeek-R1：在数学、代码、自然语言推理等任务上，性能比肩 OpenAI o1 正式版. 昨晚率先发布的 DeepSeek-R1 现在已经上架 DeepSeek 官网与 App，打开就能用。. 面对弱智吧难题...

- **从o1到DeepSeek-R1，万字长文带您揭秘推理模型——及其与标准 ...** (relevance: 66%) <https://zhuanlan.zhihu.com/p/26076930125> 推理模型与标准LLM的主要区别在于能够在回答问题之前“思考”。推理模型的思维只是由LLM输出的长链思维——简称长CoT，有时称为推理轨迹或路径。长CoT的
- **智能体式思考，AI大模型的旦用难回** (relevance: 65%) <https://finance.sina.cn/stock/jdts/2026-03-31/detail-inhswxzv9097129.d.html?vt=4> OpenClaw（龙虾）带来的「飓风」还在继续刮，而且看起来更是一场 AI 的范式转移。· 上周五举办的 2026 中关村论坛人工智能主题日上，月之暗面创始人杨植、智谱 AI CEO 张鹏、无问芯穹 CEO 夏立雪、小米;) MiMo 大模型负责人罗福莉、香港大学 nanobot 负责人黄超教授，共同参与了一场聚焦「OpenClaw 与 AI 开源」的圆桌对话。· 这里就不介绍对话详情，只提一点就是：Harness 和 Skill 在影响 Agent 框架的方向，Agent 框架也在影响大模型的方向。说简单点，他们都认为接下来大模型要更加适应 Agent 的进化方向。· 事实上就在前一天，一度...

4.多模态模型

检索关键词: 多模态,视觉,视频生成,Sora,Seedance

Answer

Seedance 2.0 is a multi-modal AI model by ByteDance for generating high-quality, synchronized audio-visual content, and it has been compared to industry-leading models like Sora and Veo 3.1. It focuses on creating director-level video sequences with integrated audio.

Sources

- **Seedance2.0春晚出圈，AI视频应用浮现哪些风口？ - 财联社** (relevance: 65%) <https://www.cls.cn/detail/2291704> ## 首页## 电报## 话题## 盯盘## VIP## FM## 投研## 下载. ### 头条. ### A股. ### 港股. ### 环球. ### 公司. ### 券商. ### 基金 • ETF. ### 地产. ### 金融. ### 汽车. ### 科创. ### 品见. 2026-02-19 10:59 星期四. ①Seedance 2.0大模型在春晚完成首秀，深度参与《贺花神》、《驭风歌》、《快乐小马》等节目视觉定制；②随着大模型“春节档”的密集亮相，AI产业链正迎来强力催化，多家机构建议关注AI漫剧与AI短剧；③中美AI视频大模型竞争白热化，国产力量加速追赶，性价比优势显...
- **【Seedance 2.0 技术解析】：字节跳动电影级多模态视频生成模型 ...** (relevance: 58%) <https://developer.aliyun.com/article/1724018> 简介：字节跳动于2026年2月发布 Seedance 2.0，登顶AI视频生成Elo榜（1269分）。其首创双分支扩散Transformer（DB-DiT），实现原生音画同步、60秒2K视频、8+

- **Seedance 2.0 正式发布 - ByteDance Seed** (relevance: 58%) <https://seed.bytedance.com/zh/blog/seedance-2-0-%E6%AD%A3%E5%BC%8F%E5%8F%91%E5%B8%83> # Seedance 2.0 正式发布. 目前, Seedance 2.0 已上线即梦AI、豆包等平台, 欢迎体验和反馈。 . https://seed.bytedance.com/seedance2_0. 1) 即梦网页端-视频生成-选择 Seedance 2.0; . 2) 豆包 App 对话框-Seedance2.0-选择 2.0 模型; . 3) 火山方舟体验中心-选择 Doubao-Seedance-2.0。 . ### 拟真视听效果和导演级操控. ### 让音视频生成“所想即所见”. 能完成前代模型难以实现的多人竞技运动生成, 音频效果更加自然沉浸, 输入也不再局限于单一的文字或图片, ...
- **国产模型悄无声息地赢得了一场多模态战役 - 新浪财经** (relevance: 57%) <https://cj.sina.cn/articles/view/8019266654/1ddfc4c5e00101mchy?from=ggmp&vt=4> Seedance 2.0凭借它的强大能力, 已经被人们视为未来制作电影的“神器”, 而它现在唯一存在的尴尬之处, 就在于缺少配音。 音频生成看起来比视频生成要简单, 但给
- **字節推Seedance 2.0影片生成60秒達導演級水準 - Yahoo 財經** (relevance: 51%) <https://hk.finance.yahoo.com/news/%E5%AD%97%E7%AF%80%E6%8E%A8seedance-2-0%E5%BD%B1%E7%89%87%E7%94%9F%E6> OpenAI的影片生成應用程式Sora側重於物理真實感, Kling側重於運動控制, 而Seedance 2.0則專注於製作具有原生音訊連貫多場景序列。 開源證券表示, Seedance2.0

4.算力卡

检索关键词: GPU,H100,B200,TPU,算力

Answer

H100, H200, and B200 are high-performance GPUs from NVLink series, with B200 offering the highest bandwidth and computational power for large-scale AI tasks. B200 provides significant improvements in efficiency and performance over H100 and H200. B200 is designed for next-generation AI infrastructure.

Sources

- **一张图说清: H100、H200、B200 到底该怎么选? - 博客园** (relevance: 100%) <https://www.cnblogs.com/AlayaNeW/articles/19388803> | NVLink | 第四代 (900 GB/s) | 第四代 | 第五代 (1.8 TB/s) | . H200 不是算力升级, 而是显存与带宽升级, 解决“跑不动”的问题; . B200 则是一次架构级跃迁, 面向千卡集群、下一代 AI 工厂设计。 . | **<7B 参数, 微调/推理 | A10 / L4 / RTX 6000 Ada** | 小模型对算力要求低, A10/L4 成本更低; H100 属性能过剩, 仅在统一集群时考虑 | . | **7B-30B, 全参训练** | H100 | 在 FP8 + 梯度检查点 + ZeRO 下可高效训练PyTorch/TensorFlow 生态最成熟, 调试工...

- **万字长文解析：从H100 到B200，GPGPU 与大模型扩展性深度分析** (relevance: 100%) <https://zhuanlan.zhihu.com/p/1985478405458788975> GPU 算力增速远超带宽提升,数据并行的临界Batch Size 从H100 的2500 tokens/GPU 激增到B200 的5625 tokens/GPU; 应对策略包括FP8/FP4 量化、MoE 稀疏
- **全球主流算力芯片参数汇总、整理、对比（修正版） - 与非网** (relevance: 100%) <https://www.eefocus.com/article/1843061.html> 英伟达的芯片覆盖最广，包括高性能的H100、H200和B200，以及较早的V100、P100等，其产品线在算力和迭代速度均占据领先地位。英特尔的AI芯片为Guadi系列（如
- **芯片推理速度是英伟达的21倍，成本低30%，奥特曼早早投资了** (relevance: 100%) <https://www.51cto.com/aigc/9921.html> 这种技术路线与英伟达AI GPU算力体系以及谷歌TPU(AI ASIC技术路线)都截然 ... 智谱AI开源6款模型，推理速度200 tokens/秒碾压竞品，价格仅1/30
- **H100 vs. H200 vs. B200：为您的AI工作负载选择合适的NVIDIA GPU** (relevance: 100%) <https://introl.com/zh/blog/h100-vs-h200-vs-b200-choosing-the-right-nvidia-gpus-for-your-ai-workload> # H100 vs. **H100**: 3.35 TB/s（可观）. **H200**: 4.8 TB/s（43%改进）. **B200**: 8 TB/s（另一个宇宙）. "H200 Tensor Core GPU." NVIDIA Data Center. "DGX B200: The Foundation for Your AI Factory." NVIDIA Data Center. "Choosing GPU Infrastructure for LLM Training in 2025: NVIDIA H100 vs. "NVIDIA H200 vs H100: Better Per...

4.数据存储

检索关键词: HBM,显存,存储,NVLink

Answer

High Bandwidth Memory (HBM) is crucial for AI due to its high bandwidth and low latency, enhancing GPU performance. HBM improves data transfer rates, reducing bottlenecks in AI model training and inference. It enables efficient handling of large datasets and complex computations.

Sources

- **HBM，何以成为AI角力关键？ - 苏州超集信息科技有限公司** (relevance: 62%) <https://www.amaxchina.com/news/2167.html> # HBM，何以成为AI角力关键？_新闻中心_苏州超集信息科技有限公司. 三星电子近日宣布，其12层第六代HBM4内存将于10月底正式发布，现已进入研发冲刺阶段，并计划今年晚些时候量产。这一动作无疑为2025年本就爆发式增长的HBM市场再添一把烈火。. 为什么HBM年增速能突破200%，达到68亿美元全球市

值，成为AI赛道的"战略石油"。今天，超集信息带您透视HBM的底层逻辑：从打破"存储墙"到决定大模型训练速度，它如何悄悄掌控AI算力的生死线。· HBM对GPU的性能提升，本质是解决了传统内存（如GDDR6、DDR5）的"带宽瓶颈"——GPU计算核心的算力（如FP8算力达1-2 ...

- [illegible]

4.数据加速

检索关键词: FlashAttention,量化,推理优化

Answer

FlashAttention accelerates large language model inference through optimized attention mechanisms. It combines mixed precision quantization and inference optimization for performance gains. FlashAttention reduces computational bottlenecks and improves inference speed.

Sources

- **LLM推理加速4：MInference/FlashAttention-3/EAGLE-2/Q-Sparse. etc** (relevance: 100%) <https://zhuanlan.zhihu.com/p/708128459> 考虑量化也可以加速推理，因此公式变为 $Y=(Q(X)\odot M)W^T$ 。量化. 这种方法可以和量化一起使用，公式则变成 $Y=(Q(X)\odot M)Q(W^T)$ 。为了进一步提高激活的稀疏性，对
- **混合精度量化：FlashAttention实现模型压缩与加速的核心技术** (relevance: 100%) https://blog.csdn.net/gitblog_01067/article/details/152772343 FlashAttention作为高性能注意力机制实现，通过混合精度量化（Mixed Precision Quantization）技术在保持模型精度的同时实现了显著的性能提升。
- **FlashAttention - 3的新优化点对AI模型意味着什么？ - 飞书文档** (relevance: 100%) <https://docs.feishu.cn/v/wiki/ESWYwhmISiMOvIkU44CcIZVzntb/ad> 它在FlashAttention和FlashAttention-2 的基础上，进一步优化了对H 系列架构的支持，通过异步计算和低精度FP8 的使用，实现了GEMM（通用矩阵乘法）和Softmax 操作的重叠，以及
- **FlashAttention算法详解 - 阿里云开发者社区** (relevance: 100%) <https://developer.aliyun.com/article/1311766> 本文深入解析大语言模型推理加速的核心技术——FlashAttention。通过分析传统注意力机制的计算瓶颈，详细阐述FlashAttention的IO感知算法设计、前向反向传播
- **从FlashAttention到FlashDecoding：大模型推理加速的演进之路** (relevance: 100%) <https://blog.csdn.net/web39explorer/article/details/151979458> 所以，优化大模型推理速度，尤其是解码（生成）阶段的速度，首要目标不是让计算单元（CUDA Core）算得更快，而是想尽办法减少数据搬运的次数和数量，让数据尽可能待

4.Agent

检索关键词: 智能体,Agent,AutoGPT

Answer

智谱推出了全球首个设备操控智能体AutoGLM，并开源了其核心模型，旨在提升AI Agent的推理和执行能力。AutoGLM能够深入研究和执行任务，超越单纯的思考者。智谱致力于研发通用人工智能基座模型。

Sources

- **智谱发布全新Agent，集深度研究和操作执行于一体** (relevance: 100%) <https://zhuanlan.zhihu.com/p/1890064406051813020> 智谱在AI Agent领域的研发，包括从最早推出具备Function Call能力的智谱清言，到率先上线支持智能体编排的GLMs，再到推出全球首个设备操控智能体AutoGLM。
- **智谱、OpenAI “较上劲”！AI智能体又进化了：微信拜年 - 财联社电报** (relevance: 100%) <https://m.cls.cn/detail/1928882> 中国银河证券表示，AI Agent将是通往通用人工智能时代的必经之路，大模型快速迭代升级推动AI Agent能力提升，长期来看AI Agent关键在于推理能力，未来AI Agent广泛渗透时，对于
- **比R1快8倍、价格仅3%，智谱新推理模型来袭，能让免费智能体自己 ...** (relevance: 100%) <https://www.infoq.cn/article/wzqmmngbnzifflijqprnw> 智谱表示，未来两周，他们将进一步扩展更多智能体执行能力，包括推出“虚拟机”版本。此外，智谱还将于4月14日开源AutoGLM 沉思核心链路的模型和技术。据智谱 CEO 张鹏称，AutoGLM 背后有一系列的模型能力，Agent 也同大模型一样存在类似的 Scaling Law。· # AutoGLM 沉思背后的核心模型。“让机器不仅能够思考，还能主动行动。”智谱表示，这是他们对 AI Agent 的核心理解，目前已经探索到 L3-Agentic LLM 阶段。· 据介绍，与 OpenAI 的 Deep Research 不同，AutoGLM 沉思不仅能深入研究，还能真正执行任务，推...
- **厉害了，智谱造了全球首个手机通用Agent！人人免费 - 量子位** (relevance: 100%) <https://www.qbitai.com/2025/08/324341.html> 它会直接接管你的手机，不需要在各种APP之间跳来跳去，就可以把点外卖的活儿给干完。嗯，非常直观的感受就是：够方便，够智能。那么这个Agent到底是什么来头？
- **全栈布局AI智能体生态智谱发布集深度研究和操作执行于一体的Agent** (relevance: 100%) <http://www.zqrb.cn/gscy/gongsi/2025-03-31/A1743415736834.html> 据《证券日报》记者了解，这款全新智能体不仅具备深度研究能力（Deep Research），还能实现实际操作（Operator），可以像人类一样打开并浏览网页，完成从数据检索

五、整体技术趋势判断

5.1 战略方向

基于2026年04月05日的检索结果，智谱AI的AI战略呈现以下特点：

1. 技术路线:
2. 产品布局:
3. 生态建设:

5.2 竞争态势

- vs OpenAI:
- vs Google:
- vs 国内竞品:

5.3 未来展望

预测智谱AI在未来3-6个月可能的技术/产品动向：

- 1.
- 2.
- 3.

六、参考来源

- Tavily Search 检索结果
- 企业官方博客/公告
- 技术媒体（量子位、机器之心等）
- 学术论文（arXiv）

本报告由 OpenClaw AI 系统自动生成

报告版本: v1.0

生成时间: Sun Apr 5 06:01:29 AM CST 2026