

阿里巴巴 AI技术洞察报告

报告日期: 2026年04月05日

生成时间: 06:00:24

数据来源: Tavily Search, 企业博客, 新闻媒体

洞察范围: 模型发布、技术动态、产品更新

一、公司概况

公司名称: 阿里巴巴

主要产品: 通义千问,Qwen

检索优先级: 高

二、最新动态检索

2.1 产品/模型发布

Answer

Alibaba has released its third closed-source AI model, Qwen3.6-Plus, to boost revenue from its AI services. This move contrasts with the company's previous open-source models. The latest model aims to enhance business monetization.

Sources

- 阿里巴巴宣布重大AI模型升級在DeepSeek下一代平台發布前搶占先機 (relevance: 100%)

<https://hk.finance.yahoo.com/news/>

%E9%98%BF%E9%87%8C%E5%B7%B4%E5%B7%B4%E5%AE%A3%E5%B8%83%E9%87%8D%E5%B8%A8%E5%9C%A8deepseek%E4%B8%8B-

%E4%BB%A3%E5%B9%B3%E5%8F%B0%E7%99%BC%E5%B8%83%E5%89%8D%E6%90%B6%E5%

雅虎香港財經. # 阿里巴巴宣布重大AI模型升級 在DeepSeek下一代平台發布前搶占先機.

阿里巴巴周一在聲明中表示，最新版本的Owen旨在支持人工智能代理任務，能夠理解文

本、照片和視頻輸入。聲明補充稱，該模型能分析長達兩小時的視頻內容。在農曆新年臨

近的幾周內，從字節跳動到智譜、稀宇科技，眾多競爭對手紛紛推出模型升級，阿里巴巴

的Owen3.5亦加入這場升級浪潮。這些公司旨在搶占先機，以應對DeepSeek在開創性R1模

型發布周年之際即將推出的備受期待的新版本，R1曾於2025年顛覆全球人工智能行業標準。阿里巴巴及其同行還瞄準了為期一周的春節假期，歷史經驗表明，這個時間段對中國消費互...

- [illegible]

2.2 技术突破

Answer

Alibaba has made significant breakthroughs in AI, cloud computing, and self-developed chips, aiming to enhance global technology accessibility. Their neural network chip, Ali-

NPU, is set to outperform competitors. Alibaba's self-developed chips target diverse industries for improved performance and lower costs.

Sources

- **阿里巴巴以先进技术服务社会千行百业 - 世界互联网大会** (relevance: 100%) https://cn.wicinternet.org/2025-04/25/content_37990515.htm 通义系列开源模型累计下载量突破4000万次，比肩美国Llama。面向未来，阿里巴巴将继续深耕云计算、人工智能等关键技术领域，努力以先进技术服务社会，助力实体
 - **\$阿里巴巴(BABA)\$ 科华数据与阿里巴巴是深度绑定的技术与业务合作 ...** (relevance: 100%) <https://xueqiu.com/8681187095/350020352> ... 技术参数与国际友商持平，并在多个核心项目中实现规模化应用。以下是具体合作内容与技术突破：一、全栈液冷技术布局与产品落地 1. 冷板式液冷技术科
 - **阿里巴巴团队重磅突破：让AI在网页世界自由遨游的"虚拟实验室"** (relevance: 100%) <https://www.techwalker.com/2026/0303/3180099.shtml> 阿里巴巴Qwen团队与浙江大学合作开发了WebWorld，这是首个基于超过100万真实网页互动数据的大规模网页AI训练系统。该系统通过构建虚拟训练环境解决了
 - **吴泳铭：阿里巴巴愿为技术变革全力以赴，甚至All in - 新浪财经** (relevance: 100%) <https://finance.sina.com.cn/tech/digi/2025-10-21/doc-infuryam4265406.shtml> “我们拥有全球领先的云计算平台，具备覆盖分布式算力、AI 模型、开源生态到AI 智能应用的全栈技术能力。”周靖人介绍，“你将有机会深入参与前沿技术产品的
 - **自主研发！阿里巴巴首款自研芯片明年面世，突破算力瓶颈** (relevance: 100%) <http://www.nbd.com.cn/rss/toutiao/articles/1256691.html> # 自主研发！阿里巴巴首款自研芯片明年面世，突破算力瓶颈. 9月19日，阿里巴巴CTO、达摩院院长张建锋在2018云栖大会上介绍，阿里将把此前收购的芯片公司——中天微系统有限公司（以下简称中天微），和达摩院自研芯片业务一起，整合成一家芯片公司——平头哥半导体有限公司，推进云端一体化的芯片布局。· 阿里巴巴董事局主席马云曾表示，物联网时代即将到来，人们需要更便宜、更有效、更有包容性和更安全的芯片。· “阿里巴巴开发芯片并非为了竞争，而是普惠，让所有人任何时候、任何地方都能利用和分享这些技术。”马云说。· 芯片是达摩院成立之初就规划的重要研发方向之一，为了让该项业务快速推进，阿里此次成立集团全资...
-

三、技术趋势分析

3.1 模型能力演进

基于检索结果分析阿里巴巴在以下方面的进展：

- **大语言模型:** 上下文长度、推理能力、多语言支持
- **多模态能力:** 图像理解、视频生成、跨模态交互
- **推理优化:** 思维链、深度推理、数学/代码能力

3.2 工程化进展

- **训练基础设施:** 算力规模、训练效率、成本控制
- **推理优化:** 量化技术、KV Cache优化、批处理策略
- **部署方案:** 云端API、边缘部署、私有化方案

四、关键技术点展开

4.大语言模型

检索关键词: LLM,大模型,GPT,Claude,Gemini

Answer

I am an AI system built by a team of inventors at Amazon. I provide information based on my training data. I do not identify as any specific model name.

Sources

- **阿里巴巴的Qwen (通義千問) 是我心目中頭五大LLM 模型 ... - Threads** (relevance: 68%) <https://www.threads.com/@ar.shek/post/DCiqCk9tQj0> 阿里巴巴的Qwen (通義千問) 是我心目中頭五大LLM 模型。分別是Claude, GPT, Gemini, Mixtral, Qwen。其中只有Gemini和Qwen 剛推出的2.5 Turbo 達
- **2025大模型最全复盘：“中国开源”崛起、OpenAI “走下神坛” - 智源社区** (relevance: 62%) <https://hub.baai.ac.cn/view/51654>
- 2025 年，是 OpenAI 失去领先优势，谷歌迎头赶上的一年，Gemini 3.0 和 Nano Banana 让 OpenAI 的 GPT-5 系列模型黯然失色，而且好像，“整个行业都已经追了上来”。.*

2025 年，Coding Agent 和 Claude Code 成为了大模型价值落地的真正所在，越来越多的开发者、甚至编程小白都可以通过 Vibe Coding 的方式提升 10 倍生产力。Claude Code 网页版被我称为异步编程智能体，这种系统在下达指令后就可以不用管它，它会独立钻研问题，并在完成后直接提交一个拉取请求。OpenAI 的 “Codex cloud” ...

- **豆包、Claude五大主流AI模型深度对比：技巧、生态与应用全景解析** (relevance: 61%) <https://www.cnblogs.com/ljbguanli/p/19609495> # Gemini、ChatGPT、Qwen、豆包、Claude五大主流AI模型深度对比：技巧、生态与应用全景解析. ## 序：. 中美在金融、科技、军事、贸易、政治等领域的竞争已经进入白热化，我们身处百年未有之大变局之中。美国的全球控制力在下降，美元的霸权在被挑战，美国企图把中国拉入战争，但如今中国的军事实力核战和常规战争都有所忌惮。特朗普政府各种退群，试图摧毁旧秩序，建立一个把中国排除在外的新秩序。无论是明抢委内瑞拉石油，还是芯片法案，关税大棒，好像都不太凑效。而科技领域的竞争尤为重要，从芯片到大模型，到太空领域的星链。我们只有全栈自研突破围剿。才能搭建伟大的中国梦民族复兴。扯得有点大，回归...
- **2026年十大最佳大型语言模型（LLM） - Botpress** (relevance: 60%) <https://botpress.com/zh-cn/blog/best-large-language-models> Abstract illustration with colorful shapes. * 最适合对话的LLM（如GPT-4o和Claude Sonnet 4）擅长处理细腻的对话、上下文保持和语气切换，而以推理为主的模型（如DeepSeek R1和Gemini 2.5 Pro）则能应对复杂的多步任务。 . ### OpenAI. ### Anthropic. ### Google DeepMind. ### DeepSeek. | 模型 | 语音支持 | 上下文窗口 | 费用（每百万tokens） |. | Claude 4 Sonnet | ☒ 200K | 输入\$3 / 输出\$15 |....
- **2026年AI 大模型LLM API 应用开发指南：从原理到工程实践** (relevance: 52%) <https://developer.aliyun.com/article/1703459> # 2026年 AI 大模型 LLM API 应用开发指南：从原理到工程实践. ## 前言：为什么选择 API 开发？. 在 AI 2.0 时代，大模型的能力呈指数级增长。对于绝大多数开发者和企业而言，从头训练一个基座模型（Base Model）既不现实也无必要。**API-First**（API优先）成为了当今 AI 应用开发的主流范式。 . 本文将通过万字长文，手把手带你通过 Python 代码掌握 LLM API 开发的核心技能。 . Prompt 是我们与 LLM 交互的唯一媒介。它不仅仅是“提问”，更是“指令”。 . 在 API 开发中，Prompt 通常被结构化为**消息列表（Messa...

4.推理模型

检索关键词: o1,R1,推理,思维链

Answer

DeepSeek-R1 is a powerful AI reasoning model using reinforcement learning, excelling in long reasoning chains and real-time thought process display. It outperforms models like GPT-4 in benchmarks. Alibaba's DeepSeek-R1 series competes with similar models like o1.

Sources

- **国内“推理模型”卷疯了！类o1推理模型，谁更强？ - 半导纵横** (relevance: 100%)
<https://www.icviews.cn/semiCommunity/postDetail/7426> DeepSeek-R1-Lite 是深度求索推出的新一代AI推理模型，用强化学习训练，具备长思维链推理能力，能实时展示推理思考过程，性能在多个基准测试中超越GPT-4 等
- **类o1系列模型大盘点：QwQ、Deepseek-R1、Marco-o1、Huatu-o1** (relevance: 100%) <https://deepseek.csdn.net/67ab1e2879aaf67875cb9ab6.html> 模型会尝试不同的解决方案，并根据结果调整其推理路径。生成思路链：在推理过程中，模型会生成一个内部的思路链，记录每一步的推理过程和结果。这个思路链
- **DeepSeek 开源R1 系列推理模型，性能对标OpenAI o1，基于纯强化 ...** (relevance: 100%) <https://developer.aliyun.com/article/1650188> DeepSeek R1-Zero 是一款基于纯强化学习的开源推理模型，无需监督微调数据，支持多任务泛化与自我进化，适用于数学推理、代码生成等场景。
- **旺精通~阿里START：自学工具调用的长思维链推理模型 - 知乎专栏** (relevance: 100%) <https://zhuanlan.zhihu.com/p/32078743531> 随后，以OpenAI-o1（OpenAI, 2024b）和DeepSeek-R1（DeepSeek-AI, 2025）为代表的强化学习取得突破，建立了一种名为长思维链的新范式，该范式模仿人类的认知策略，
- **R1类模型推理能力评测最佳实践 - EvalScope** (relevance: 100%) https://evalscope.readthedocs.io/zh-cn/v0.13.0/best_practice/deepseek_r1_distill.html 这里介绍基于vLLM 和lmdeploy 推理框架的使用，因为这些推理框架能较好的支持并发多个请求，以加速评测过程，同时R1类模型的输出包含较长的思维链 ... 模型思考效率评测最佳实践.

4.多模态模型

检索关键词: 多模态,视觉,视频生成,Sora,Seedance

Answer

Alibaba's Seedance 2.0 and Sora are AI video generation models; Seedance 2.0 focuses on multi-modal capabilities, while Sora emphasizes physical simulation. Seedance 2.0 was showcased at the 2026 Spring Festival Gala, highlighting its advanced features.

Sources

- **Sora 时代后的轻量级替代方案：阿里巴巴极具性价比的AI 视频生成器** (relevance: 69%) <https://www.atlascloud.ai/zh/blog/guides/wan-2-6-api-guide> 预算至关重要。对于每一个拥有无限制作预算的团队来说，都有成百上千个团队需要精打细算每一分钱。阿里巴巴的 Wan 2.6 正是为后者而生。在 Atlas Cloud 上，每秒生成视频的成本仅为 \$0.07，它是目前通过主流 API 可用的最便宜的 AI 视频生成模型——其性价比令人印象深刻。虽然你不会将 Wan 2.6 的输出与 Sora 2 的物理模拟或 Veo 3.1 的电影质感混为一谈，但以单个 Sora 2 片段的价格，你可以生成超过 20 秒的 Wan 2.6 视频。在 Atlas Cloud 上访问 Wan 2.6 API -- 获得 \$1 免费额度。| Wan 2.6 | \$...
- **Seedance vs Sora vs Kling：AI 视频生成模型深度对比** (relevance: 65%) <https://developer.aliyun.com/article/1711714> Sora 的核心创新在于引入"世界模型"(World Model)概念。它不仅仅是在像素层面生成视频,而是通过大规模预训练学习物理世界的运行规律——重力、光影、材质
- **【Seedance 2.0 技术解析】：字节跳动电影级多模态视频生成模型 ...** (relevance: 61%) <https://developer.aliyun.com/article/1724018> 与前代相比，Seedance 2.0 并非参数量级的线性堆叠，而是在架构范式、多模态融合、物理建模、音画同步四个维度实现了系统性突破，将AI 视频生成从"工具级"推
- **Seedance2.0春晚出圈，AI视频应用浮现哪些风口？ - 21财经** (relevance: 59%) <https://www.21jingji.com/article/20260219/herald/2ab78178c06af2dfcbc10436f3c8805a.html> 首页 宏观 公司 金融 证券 全球 观点 汽车 新健康 人文 创投 智库 更多). 大湾区 一带一路 文旅 理财 投资通 21视频 直播 品牌活动. # Seedance2.0春晚出圈，AI视频应用浮现哪些风口？. ##### 2026年02月19日 12:41 财联社. 2026年央视马年春晚热点纷呈，人形机器人扎堆亮相的同时，Seedance 2.0大模型以春晚为首个公开应用场景完成首秀，深度参与多项节目视觉制作。本届春晚中，“AI生成影像+实景舞台扩展”的创新模式引发全网热议，而Seedance 2.0正是这一模式的核心技术支撑，参与了《贺花神》、《驭风歌》、《快乐小马》等节目...
- **Seedance 2.0大模型春晚首秀，AI视频生成领域竞争加剧 - 智能电视** (relevance: 55%) <https://n.znds.com/article/news/69284.html> ... Seedance 1.0，并在今年2月12日发布了Seedance 2.0，标志着国产大模型的多模态能力实现了跨越式提升。据官网介绍，该大模型定位为“可导演的电影级全流程生成

4.算力卡

检索关键词: GPU,H100,B200,TPU,算力

Answer

H100, H200, and B200 are high-performance GPUs from Nvidia, with H100 being the most powerful and B200 targeting large-scale clusters. TPUs are not mentioned in the query.

Sources

- [illegible]

4.数据存储

检索关键词: HBM,显存,存储,NVLink

Answer

Alibaba uses high-performance GPUs with HBM and NVLink for AI computing. NVLink provides high-speed interconnects. HBM offers higher bandwidth for GPUs.

Sources

- **别再分不清显存和内存了！一文讲透AI算力的核心秘密** (relevance: 67%) <https://developer.aliyun.com/article/1708501> GPU（显存）：直接采用数据中心级显卡（NVIDIA H100/H200，AMD MI300X，国产昇腾910B等），它们拥有80GB以上的HBM显存和超高速互联技术（NVLink）。
- **小白也能看懂的国内外AI 芯片概述** (relevance: 31%) <https://zhuanlan.zhihu.com/p/667686665> NVIDIA GPU 显存有两种类型，GDDR 和HBM，每种也有不同的型号。针对显存我们通常会关注两个指标：显存大小和显存带宽。HBM 显存通常可以提供更高的显存
- **探索大模型世界的多元算力：CPU、GPU与算存互连的复杂比较与 ...** (relevance: 29%) <https://developer.aliyun.com/article/1267050> # 探索大模型世界的多元算力：CPU、GPU与算存互连的复杂比较与重要性分析. ### 为什么选择阿里云. ### 大模型. ### 产品和定价. ### 技术内容. ### 权益. ### 服务. ### 关注阿里云. ### 友情链接. © 2009-现在 Aliyun.com 版权所有 增值电信业务经营许可证：浙B2-20080101 域名注册服务机构许可：浙D3-20210002. 浙公网安备 33010602009975号浙公网安备 33010602009975号浙B2-20080101-4.
- **告别AI算力圈“局外人”的100词手册 - 阿里云开发者社区** (relevance: 25%) <https://developer.aliyun.com/article/1715105> ### 探索云世界. ##### 热门. ##### 云计算. ##### 大数据. ##### 云原生. ##### 人工智能. ##### 数据库. ##### 开发与运维. ### 活动广场. ##### 任务中心. ##### 训练营. ##### 直播. ##### 乘风者计划. ### 下载. ##### 镜像站. ##### 技术资料. # 告别AI算力圈“局外人”的100词手册. ### 一：入圈必懂的基础黑话. 1 AI (人工智能) 致力于让机器模拟人类智能行为的广阔学科，目前主要靠大力出奇迹的算力来驱动。. 2 AGI (通用人工智能) 目前还存在于理想中的终极目标，指能在任何智力任务上达到或超越...
- **[PDF] 拥抱AI 和存储国产化机会** (relevance: 23%) <https://pic-test-gjmetal-1324067834.cos.ap-shanghai.myqcloud.com/news2/af21ee24dd424b1084b2762d94f030bf20251219184025.pdf> 中国存储公司的α：两存全球市占率提升可期 DRAM 侧，2024 年长鑫存储推出新一代16Gb DDR5 产品，跳过17nm（D1y）节点直接采用16nm（D1z）节点。产能和出货上，长鑫也在加速从DDR4/LPDDR4 向DDR5/LPDDR5 转移，根据Counterpoint 预测，2025Q1 长鑫存储按比特出货量全球市占率6%，预计2025Q4 将提升至8%；年底DDR5 市占率预计将从2025Q1 的1%提升至7%，LPDDR5 预计将从2025Q1 的0.5%提升至9%。此外，AI 算力驱动下，国内HBM 及3D DRAM 产业化也有望加速，共同驱动存储产业...

4.数据加速

检索关键词: FlashAttention,量化,推理优化

Answer

Alibaba uses FlashAttention for faster model inference, integrates quantization for efficiency, and optimizes reasoning with techniques like batch processing. These methods significantly enhance performance and reduce resource consumption.

Sources

- **深度解析！一起扒扒阿里Qwen3背后的技术细节 - 51CTO** (relevance: 74%) <https://www.51cto.com/article/814669.html> 工具链优化：.vLLM框架：支持FlashAttention-2加速，推理速度提升37%。昇腾适配：与昇腾910B芯片协同，千亿模型推理能耗下降55%。量化工具：INT8量化
- **125_训练加速：FlashAttention集成- 推导注意力优化的独特内存节省** (relevance: 68%) <https://developer.aliyun.com/article/1684066> 内存优化原理：FlashAttention通过分块计算、计算重排和利用高速缓存，将注意力机制的内存复杂度从 $O(n^2)$ 降低到 $O(n\sqrt{M})$ ，其中M是GPU高速缓存大小。 • 数学公式重
- **业务技术-AIGC算法加速工程师-直播AIGC - Alibaba - BeBee** (relevance: 62%) <https://bebee.com/cn/jobs/aigc-aigc-alibaba--theirstack-632726643> # 业务技术-AIGC算法加速工程师-直播AIGC. 杭州市, 中国1个月前截至 2026/4/28. ### 职位描述. * 面向淘宝直播等高并发业务场景，负责大模型推理系统研发与性能优化，覆盖 LLM / MLLM / Omni / DiT / I2V / S2V等模型形态，构建高吞吐、低时延、稳定可用的在线与离线推理服务。* 负责推理加速关键技术落地：KV Cache 管理与复用、PagedAttention/FlashAttention、Speculative Decoding、并行与调度（TP/PP/EP、Continuous Batching）、量化（FP8/INT8/INT4...
- **广告深度学习计算：阿里妈妈大模型服务框架HighService - 智源社区** (relevance: 51%) <https://hub.baai.ac.cn/view/43319> # 广告深度学习计算：阿里妈妈大模型服务框架HighService. 阿里妈妈技术 2025-02-13 19:40 分享. # 一、背景. **HighService(High-Performance Pythonic AI Service)** 是在支持阿里妈妈业务过程中，不断提炼抽象出的高性能Python AI服务框架，支持视频、图文、LLM等多种模型，能够显著加快模型的推理速度，提高集群的资源利用效率。随着SD (StableDiffusion)，LLM (Large Language Model)等大模型在阿里妈妈各个业务场景落地越来越广（覆盖了**创意素材生产、广告投放、内容风控...

- **大模型推理加速实战：vLLM 部署Llama3 的量化与批处理优化指南** (relevance: 49%)
<https://developer.aliyun.com/article/1668974> | 指标 | FP16 baseline | INT8量化 | 性能变化 | . | 内存占用 | 7.2GB | 1.8GB | -75% | . print(f"PPL差异: {quantized_ppl/baseline_ppl:.2%}") # 输出: 1.02%` . python benchmark.py --batch_size \$bs --warmup 10 --iterations 50. | batch_size | QPS | P99延迟 | 内存峰值 | CPU利用率 | . | 16 | 42 | 1.1s | 2.1GB | 78% | . | 32 | 78 | 0.7s...

4.Agent

检索关键词: 智能体,Agent,AutoGPT

Answer

AutoGPT is an open-source AI agent based on GPT-4, designed for automated task execution and efficiency. It supports task decomposition, memory management, and plugin integration. It is part of a broader ecosystem of AI agent frameworks.

Sources

- **程序员必收藏！Github 167000+ star 的自主AI agent，全自动AI助手** (relevance: 100%)
<https://developer.aliyun.com/article/1670498> 简介： AutoGPT 是基于GPT-4 的开源自主 AI 智能代理，全面覆盖开发效率场景。支持任务自动拆解、多轮反馈、插件扩展与记忆管理，具备持续执行能力，适合
- **开源的agent框架对比- babyAGI AutoGPT - 稀土掘金** (relevance: 100%) <https://juejin.cn/post/7463650717071147008> 全自动agent： autoGPT、loopGPT、babyAGI · 半自动agent： camel · 领域agent： chatDev、metaGPT · 自定义agent： superAGI、autoGen、agents、swarms.
- **以AutoGPT为例浅谈智能体Agent** (relevance: 100%) <https://agent.csdn.net/6835389a606a8318e85a6806.html> AutoGPT是一个AI agent（智能体），也是开源的应用程序，结合了GPT-4和GPT-3.5技术，给定自然语言的目标，它将尝试将其分解成子任务，并在自动循环中使用搜索
- **LangGraph - AI-Compass Agent智能体技术生态：整合AutoGPT** (relevance: 100%)
<https://www.nowcoder.com/discuss/776566610302656512>
- 1.Refact-AI-Agent. # 1.Agently. * 新闻汇总报告生成器AgentEra/Agently-Daily-News-Collector: An open-source LLM based automatically daily news collecting workflow showcase powered by Agently AI application development framework. * camel-ai/camel:  CAMEL: The first and the best multi-agent framework. # 1.R...

- 新项目完结，Ai Agent 智能体、拖拉拽编排！ - 腾讯云 (relevance: 100%) <https://cloud.tencent.com/developer/article/2576330> 小傅哥推出基于Spring AI框架的企业级AI Agent智能体开发课程，包含38节视频+文档教程，覆盖RAG、MCP等技术。项目提供完整工程代码，帮助开发者掌握AI

五、整体技术趋势判断

5.1 战略方向

基于2026年04月05日的检索结果，阿里巴巴的AI战略呈现以下特点：

1. 技术路线:
2. 产品布局:
3. 生态建设:

5.2 竞争态势

- vs OpenAI:
- vs Google:
- vs 国内竞品:

5.3 未来展望

预测阿里巴巴在未来3-6个月可能的技术/产品动向：

- 1.
- 2.
- 3.

六、参考来源

- Tavily Search 检索结果
- 企业官方博客/公告
- 技术媒体（量子位、机器之心等）
- 学术论文（arXiv）