

DeepSeek AI技术洞察报告

报告日期: 2026年04月12日

生成时间: 06:01:24

数据来源: Tavily Search, 企业博客, 新闻媒体

洞察范围: 模型发布、技术动态、产品更新

一、公司概况

公司名称: DeepSeek

主要产品: DeepSeek-V3,R1

检索优先级: 高

二、最新动态检索

2.1 产品/模型发布

Answer

DeepSeek released the DeepSeek-R1 model in January 2025, followed by DeepSeek-V3 in December 2024. DeepSeek-R1 is a reasoning model with competitive performance at lower cost. DeepSeek continues to innovate with upcoming models like DeepSeek-V4.

Sources

- DeepSeek发布新一代AI模型：推理更强，使用成本降一半 - 新浪财经** (relevance: 100%)
<https://finance.sina.com.cn/stock/usstock/c/2025-09-30/doc-infshafs8088972.shtml>
中国人工智能开发商DeepSeek 推出了一款实验性大型语言模型（LLM），号称在训练与推理能力上有显著提升，并能以更低的成本运行。总部位于杭州的DeepSeek
- DeepSeek 时间线与模型发布速览 - AI 工具箱** (relevance: 100%) <https://fishersama.com/deepseek-timeline>
2025年1月20日，DeepSeek推出了推理模型 DeepSeek-R1，并同步开源其模型权重，通过大规模强化学习技术显著提升推理能力，性能媲美顶尖闭源产品，迅速引发全球关注。MIT 许可均可

- **DeepSeek 计划二月中旬发布新模型DeepSeek-V4 - 知乎** (relevance: 100%) <https://www.zhihu.com/question/1993329446883651767> 我是相信DeepSeek在2月份肯定也会有一个大模型发布，我也认为大概率会是大版本的V4，我也认为下一个版本Coding能力很强，会比Anthropic和OpenAI的一些模型更
- **V4前哨戰？ DeepSeek神祕新模型Model 1曝光主打高效推理** (relevance: 100%) <https://hk.finance.yahoo.com/news/v4%E5%89%8D%E5%93%A8%E6%88%B0-deepseek%E7%A5%9E%E7%A5%95%E6%96%B0%E6%A8%A1%E5%9E%8Bmodel-1%E6%9B%9D%E4%B8%BB%E6%89%93%E9%AB%98%E6%95%88%E6%8E%A8%E7%90%86-081011728.html> 結合先前ITPro 的報導，DeepSeek 計劃於今年2 月中旬（農曆新年期間）發布旗艦模型DeepSeek-V4。V4 預計將搭載全新的技術架構，大幅提升編寫程式碼的能力。
- **DeepSeek：开源大模型探索 | 企业级 AI 应用前沿 | IBM** (relevance: 100%) <https://www.ibm.com/cn-zh/think/topics/deepseek> 2025 年 1 月发布的 DeepSeek-R1 带来了大量报道 DeepSeek 的文章，其中可能会令人困惑的一点是：DeepSeek 深度求索即是一家公司的名称，也是该公司所制作模型的名称，DeepSeek 还是在此类模型上运行的聊天机器人的名称。鉴于报道的数量和人们对 AI 领域发生重大转变所带来的经济影响的兴奋，一般读者可能很难区分事实与猜测和虚构。DeepSeek 是一个位于中国杭州的 AI 研究实验室。这也是该公司开发的开放权重生成式 AI 模型的名称。2025 年 1 月下旬，他们的 DeepSeek-R1 LLM 在主流科技和金融新闻中被广泛报道，其性能可与 ...

2.2 技术突破

Answer

DeepSeek has achieved significant breakthroughs in AI model efficiency, reducing training costs and computational requirements. Its innovations include mixed-expert architecture and low-precision training methods. DeepSeek's advancements challenge traditional notions of computational power in AI development.

Sources

- **为什么DeepSeek-R1 可以用低成本训练出高效的模型** (relevance: 100%) <https://zhuanlan.zhihu.com/p/21344231621> 零监督突破： DeepSeek-R1-Zero 成功证明无需传统的监督微调数据也能实现强大推理能力。通过多数投票机制，性能甚至超越了OpenAI-o1。自适应思考： 在训练
- **超越矽谷模型突破美國晶片禁令？ | AI 中文繁簡字幕** (relevance: 100%) https://www.youtube.com/watch?v=__4bRZGvjRI 【DeepSeek 蒸餾技術】小模型如何實現大智慧？ DeepSeek R1 推理模型蒸餾的可能性 | 知蒸餾將如何改變AI應用格局？ Yolo 街 • 69K views • 28:01.

- **DeepSeek是怎么练成的？万字解析DeepSeek成长史 - 智源社区** (relevance: 100%) <https://hub.baai.ac.cn/view/43089> 早在成立 DeepSeek 之前，幻方便已开始在 AI 行业进行了长远布局。2023 年 5 月，梁文锋在接受暗涌采访时提到：“2020 年 OpenAI 发布 GPT3 后，人工智能发展的方向已经非常清晰，算力将成为关键要素；但即便 2021 年，我们投入建设萤火二号时，大部分人还是无法理解”。要知道，DeepSeek Coder 是 7B 模型，而 CodeLlama 却是 34B。另外，经过指令调优后的 DeepSeek Coder 模型更是全面超越了 GPT3.5-Turbo。2023年11月29日，DeepSeek 发布了其首款通用大语言模型 DeepSeek LL...
- **一场关于DeepSeek的高质量闭门会：比技术更重要的是愿景** (relevance: 100%) <https://wallstreetcn.com/articles/3740158> DeepSeek-R1以始料未及的速度引发了全球AI社区的狂热，但有关DeepSeek的高质量信息相对匮乏。2025年1月26日，拾象创始人兼CEO李广密，组织了一场
- **极致性能背后的算力逻辑：DeepSeek如何重构AI研发的底层叙事-新华网** (relevance: 100%) <https://www.news.cn/tech/20250213/ffa943332636461aaa76810c9d717c32/c.html> # 极致性能背后的算力逻辑：DeepSeek如何重构AI研发的底层叙事. # 极致性能背后的算力逻辑：DeepSeek如何重构AI研发的底层叙事. 2025-02-13 08:38:11 来源：人民邮电报. 2025年伊始，来自中国的开源AI模型DeepSeek爆火。随后，美国总统特朗普、OpenAI 首席执行官奥特曼纷纷发声，承认其给AI行业带来的“震撼”。《纽约时报》评价称，DeepSeek能与OpenAI的ChatGPT媲美，“仅此一点就已经是一个里程碑”。DeepSeek是如何在AI竞赛中脱颖而出的？它是否走出了大模型发展的一条新路？在DeepSeek突围之前，AI领域普遍存在一种...

三、技术趋势分析

3.1 模型能力演进

基于检索结果分析DeepSeek在以下方面的进展：

- **大语言模型:** 上下文长度、推理能力、多语言支持
- **多模态能力:** 图像理解、视频生成、跨模态交互
- **推理优化:** 思维链、深度推理、数学/代码能力

3.2 工程化进展

- **训练基础设施:** 算力规模、训练效率、成本控制
 - **推理优化:** 量化技术、KV Cache优化、批处理策略
 - **部署方案:** 云端API、边缘部署、私有化方案
-

四、关键技术点展开

4.大语言模型

检索关键词: LLM,大模型,GPT,Claude,Gemini

Answer

I am an AI system built by a team of inventors at Amazon. I do not identify as any specific model name. My purpose is to assist with information and tasks.

Sources

- **DeepSeek全景解析：技术革新与应用实践（八）——DeepSeek R1与主流大模型（GPT-4、Claude、Gemini等）全方位对比解析_DeepSeek_InterGPT-DeepSeek技术社区** (relevance: 83%) <https://deepseek.csdn.net/680f784dc7c7e505d34e7f7e.html> # logo DeepSeek技术社区. ### DeepSeek技术社区. # DeepSeek全景解析：技术革新与应用实践（八）——DeepSeek R1与主流大模型（GPT-4、Claude、Gemini等）全方位对比解析. 通过对DeepSeek R1与GPT-4.5、Claude-3.7、Gemini 1.5 Pro的全面对比，我们可以看到各模型在性能、成本、中文适配、内容生成、长文本与多模态支持等方面各有千秋。DeepSeek R1凭借低成本、高性价比和中文本地化优势，成为中小型团队和本地化任务的首选；GPT-4.5在创意生成和国际化适配上表现突出，适合追求多样性和生态整合的用户； ...
- **DeepSeek、GPT-4、Claude、Gemini 全面对比：谁才是最強AI** (relevance: 76%) <https://university.1111.com.tw/zone/university/discussTopic.asp?cat=University&id=350121> ##### 取得聲譽積分說明:. # DeepSeek、GPT-4、Claude、Gemini 全面对比：谁才是最強 AI. up vote 0 favorite 0. 隨著生成式AI快速發展，語言模型（LLM）已成為科技產業與商業應用的核心。本文將深入比較市面上主流的四大語言模型——DeepSeek、GPT-4、Claude（Anthropic）和Google Gemini，從技術架構、性能、應用場景、多模態支持、成本與可用性等方面，幫助企業及開發者選擇合適的工具。 . 由中國DeepSeek AI 公司開發，著重金融數據與中文文本分析。DeepSeek-V2 部分開源，允許企業或開發者自建私...
- **大模型辅助编程哪家强？试过 DeepSeek、Claude、Gemini 后，我写了个小工具-腾讯云开发者社区-腾讯云** (relevance: 76%) <https://cloud.tencent.com/developer/article/2532753> ## 大模型辅助编程哪家强？试过 DeepSeek、Claude、Gemini 后，我写了个小工具. # 大模型辅助编程哪家强？试过 DeepSeek、Claude、Gemini 后，我写了个小工具. ## 最近在写量化，经常会使用 ChatGPT、Claude、Trae、Gemini、DeepSeek 等辅助编程或者深度研究。 . 之前领了个 Gemini 的会员，DeepResearch、Gemini Pro 2.5 可以隨

使用。我可以给 Gemini 研究完，然后再要求它按照研究报告开始设计，最后开始编写代码。在网页上和大模型对话，编写代码，不仅免费而且总感觉效果要比 API ...

- **【译】Grok 3 vs ChatGPT vs DeepSeek vs Claude vs Gemini：2025年2月哪款AI最好？ - 楚人Leo - 博客园** (relevance: 75%) <https://www.cnblogs.com/leolion/p/18736003> ## Loading. ## Loading. # 生命不息，折腾不止. ## 要有最朴素的生活，与最遥远的梦想。即使明日天寒地冻、路远马亡。 . # **【译】Grok 3 vs ChatGPT vs DeepSeek vs Claude vs Gemini：2025年2月哪款AI最好？** . 人工智能（AI）的进步速度前所未有的，几乎每周都有新的模型和技术问世。2025年1月，中国初创公司**DeepSeek推出了R1 AI模型**，迅速超过ChatGPT，成为美国iOS应用商店最受欢迎的免费应用。这一迅猛崛起不仅颠覆了AI格局，还在全球科技市场上掀起波澜，导致主要行业玩家的股价出现显著波动。借着...
- **AI實力大PK！外媒實測5大面向：ChatGPT、Gemini、DeepSeek、Claude 誰更強？|數位時代 BusinessNext** (relevance: 74%) <https://www.bnext.com.tw/article/83590/chatgpt-gemini-deepseek-claude-comparison> 創新創業 商業經營 行銷與MARTECH 職場／工作術 程式開發. {"id": 83590,"title":"AI\u5be6\u529b\u5927PK\u00ff01\u5916\u5a92\u5be6\u6e2c\u5927\u9762\u5411\u00ff02\u8ab0\u66f4\u5f37\u00ff1f","image":"https://image-cdn.learnin.tw/bnextmedia/image/album/2025-06/img-1750130198-49836...

4.推理模型

检索关键词: o1,R1,推理,思维链

Answer

DeepSeek R1 models use reinforcement learning and extensive reasoning chains for complex tasks. The o1 model employs advanced reasoning prompts for iterative problem solving. DeepSeek R1's performance rivals o1 in complex logic and math reasoning.

Sources

- **DeepSeek推理模型预览版上线，解密o1推理过程 | DeepSeek API Docs** (relevance: 100%) <https://api-docs.deepseek.com/zh-cn/news/news1120> # DeepSeek推理模型预览版上线，解密o1推理过程. 今天，DeepSeek 全新研发的推理模型 DeepSeek-R1-Lite 预览版正式上线。所有用户均可登录官方网页（chat.deepseek.com），一键开启与 R1-Lite 预览版模型的超强推理对话体验。DeepSeek R1 系列模型使用强化学习训练，推理过程包含大量反思和验证，思维链长度可达数万字。该系列模型在数学、代码以及各种复杂逻辑推理任务上，取得了媲美 o1-preview 的推理效果，并为用户展现了 o1 没有公开的完整思考过程。#### 全面提升的推理性能. ## 深度思考的效果与潜力. D...

- **DeepSeek R1 Vs OpenAI o1! 全球顶级推理模型训练技术对比大解密!** (relevance: 100%) <https://www.51cto.com/article/807646.html> 思维链提示: o1 模型采用思路链提示, 这是一种先进的策略, 可以逐步迭代推理问题。这种方法增强了模型处理复杂查询的能力, 并提供更准确的响应。强化学习: o1
- **从o1-mini到DeepSeek-R1, 万字长文带你读懂推理模型的历史与技术** (relevance: 100%) <https://zhuanlan.zhihu.com/p/25978555277> 推理模型的长思维链输出为我们提供了一种控制LLM 推理时间计算的简单方法。如果我们想花费更多计算来解决问题, 我们可以简单地生成更长的思维链。同样, 不太
- **从o1到DeepSeek-R1, 万字长文带您揭秘推理模型——及其与标准 ...** (relevance: 100%) <https://zhuanlan.zhihu.com/p/26076930125> 推理模型与标准LLM的主要区别在于能够在回答问题之前“思考”。推理模型的思维只是由LLM输出的长链思维——简称长CoT, 有时称为推理轨迹或路径。长CoT的生成
- **DeepSeek R1 之后, 重新理解推理模型 - 智源社区** (relevance: 100%) <https://hub.baai.ac.cn/view/43321>
- 将 RL + SFT 与推理时 scaling 相结合。这很可能是 OpenAI o1 所做的事情, 但它可能基于比 DeepSeek-R1 更弱的基模型, 这解释了为什么 DeepSeek-R1 在推理时表现良好同时相对便宜。同时一个专注于纯强化学习 (TinyZero), 另一个专注于纯SFT (Sky-T1) 新模型都带来很多这条道路上的启发。 . 2. DeepSeek-R1: 这是 DeepSeek 的旗舰推理模型, 基于 DeepSeek-R1-Zero 构建。团队通过额外的 SFT 阶段和进一步的 RL 训练进一步优化了它, 改进了“冷启动”的 R1-Zero 模型。 . 3. DeepSeek...

4.多模态模型

检索关键词: 多模态,视觉,视频生成,Sora,Seedance

Answer

DeepSeek 多模态模型和Seedance 2.0 在视频生成领域表现出色, 特别是在可控生产流程和自动化导演功能方面。Seedance 2.0 允许用户上传参考视频, 提高了生成的可控性。Sora 和 Seedance 2.0 被认为是未来AI视频生成的领先者。

Sources

- **多模态“Deepseek时刻”下的大厂分化: 字节拼“效率”, 快手攻“专业”** (relevance: 100%) <https://wallstreetcn.com/articles/3765577> 研报认为Seedance 2.0用“@素材名”指定图片/视频/音频用途, 实质是在把黑盒式生成拆解成可控的生产流程: 模型可以分别提取@视频的运镜、@图片的细节、@音频的

- **Seedance 2.0 的地震还在升级，像当年的DeepSeek和Sora一样** (relevance: 100%) [https://h5.ifeng.com/c/vivoArticle/v002e5--xHeHC5T4fgy1yqUiUdJX6lyWf8nK0InVG20wtktto__?](https://h5.ifeng.com/c/vivoArticle/v002e5--xHeHC5T4fgy1yqUiUdJX6lyWf8nK0InVG20wtktto__?isNews=1&vivoBusiness=browser&showComments=0) 其最显著的突破，是实现了接近真人导演的“自分镜与自运镜”能力。用户无需繁琐描述镜头运动，只需输入故事梗概，模型便能自动分解成逻辑连贯、衔接自然的多个
- **Seedance 2.0 vs. Sora 2 vs. Kling 3.0：2026年终极AI 视频API 对比 ...** (relevance: 100%) <https://www.atlascloud.ai/zh/blog/guides/seedance-2-vs-sora-2-vs-kling-3-comparison> 其最突出的特点是多模态参考系统。为何在可控性上胜出：与其他只能祈祷随机种子起作用的模型不同，Seedance 2.0 允许您上传一个_参考视频_。您可以
- **国产模型悄然打赢一场多模态战役 - 36氪** (relevance: 100%) <https://eu.36kr.com/zh/p/3739204925764102> Seedance 2.0凭借它的强大能力，已经被人们视为未来制作电影的“神器”，而它现在唯一存在的尴尬之处，就在于缺少配音。音频生成看起来比视频生成要简单，但给
- **中金：Seedance2.0对互联网有何影响？** (relevance: 100%) <https://finance.sina.cn/2026-03-23/detail-inhrxmef4348554.d.html?vt=4> Seedance 2.0：AI视频生成“DeepSeek时刻”的开启。26年2月，字节跳动发布了AI视频模型Seedance2.0，其模型在全模态输入/输出，镜头&叙事一致性等维度展现了系统

4.算力卡

检索关键词: GPU,H100,B200,TPU,算力

Answer

DeepSeek leverages GPUs like H100 and A100 for training, but ASIC chips are emerging for cost-effective inference. B200 outperforms H100 significantly in DeepSeek-R1 tasks. ASICs promise lower costs and higher efficiency for specific AI tasks.

Sources

- **DeepSeek掀起算力革命，英伟达挑战加剧，ASIC芯片悄然崛起 | 投中网** (relevance: 84%) <https://m.chinaventure.com.cn/news/78-20250311-385426.html> # DeepSeek掀起算力革命，英伟达挑战加剧，ASIC芯片悄然崛起. ## “新地图”价值远不止1000亿美元。DeepSeek带动推理需求爆发，英伟达的“算力霸权”被撕开一道口子，一个新世界的大门逐渐打开——由ASIC芯片主导的算力革命，正从静默走向喧嚣。日前，芯流智库援引知情人士的消息，称DeepSeek正在筹备AI芯片自研。相比这个后起之秀，国内大厂如阿里、百度、字节们更早就跨过了“自研”的大门。此前更是一度传出Sam Altman计划筹

集70000亿美元打造“芯片帝国”，设计与制造通吃。此外，谷歌、亚马逊、微软、Meta也都先后加入了这场“自研热潮”。. 一个明显的信...

- **地球上算力芯片参数汇总、整理、对比- 吴建明wujianming - 博客园** (relevance: 69%)
<https://www.cnblogs.com/wujianming-110117/p/18886018> # 吴建明. ## 微信视频号: sph0RgSyDYV47z6 快手号: 4874645212 抖音号: dy0so323fq2w 小红书号: 95619019828 B站1: UID:3546863642871878 B站2: UID: 3546955410049087 知乎视频: https://www.zhihu.com/people/wujianming_110117/zvideos 知乎: https://www.zhihu.com/people/wujianming_110117. # 地球上算力芯片参数汇总、整理、对比. AI大模型能力的快速提升（如Qwen3、Llama4的多模态升级与逻...
- **不同型号部署DEEPSEEK解析 - AI学院 - 猿界算力** (relevance: 69%) <https://www.apetops.com/AIxueyuan/292.html> 基于 Hopper 架构的 H100，拥有 800GB/s 的 HBM3 显存带宽，显存容量分为 80GB 或 40GB，FP8 算力高达 624 TFLOPS。在 DeepSeek 部署场景下，处理常规自然语言处理任务，若每个请求处理 1000 - 1500 个 Token，单卡每秒可处理 35 - 50 个并发请求。其强劲算力与显存带宽，能迅速读取与计算 DeepSeek 众多模型参数，单卡每秒处理 Token 数可达 3500 - 5000 个。多卡协作时，通过合理资源调度，H100 集群可为大规模用户提供稳定高效的推理服务，适用于对性能严苛的商业应用，如大型企业智能客服系统。. 基于安...
- **NVIDIA B300 vs H200: GPU 参数、性能与DeepSeek 推理能力解析** (relevance: 63%) <https://my.oschina.net/u/9501172/blog/19210157> 根据NVIDIA 官方技术文档，B300 的显存容量是H200 的2 倍，是H100 的3.6 倍；FP8 算力则达到了H200 的9 倍以上。这种代际间的巨大提升，主要得益于
- **英伟达下场，首次优化DeepSeek-R1! B200性能狂飙25倍，碾压H100** (relevance: 63%) <https://finance.sina.com.cn/tech/csj/2025-02-26/doc-inemuzuz3577230.shtml> 在新模型的加持下，B200实现了高达21,088 token每秒的推理吞吐量，相比于H100的844 token每秒，提升了25倍。与此同时，每token的成本也实现了20倍的降低。

4.数据存储

检索关键词: HBM,显存,存储,NVLink

Answer

DeepSeek uses HBM and NVLink for high-bandwidth memory and storage solutions. NVLink enhances data transfer speeds. DeepSeek's architecture leverages advanced memory technologies for efficient AI model operations.

Sources

- **DeepSeek是否有国运级创新？2万字解读与硬核分析V3/R1的架构** (relevance: 69%)
https://h5.ifeng.com/c/vivoArticle/v002zr0oY-_X4A3WNUbrKlpzgu5Jl0B390bwzHn8RaBkqYoM__?vivoBusiness=hiboardnews 当然DeepSeek团队也开发了基于NVLink的HFReduce with NVLink，在将 ... 显存或扩展存储显得尤为重要。我们对此持不同看法，首先要看产品应用
- **强力篇：运行DeepSeek R1 671b满血版的硬件方案 - 百度智能云** (relevance: 60%)
<https://cloud.baidu.com/article/3581948>
- 存储架构设计. 采用三级存储体系：. 热存储：NVMe SSD RAID0（用于实时数据加载）；温存储：SAS HDD阵列（用于检查点存储）；冷存储：对象存储（用于长期数据
- **引领大湾区芯片行业先进封装，佰维存储要做全球存储技术第一梯队！** (relevance: 57%)
<https://hea.china.com/articles/20250328/202503281654098.html> 英伟达4090的显存容量为24G，用的是GDDR6X，不支持NVLink。算力与之相当的A100用的是40/80GB HBM2，显存带宽是前者的1.5倍，NVLink速度高达600GB/s。
- **【大模型DeepSeek v3】4万字超详细解读DeepSeek v3全论文技术 ...** (relevance: 52%)
<https://zhuanlan.zhihu.com/p/22985118565> 管理细粒度内存布局：在分块数据通过IB和NVLink传输到多个领域专家。... 在反向传播过程中，需要从内存中读取这些矩阵，进行解量化、转置、重新量化为128x1的
- **Deepseek与北京大学联合研发出第四代长期以来，AI大模型的运行 ...** (relevance: 50%)
<https://caifuhao.eastmoney.com/news/20260120190902555947620> ... HBM显存——运行一个千亿参数模型通常需要8张价值数万美元的A100显卡，硬件成本高达几十万，GPU也因此成为AI算力的核心载体。但Deepseek V4的核心技术

4.数据加速

检索关键词: FlashAttention,量化,推理优化

Answer

DeepSeek uses FlashAttention for GPU efficiency, quantization, and inference optimization. FlashAttention boosts GPU utilization and reduces memory needs. It enhances transformer model performance significantly.

Sources

- **写在2025.10：DeepSeek开源半年后，transformer的性能优化得怎样 ...** (relevance: 82%) <https://zhuanlan.zhihu.com/p/1957182000264876367> 从训练端看，FlashAttention系列使GPU利用率从35%跃升至75%，FP8/FP4混合精度将内存需求减半，3D并行+ZeRO优化使万亿参数模型训练成为可能。从推理端看，量化
- **DeepSeek-OCR-2性能优化：vLLM张量并行+FlashAttention加速推理 ...** (relevance: 76%) <https://ascendai.csdn.net/69d61cab72111d255bf8418f.html> 本文介绍了如何在星图GPU平台上自动化部署DeepSeek-OCR-2镜像，并利用vLLM张量并行与FlashAttention技术优化其推理性能。该方案能显著提升OCR处理速度，
- **大模型推理加速完全指南：从KV Cache到Speculative Decoding，我踩过的坑和实战方案一张RTX 4 - 掘金** (relevance: 72%) <https://juejin.cn/post/7626606503860781062> # 大模型推理加速完全指南：从KV Cache到Speculative Decoding，我踩过的坑和实战方案. 一张RTX 4090跑70B模型？量化+推理优化真的能做到。这篇把KV Cache、FlashAttention、vLLM、量化全拆一遍，附带实测数据和选型建议。先交代背景：我之前一直觉得大模型推理慢就是显卡不行。直到有次用LLaMA2-7B跑8K上下文，眼睁睁看着生成速度从50 token/s掉到5 token/s——像回到了56K猫时代。后来花了三个月翻了论文、源码、论坛，自己搭了好几个推理框架。这篇文章就是这段时间的总结。不整虚的，直接上原理、数据、踩坑和最终方案。....
- **DeepSeek-V3注意力计算优化终极指南 - 火山引擎ADG 社区** (relevance: 59%) <https://adg.csdn.net/69730cfe437a6b40336b621f.html> DeepSeek-V3作为新一代大语言模型，通过创新的注意力计算优化技术实现了性能飞跃。本文将全面解析其核心优化方案，包括FlashAttention-2高效注意力机制与
- **如何重现 DeepSeek 推理性能突破 - InfoQ** (relevance: 58%) <https://www.infoq.cn/article/apw0hvsbpxwqvfwvots> **DeepSeek 推理系统在实际生产服务中，Prefill 吞吐为 32.2K per node**，Decode 吞吐为 14.8K TPS per node。**在 RTP-LLM 测试中，我们使用 4K input/2K output，** 在 1.6s TTFT 和 50ms ITL 约束下，达到了 Prefill42.6KTPS per node，Decode14.7KTPS per node 的性能。为使 GPU 计算和网络通信互相覆盖，我们完整实现了 Prefill/Decode Micro Batching 方案，并接入了 DeepEP 的 Over...

4.Agent

检索关键词: 智能体,Agent,AutoGPT

Answer

I am an AI system built by a team of inventors at Amazon. AI agents are intelligent systems that can perform tasks autonomously. They use advanced language models and tools to understand and act in the environment.

Sources

- **[北京大学]: DeepSeek内部研讨系列: AI Agent与Agentic AI的原理和应用 - 发现报告** (relevance: 80%) <https://www.fxbaogao.com/detail/4873210> # DeepSeek内部研讨系列: AI Agent与Agentic AI的原理和应用. AI Agent技术正处于爆发期, 其兴起得益于大语言模型 (LLM) 能力的跃升和基础设施的成熟。LLM的突破性进展解决了传统Agent在理解复杂指令、多轮对话、知识运用和推理等方面的瓶颈, 而向量数据库、模型API和服务化、开源框架和社区等基础设施的完善, 则为Agent的开发和迭代提供了有力支撑。AI Agent的核心特质在于其自主性、交互性、主动性、反应性、学习/适应性和目标导向性, 能够持续环境交互、适应并自主完成任务。Agentic AI则更强调AI系统的自主性、目标驱动、环境交互和学习能力, 追求更高阶的智...
- **DeepSeek与开源AI Agent框架: 智能体开发的最优解法** (relevance: 76%) <https://cloud.baidu.com/article/3727221> 简介: 本文深度解析DeepSeek与主流开源AI Agent框架 (如AutoGPT、LangChain、BabyAGI) 的协同开发策略, 从架构适配、性能优化、开发效率三个维度提供可
- **智能体主题分享: DeepSeek、Manus与AI Agent行业现状, 附51页PPT** (relevance: 71%) <https://zhuanlan.zhihu.com/p/1891120824775312729> 在2023年3月, AutoGPT横空出世, 那时人们开始接触AI Agent, 但对其并不了解。7月份, OpenAI的翁丽莲发表了一篇名为《LLM Powered Autonomous AI Agents》的
- **AutoAgent: 无需编程! 接入DeepSeek用自然语言创建和部署AI智能体! 港大开源框架让AI智能体开发变成填空题 - 掘金** (relevance: 57%) <https://juejin.cn/post/7488545861090803739> ## AutoAgent 是什么. AutoAgent 是基于自然语言交互的自动化 LLM智能体框架, 用户无需编程即可创建定制化AI助手。其核心设计理念是将智能体开发转化为对话过程, 通过多代理协作系统自动完成工具创建、任务分解和流程优化。 . ## AutoAgent 的主要功能. ## AutoAgent 的技术原理. ## 如何运行 AutoAgent. 下面将详细介绍如何运行 AutoAgent, 包括安装、配置 API 密钥、以及通过 CLI 模式启动框架。 . ### 安装 AutoAgent. #### AutoAgent 安装. `git clone https://github.com...
- **如何用利用deepseek的API能力来搭建属于自己的智能体-优雅草卓伊凡-腾讯云开发者社区-腾讯云** (relevance: 56%) <https://cloud.tencent.com/developer/article/2527598> ## 如何用利用deepseek的API能力来搭建属于自己的智能体-优雅草卓伊凡. # 如何用利用deepseek的API能力来搭建属于自己的智能体-优雅草卓伊凡. ## 如何用利用deepseek的

API能力来搭建属于自己的智能体-优雅卓伊凡. 了解 DeepSeek 提供的 AI 能力.

DeepSeek 提供强大的 大语言模型（LLM），可用于：. 目前（2024年），DeepSeek 可能提供 API 访问（类似 OpenAI 的 GPT API），你可以：. ##### 示例：Python 调用 DeepSeek API.** url = "https://a...

五、整体技术趋势判断

5.1 战略方向

基于2026年04月12日的检索结果，DeepSeek的AI战略呈现以下特点：

1. 技术路线:
2. 产品布局:
3. 生态建设:

5.2 竞争态势

- vs OpenAI:
- vs Google:
- vs 国内竞品:

5.3 未来展望

预测DeepSeek在未来3-6个月可能的技术/产品动向：

- 1.
- 2.
- 3.

六、参考来源

- Tavily Search 检索结果
- 企业官方博客/公告
- 技术媒体（量子位、机器之心等）
- 学术论文（arXiv）

本报告由 OpenClaw AI 系统自动生成

报告版本: v1.0

生成时间: Sun Apr 12 06:01:45 AM CST 2026