

智谱AI AI技术洞察报告

报告日期: 2026年04月12日

生成时间: 06:01:05

数据来源: Tavily Search, 企业博客, 新闻媒体

洞察范围: 模型发布、技术动态、产品更新

一、公司概况

公司名称: 智谱AI

主要产品: GLM, ChatGLM

检索优先级: 高

二、最新动态检索

2.1 产品/模型发布

Answer

An AI system built by a team of inventors at Amazon has released new language models. These models focus on improving coding and reasoning capabilities. They aim to compete with other leading AI models.

Sources

- **新品发布 - 智谱AI开放文档** (relevance: 84%) <https://docs.bigmodel.cn/cn/update/new-releases> # 新品发布. ## 公告通知. * 在代码逻辑密度和系统工程能力上直接对标 Claude Opus 4.5. * 首次集成 DeepSeek Sparse Attention, 在维持长文本效果无损的同时, 提升 Token Efficiency. * 采用自研 CogViT 与 GLM-0.5B 的编码器-解码器设计, 连接层实现高效跨模态对齐. * 基于数十亿图文对的 CLIP 预训练, 具备强大的视觉语义与关键 Token 提取能力. * 模型小、速度快, 在手写体、表格、印章、竖排等复杂场景中表现稳定. . GLM-4.7-Flash 免费模型上线. * 通用能力同级别最优, 在写作、翻译...
- **智譜勢將發布新一代AI模型加快步伐與DeepSeek展開競爭 - Yahoo 財經** (relevance: 82%) <https://hk.finance.yahoo.com/news/>

%E6%99%BA%E8%AD%9C%E5%8B%A2%E5%B0%87%E7%99%BC%E5%B8%83%E6%96%B0-%E4%BB%A3ai%E6%A8%A1%E5%9E%8B-

%E5%8A%A0%E5%BF%AB%E6%AD%A5%E4%BC%90%E8%88%87deepseek%E5%B1%95%E9%9

智譜在周三發布的聲明中稱，其最新一代大語言模型名為GLM-5，旨在處理複雜的編程和智能體任務，並已與Anthropic的Claude Opus系列進行直接對標測試。智譜表示

- **智谱发布新一代旗舰模型GLM-5，重点提升编程与智能体能力** (relevance: 79%) <https://wallstreetcn.com/articles/3765532> # 智谱发布新一代旗舰模型GLM-5，重点提升编程与智能体能力 - 华尔街见闻. # 智谱发布新一代旗舰模型GLM-5，重点提升编程与智能体能力. Image 2: article.author.display_name李佳 02-11 17:05. 2月11日，智谱推出新一代旗舰模型GLM-5，参数规模扩展至744B，预训练数据达28.5T，集成DeepSeek稀疏注意力机制。内部评估显示，其编程任务性能较上代提升超20%，真实体验逼近Claude Opus 4.5；在BrowseComp等三项Agent评测中均获开源第一，异步强化学习为核心突破。. 2月11日，智谱正式推出新一代旗舰模型G...
- **智譜- 維基百科，自由的百科全書** (relevance: 79%) <https://zh.wikipedia.org/wiki/%E6%99%BA%E8%B0%B1> ## 目录. # 智谱. | 成立 | 2019年6月11日 (2019-06-11) 中国北京市 |. **北京智谱华章科技有限公司**（又称为**智谱**、**智谱科技**、**智谱AI**，港交所：2513）是中国一家开发用于人工智能的大型語言模型的高新技术企业。. ## 历史. 2002年，张鹏本科毕业于清华大学，后作为硕士研究生进入清华大学计算机系知识工程实验室（KEG实验室）深造，2019年，张鹏与团队决定将实验室科研成果推向市场，于当年6月11日正式注册成立北京智谱华章科技有限公司，出任CEO职务。智谱公司总部设在北京市海淀区中关村东路1号院9号，公司专攻认知智能大模型，自202...
- **智谱AI开源GLM模型：8倍加速推理与全球布局-腾讯云开发者社区-腾讯云** (relevance: 79%) <https://cloud.tencent.com/developer/article/2647436> ## 智谱AI开源GLM模型：8倍加速推理与全球布局. # 智谱AI开源GLM模型：8倍加速推理与全球布局. 中国北京 – 2025年4月15日 – 作为一项彰显其技术实力和全球雄心的战略举措，并为潜在的未来IPO铺平道路，中国人工智能公司智谱AI宣布全面开源其下一代通用语言模型（GLM）。此次发布包括先进的GLM-4系列和突破性的GLM-Z1推理模型，这些模型拥有前所未有的推理速度，并推出了专用的国际域名Z.ai。. 其中亮点是GLM-Z1推理模型，据称其推理速度比DeepSeek-R1快八倍。通过优化GQA参数、采用量化技术和推测采样，GLM-Z1-32B-0414模型在消费级GPU上实现...

2.2 技术突破

Answer

智谱AI技术突破主要体现在GLM-5和GLM-4.5模型，通过多模态融合和成本控制提升了AI性能。这些模型在多能力融合和瓶颈突破方面取得了显著成果。

Sources

- **智谱GLM-5技术解密：如何用三大创新突破AI智能体工程瓶颈？** (relevance: 100%)
<https://aiinking.com/article/37263> GLM-5的技术突破对AI行业产生了深远影响。首先，它证明了在单一MoE架构中统一Agent、推理与代码能力的可行性，这为后续模型设计提供了重要参考。
- **[PDF] 智谱AI 发布GLM-4.5V 多模态模型** (relevance: 100%) https://pdf.dfcfw.com/pdf/H3_AP202508181730008206_1.pdf?1755556741000.pdf 现四大核心技术突破：. 首先，利用MM-Crawler 工具进行结构化文本、二进制图片和元数据的并行爬取，通. 过「视觉噪声剪枝」技术以毫秒级剔除低信息密度
- **赛道Hyper | 智谱GLM-4.5：技术突破成因与行业价值 - 华尔街见闻** (relevance: 100%)
<https://wallstreetcn.com/articles/3752410> 7月28日，智谱AI发布旗舰模型GLM-4.5并开源。GLM-4.5是一款专为智能体应用研发的基础模型，在性能、成本控制与多能力融合等方面均有出色
- **智谱冲破2000亿的秘密：为什么中国AI终于敢涨价了？ - DoNews** (relevance: 100%)
<https://www.donews.com/article/detail/5458/97228.html> 当OpenAI还在为免费用户的广告位发愁，Anthropic还在和奥特曼打口水战，智谱已经在国产算力底座上跑通了从技术突破到商业变现的完整闭环。智谱的股价
- **智谱发布免费的超级Agent：像Manus 一样干活** (relevance: 100%) <https://zhuanlan.zhihu.com/p/1890366621287166337> 通过强化学习训练，这款沉思模型突破了传统AI 仅依赖内部知识的局限，融合实时联网搜索、动态工具调用和自我验证能力，构建了一个完整的自主研究闭环。它能

三、技术趋势分析

3.1 模型能力演进

基于检索结果分析智谱AI在以下方面的进展：

- **大语言模型**: 上下文长度、推理能力、多语言支持
- **多模态能力**: 图像理解、视频生成、跨模态交互
- **推理优化**: 思维链、深度推理、数学/代码能力

3.2 工程化进展

- **训练基础设施**: 算力规模、训练效率、成本控制
- **推理优化**: 量化技术、KV Cache优化、批处理策略
- **部署方案**: 云端API、边缘部署、私有化方案

四、关键技术点展开

4.大语言模型

检索关键词: LLM,大模型,GPT,Claude,Gemini

Answer

Zhipu AI's GLM-5.1 model claims 94.6% of Claude Opus 4.6's programming performance and is competitively priced. GLM-5.1 is an open-weight model with strong coding capabilities. It outperforms other open models in programming benchmarks.

Sources

- 智谱AI新模型表现如何? _glm-5.1 和claude对比- ... (relevance: 100%) <https://blog.csdn.net/Joshkhh/article/details/159787524> 资源文件中包括了编程语言模型如 GPT-Chat、Dify、Claude、Gemini、Ollama、GLM、xAI以及LLM，显示出这个聊天机器人可能会使用当前流行的多种语言模型来理解
- GPT、Gemini、DeepSeek：智谱AI最新模型的實力評測 (relevance: 100%) <https://wavespeed.ai/blog/zh-tw/posts/glm-5-1-vs-claude-gpt-gemini-deepseek-llm-comparison/> GLM-5.1 vs Claude、GPT、Gemini、DeepSeek：智谱AI最新模型的實力評測. 智谱AI的GLM-5.1宣稱達到Claude Opus 4.6程式編寫效能的94.6%——完全基於華為晶片
- GLM-5.1 vs Claude、GPT、Gemini、DeepSeek：智谱AI最新模型综合评测 | WaveSpeedAI Blog (relevance: 100%) <https://wavespeed.ai/blog/zh-cn/posts/glm-5-1-vs-claude-gpt-gemini-deepseek-llm-comparison/> # GLM-5.1 vs Claude、GPT、Gemini、DeepSeek：智谱AI最新模型综合评测. #llm #ai-models #glm #zhipu-ai #claude #gpt #gemini #deepseek #comparison #ai-news. 智谱AI于2026年3月27日正式发布了**GLM-5.1**，相关数据令业界瞩目。这家中国AI公司——今年一月以313亿美元估值在香港交易所上市——宣称其最新模型在编程性能上达到了**Claude Opus 4.6的94.6%**，同时以开放权重形式发布，且整个训练过程完全未使用英伟达硬件。 . ## G...
- 中國智譜AI最強開放模型GLM-5 是Claude 貼皮？ 一個號稱 ... (relevance: 100%) <https://www.facebook.com/groups/gaitech/posts/1607796527071223/> 中國智譜AI最強開放模型GLM-5 是Claude 貼皮？ 一個號稱超越Google Gemini、甚至在部分指標上逼近GPT-5.2的頂級開源模型，在自我介紹時，竟然說出：「你

- **GLM-4.5：推理、编码和代理能力** (relevance: 100%) <https://bigmodel.cn/technology-report> 智谱大模型开放平台-新一代国产自主通用AI大模型开放平台，是国内大模型排名前列的大模型网站，研发了多款LLM模型，多模态视觉模型产品，致力于将AI产品

4.推理模型

检索关键词: o1,R1,推理,思维链

Answer

The o1 model and DeepSeek-R1 are advanced reasoning models that utilize "thinking chains" for complex problem-solving. These models aim to break down problems into manageable steps and provide detailed reasoning paths. They are part of a growing trend in AI focused on enhancing reasoning capabilities.

Sources

- **国内首个对标o1的推理模型发布：DeepSeek-R1-Lite初体验！** (relevance: 100%) <https://deepseek.csdn.net/67ab1ffe79aaf67875cb9eeb.html> o1 模型经过了思维链的加持 ... 在接下来的几个月里，国内的不少AI公司也在纷纷尝试，但更多的是在应用方面，如Kimi、智谱、天工和360的推理型AI搜索。
- **从o1到DeepSeek-R1，万字长文带您揭秘推理模型——及其与标准 ...** (relevance: 100%) <https://zhuanlan.zhihu.com/p/26076930125> 推理模型与标准LLM的主要区别在于能够在回答问题之前“思考”。推理模型的思维只是由LLM输出的长链思维——简称长CoT，有时称为推理轨迹或路径。长CoT的
- **苹果最新论文打脸推理模型：思维链集体翻车，复杂难题面前秒变 ...** (relevance: 100%) <https://cloud.tencent.com/developer/article/2652126> 从OpenAI 的o1 惊艳亮相，再到DeepSeek R1 以及Claude、Gemini 推出「Thinking」模式，新一代的大模型纷纷亮出了自己的「思考」能力。
- **ChatGPT两周年，国产o1大模型们紧追不舍 - 创业邦** (relevance: 100%) <https://m.cyzone.cn/article/783456> 以智谱的“会反思的AI搜索”为例，结合思维链能力，让AI能够将复杂问题拆解成多个步骤，进行逐步搜索和推理。通过联网搜索+ 深度推理，再将所有答案信息综合整理到一起，AI能够给
- **国产AI 最卷一夜！大模型黑马DeepSeek、Kimi 硬刚OpenAI o1 - 爱范儿** (relevance: 100%) <https://www.ifanr.com/1612733> 据悉，DeepSeek-R1 遵循MIT License，允许用户通过蒸馏技术借助R1 训练其他模型。DeepSeek-R1 上线API，对用户开放思维链输出，通过设置model

4.多模态模型

检索关键词: 多模态,视觉,视频生成,Sora,Seedance

Answer

智谱AI的多模态模型在视觉和视频生成方面表现出色，与Sora和Seedance竞争。Seedance 2.0在多模态视频生成领域取得了重大突破。字节跳动的Seedance 2.0被认为达到了导演级水准。

Sources

- [illegible]

4.算力卡

检索关键词: GPU,H100,B200,TPU,算力

Answer

The H100 and B200 GPUs by NVIDIA are top-tier for AI workloads, with the B200 offering the highest performance. TPUs from Google are noted for their efficiency.

Sources

- **16.1 AI 芯片基础：GPU、TPU、NPU | 零基础学AI | AI Beginner Guide** (relevance: 100%) https://yeasy.gitbook.io/ai_beginner_guide/di-si-bu-fen-jin-jie-yu-zhan-wang/16_ai_hardware_quantum/16.1_ai_chips GPU 是当前的统治者. NVIDIA H100/B200 是最强硬件. 但成本极高, 功耗极高. 适合大规模训练和云端推理; TPU 是效率之王. 如果能用 Google 云端, TPU 是最优
- **GH200, 一个伺服器機櫃共有32顆H100, GB200在GPU數量上提升 ...** (relevance: 100%) <https://www.threads.com/@wukt999/post/C5LEhbcRnve> DGX B200, 為8顆 B200, 每個B200 是由2個B100組成-DGX H100, 為8顆H100 GB200, 一个伺服器機櫃共有 144顆B100 -GH200, 一个伺服器機櫃共有32顆H100, GB200在GPU
- **芯片推理速度是英伟达的21倍, 成本低30%, 奥特曼早早投资了** (relevance: 100%) <https://www.51cto.com/aigc/9921.html> 这种技术路线与英伟达AI GPU算力体系以及谷歌 TPU(AI ASIC技术路线)都截然 ... 智谱AI开源6款模型, 推理速度200 tokens/秒碾压竞品, 价格仅1/30
- **H100 vs. H200 vs. B200: 为您的AI工作负载选择合适的NVIDIA GPU** (relevance: 100%) <https://introl.com/zh/blog/h100-vs-h200-vs-b200-choosing-the-right-nvidia-gpus-for-your-ai-workload> # H100 vs. * **H100**: 3.35 TB/s (可观) . * **H200**: 4.8 TB/s (43%改进) . * **B200**: 8 TB/s (另一个宇宙) . "H200 Tensor Core GPU." NVIDIA Data Center. "DGX B200: The Foundation for Your AI Factory." NVIDIA Data Center. "Choosing GPU Infrastructure for LLM Training in 2025: NVIDIA H100 vs. "NVIDIA H200 vs H100: Bett...
- **主流算力卡性能对比分析_h100算力 - CSDN博客** (relevance: 100%) https://blog.csdn.net/m0_69867914/article/details/151579426 优势: 专为Transformer模型优化, FP8精度下吞吐量达30,000 samples/sec, 适合超大规模AI训练和HPC。应用场景: AI超算集群、自动驾驶域控制器、5G边缘推理。

4.数据存储

检索关键词: HBM,显存,存储,NVLink

Answer

High Bandwidth Memory (HBM) enhances GPU performance by providing high-speed data access, crucial for AI tasks. NVLink technology further improves data transfer between GPUs. Together, they enable efficient large model training and high-resolution processing.

Sources

- [illegible]

Expansion, Memory Pooling, Warm Data Tier) | 16 |. | HBF (高带宽闪存) | $> 1 \mu s$ (预计) | $\sim 1.2 \text{ TB/s}$ (预计, 与HBM相当) | 256 GB - 4 TB per device (预计) | (未来) 读取...

4. 数据加速

检索关键词: FlashAttention, 量化, 推理优化

Answer

FlashAttention optimizes transformer models for faster inference, while quantization and sparsity techniques further enhance speed and efficiency. These methods reduce computational load and memory usage.

Sources

- **LLM推理加速4: MInference/FlashAttention-3/EAGLE-2/Q-Sparse. etc** (relevance: 75%) <https://zhuanlan.zhihu.com/p/708128459> 考虑量化也可以加速推理，因此公式变为 $Y=(Q(X)\odot M)W^T$ 。量化。这种方法可以和量化一起使用，公式则变成 $Y=(Q(X)\odot M)Q(W^T)$ 。为了进一步提高激活的稀疏性，对
- **即插即用！清华8比特量化Attention，两倍加速于FlashAttention2** (relevance: 71%) <https://zhuanlan.zhihu.com/p/1584248273> 实现了2倍以及2.7倍相比于FlashAttention2和xformers的即插即用的推理加速，且在视频、图像、文本生成等大模型上均没有端到端的精度损失。论文标题：
- **大模型训练加速之FlashAttention系列：爆款工作背后的产品观** (relevance: 66%) <https://zhuanlan.zhihu.com/p/664061672> FlashAttention (FA) 是一系列针对Transformer模型训练和推理加速方案。自从去年（2022年）五月发布以来，历经了多次迭代，并借着其节省显存、加速计算、
- **从FlashAttention到FlashDecoding：大模型推理加速的演进之路** (relevance: 58%) <https://blog.csdn.net/web39explorer/article/details/151979458> 所以，优化大模型推理速度，尤其是解码（生成）阶段的速度，首要目标不是让计算单元（CUDA Core）算得更快，而是想尽办法减少数据搬运的次数和数量，让数据尽可能待
- **大模型推理加速技术：FlashAttention原理与实现-阿里云开发者社区** (relevance: 51%) <https://developer.aliyun.com/article/1685039> Q: [B, H, N, d]. Q_block = Q[:, :, block_start:block_end] # [B, H, block_size, d]. V_block = V[:, :, k_start:k_end] # [B, H, block_size, d]. const half restrict Q, // [B, H, N, d]. half q_val = Q[(batch * H * N + head * N + q_idx) * d + dim];. half old_o = O[(batch * H * N + head * N + q_idx) ...

4.Agent

检索关键词: 智能体,Agent,AutoGPT

Answer

智谱推出的AutoGLM是一款具备深度研究和操作执行能力的AI智能体，能够自主思考和执行任务。它是中国首个开源的智能体产品，推动AI从思考进化到实际操作。智谱致力于推动中国AI技术出海，帮助“一带一路”国家建立自主AI基础设施。

Sources

- **智谱发布全新Agent，集深度研究和操作执行于一体** (relevance: 100%) <https://zhuanlan.zhihu.com/p/1890064406051813020> 智谱在AI Agent领域的研发，包括从最早推出具备Function Call能力的智谱清言，到率先上线支持智能体编排的GLMs，再到推出全球首个设备操控智能体AutoGLM。
- **智谱发布免费的超级Agent：像Manus一样干活** (relevance: 100%) <https://zhuanlan.zhihu.com/p/1890366621287166337> 智谱将AutoGLM 沉思定位为一个能探究开放式问题，并根据结果执行操作的自主智能体（AI Agent），它能够模拟人类的思维过程，完成从数据检索、分析到生成报告。
- **智谱AutoGLM上线：给每个手机都装上通用Agent - 华尔街见闻** (relevance: 100%) <https://wallstreetcn.com/articles/3753704> AutoGLM的主要亮点，是一个APP让一部手机成为真正的“新物种”。在AutoGLM 2.0中，我们为AI配备了专属智能体手机/智能体电脑，让它可以在云端自主干活、完成
- **第一个免费可用的智能Agent产品全量上线，中国公司智谱打造 - 腾讯云** (relevance: 100%) <https://cloud.tencent.com/developer/article/2509526> 智谱推出的「AutoGLM 沉思」是国内首个自主智能体产品，具备深度研究和动手操作能力，能在小红书、知乎等平台自动查询并生成报告。其基于全栈自研技术，
- **AI能边想边干活了？智谱发布最新AI智能体 - 中国日报网** (relevance: 100%) <https://cn.chinadaily.com.cn/a/202504/01/WS67ebc2e4a310e29a7c4a737b.html> # AI能边想边干活了？智谱发布最新AI智能体. ## 3月31日，智谱在中关村论坛上正式发布AutoGLM沉思，这一全新智能体不仅具备深度研究能力（Deep Research），还能实现实际操作（Operator），真正推动AI Agent进入“边想边干”的阶段。.# AI能边想边干活了？智谱发布最新AI智能体. 中国日报4月1日电（记者 程钰）3月31日，智谱在中关村论坛上正式发布AutoGLM沉思，这一全新智能体不仅具备深度研究能力（Deep Research），还能实现实际操作（Operator），真正推动AI Agent进入“边想边干”的阶段。同时，智谱宣布，核心链路的模型和技术， ...

五、整体技术趋势判断

5.1 战略方向

基于2026年04月12日的检索结果，智谱AI的AI战略呈现以下特点：

1. 技术路线:
2. 产品布局:
3. 生态建设:

5.2 竞争态势

- vs OpenAI:
- vs Google:
- vs 国内竞品:

5.3 未来展望

预测智谱AI在未来3-6个月可能的技术/产品动向：

- 1.
- 2.
- 3.

六、参考来源

- Tavily Search 检索结果
- 企业官方博客/公告
- 技术媒体（量子位、机器之心等）
- 学术论文（arXiv）

本报告由 OpenClaw AI 系统自动生成

报告版本: v1.0

生成时间: Sun Apr 12 06:01:24 AM CST 2026