

阿里巴巴 AI技术洞察报告

报告日期: 2026年04月12日

生成时间: 06:00:23

数据来源: Tavily Search, 企业博客, 新闻媒体

洞察范围: 模型发布、技术动态、产品更新

一、公司概况

公司名称: 阿里巴巴

主要产品: 通义千问, Qwen

检索优先级: 高

二、最新动态检索

2.1 产品/模型发布

Answer

Alibaba released its AI model Qwen 2.5-Max, claiming it surpasses DeepSeek V3. The company has also released three closed-source AI models to boost business monetization. The latest model, Qwen 3.6-Plus, was announced in early April 2026.

Sources

- 阿里巴巴发布AI模型 声称超越DeepSeek (relevance: 88%) <https://www.voachinese.com/a/alibaba-releases-ai-model-it-claims-surpasses-deepseek-v3-20250129/7955186.html> ## 无障碍链接. ##### 关注我们. 中国时间 22:09 2026年4月10日 星期五. # 阿里巴巴发布AI模型 声称超越DeepSeek. 阿里巴巴透过旗下的阿里云, 发表了自家的AI语言模型通义千问Qwen 2.5-Max超大规模MoE模型, 甚至号称测试表现上优于DeepSeek V3. (美联社: 2024年5月14日). 阿里巴巴透过旗下的阿里云, 发表了自家的AI语言模型通义千问Qwen 2.5-Max超大规模MoE模型, 甚至号称测试表现上优于DeepSeek V3. (美联社: 2024年5月14日). 中国科技公司阿里巴巴星期三(1月29日)发布了其通义千问“Qwen 2.5”人工...

- **阿里巴巴发布第三款闭源AI模型加速业务变现 - 新浪财经** (relevance: 86%) <https://finance.sina.com.cn/roll/2026-04-03/doc-inhtetzf3832412.shtml> 阿里巴巴三天内发布第三款自研AI模型，加大从核心AI服务获利力度。4月2日发布新一代大语言模型Qwen3.6-Plus，此前还发布图像生成平台升级版和多模态
- **阿里巴巴发布第三款闭源AI模型，加速业务变现_凤凰网** (relevance: 86%) <https://i.ifeng.com/c/8s1HhJLIjsA> # 阿里巴巴发布第三款闭源AI模型，加速业务变现. 2026年04月03日 11:55:59 来自北京市. 这家电商巨头周四发布了新一代大语言模型Qwen3.6-Plus。此前，该公司刚发布图像生成平台的升级版，以及一款能够理解语音、图像和文本等多模态输入的模型。这三款模型均为闭源，意味着开发者无法下载和访问其代码，也无法按需对其技术进行二次开发。此举与MiniMax Group Inc.和DeepSeek等中国开发者的常见做法形成对比，这些公司倾向于开源模型，以促进使用与普及。阿里巴巴的通义千问系列模型之所以成为全球最受欢迎的AI模型之一，部分原因在于其开放性。但这家互联网公司正推动...
- **阿里巴巴發布第三款閉源AI模型加速業務變現 - MSN** (relevance: 84%) <http://www.msn.com/zh-tw/money/topstories/%E9%98%BF%E9%87%8C%E5%B7%B4%E5%B7%B4%E7%99%BC%E5%B8%83%E7%AC%AC%E5%A0%E9%80%9F%E6%A5%AD%E5%8B%99%E8%AE%8A%E7%8F%BE/ar-AA200sW2> 【彭博】-- 阿里巴巴在三天內發布了第三款自研人工智能模型，凸顯公司正加大力度從其核心AI服務中獲利。這家中國電商巨頭周四發布了新一代大語言模型Qwen3.6-Plus。
- **阿里巴巴宣布重大AI模型升級 在DeepSeek下一代平台發布前搶占先機** (relevance: 83%) <https://hk.finance.yahoo.com/news/%E9%98%BF%E9%87%8C%E5%B7%B4%E5%B7%B4%E5%AE%A3%E5%B8%83%E9%87%8D%E5%9C%A8deepseek%E4%B8%8B%E4%BB%A3%E5%B9%B3%E5%8F%B0%E7%99%BC%E5%B8%83%E5%89%8D%E6%90%B6%E5> # 雅虎香港財經. # 阿里巴巴宣布重大AI模型升級 在DeepSeek下一代平台發布前搶占先機. 阿里巴巴周一在聲明中表示，最新版本的Qwen旨在支持人工智能代理任務，能夠理解文本、照片和視頻輸入。聲明補充稱，該模型能分析長達兩小時的視頻內容。在農曆新年臨近的幾周內，從字節跳動到智譜、稀宇科技，眾多競爭對手紛紛推出模型升級，阿里巴巴的Qwen3.5亦加入這場升級浪潮。這些公司旨在搶占先機，以應對DeepSeek在開創性R1模型發布周年之際即將推出的備受期待的新版本，R1曾於2025年顛覆全球人工智能行業標準。阿里巴巴及其同行還瞄準了為期一周的春節假期，歷史經驗表明，這個時間段對中國消費互...

2.2 技术突破

Answer

Alibaba has made significant breakthroughs in AI, including the development of advanced language models like Qwen3-Max and innovative visual-language models like Qwen3-VL. These advancements have positioned Alibaba as a leader in AI technology.

Sources

- **阿里巴巴蔡崇信：中国科技成果将惠及全球 - 人民网** (relevance: 100%) <http://finance.people.com.cn/n1/2026/0323/c1004-40687106.html> 目前，阿里巴巴在云计算、芯片、大模型、AI应用方面的全栈AI布局正在转化为核心竞争力。根据相关报道，阿里自研GPU芯片已实现规模化量产，支持了自动驾驶、
- **阿里巴巴在全球 AI 技術競爭中的地位和優勢 | 科技 | 鉅亨號 | Anue鉅亨** (relevance: 100%) <https://hao.cnyes.com/post/200582> # 阿里巴巴在全球 AI 技術競爭中的地位和優勢. 1.1 阿里雲雲端 AI 體系的整體架構. 1.2 平頭哥 AI 晶片的技術突破. **平頭哥半導體在 AI 晶片領域實現多項重大突破**. 2025 年 9 月 16 日，央視新聞聯播披露了平頭哥 PPU 晶片的關鍵技術參數，標誌著中國在人工智慧核心硬體領域取得重要突破。 **Qwen3-VL 在 32 項核心能力測評中超越國際先進水平**。阿里開放原始碼的 Qwen3-VL 模型在視覺感知和多模態推理方面實現重大突破，在 32 項核心能力測評中超過 Gemini2.5-Pro 和 GPT-5。同時，Qwen3-VL 大幅提升了視覺 Age...
- **从更高到更好揭秘2021阿里双11背后的技术亮点 - 阿里云开发者社区** (relevance: 100%) <https://developer.aliyun.com/article/802555> 磐久服务器新一代硬件和技术全新应用于双11，提供行业领先的计算及存储生产力，场景化性能提升30%以上。今年云栖大会上，阿里巴巴发布自研磐久服务器系列，
- **清华大学联手阿里巴巴重大突破：让AI生成图像变得更快更聪明的全新 ...** (relevance: 100%) <https://www.techwalker.com/2025/1208/3174881.shtml> 清华大学和阿里巴巴联合研究团队提出了一种名为"反向表示对齐"的创新方法，显著改进了正规化流这类AI图像生成模型。通过在生成过程而非编码过程中注入
- **Alibaba Cloud Unveils Strategic Roadmaps for the Next Generation AI Innovations** (relevance: 98%) https://www.alibabacloud.com/tc/press-room/alibabacloudunveilsstrategicroadmaps?_p_lc=1 crystal.liu@alibaba-inc.com. # 阿里雲發佈下一代AI創新策略路線圖. ##### 推出Qwen3-Max：阿里巴巴迄今最強的大語言模型. 阿里巴巴正式推出迄今最大、參數量突破1萬億的**Qwen3-Max**旗艦級大語言模型。分為指令（Instruct）和推理（Thinking）兩大版本，該模型在廣泛基準測試中展現出色效能，尤以代碼生成與智能體能力方面的表現最為出眾。在指令模式下，SWE-Bench（大語言模型處

理現實世界軟件問題的權威評估基準）對該模型的評分為69.6分，與部份頂尖閉源模型不相伯仲；在Tau2-Bench（對話智能體的評估基準）的評測中亦表現卓越，...

三、技术趋势分析

3.1 模型能力演进

基于检索结果分析阿里巴巴在以下方面的进展：

- **大语言模型:** 上下文长度、推理能力、多语言支持
- **多模态能力:** 图像理解、视频生成、跨模态交互
- **推理优化:** 思维链、深度推理、数学/代码能力

3.2 工程化进展

- **训练基础设施:** 算力规模、训练效率、成本控制
- **推理优化:** 量化技术、KV Cache优化、批处理策略
- **部署方案:** 云端API、边缘部署、私有化方案

四、关键技术点展开

4.大语言模型

检索关键词: LLM,大模型,GPT,Claude,Gemini

Answer

Alibaba's large language model, Tongyi Dasheng, competes with LLMs like GPT, Gemini, and Claude. Gemini is a powerful multimodal AI model developed by Google DeepMind. The latest models show significant advancements in language understanding and reasoning.

Sources

- **2026年十大最佳大型语言模型（LLM） - Botpress** (relevance: 100%) <https://botpress.com/zh-cn/blog/best-large-language-models> Abstract illustration with colorful shapes. * 最适合对话的LLM（如GPT-4o和Claude Sonnet 4）擅长处理细腻的对
话、上下文保持和语气切换，而以推理为主的模型（如DeepSeek R1和Gemini 2.5 Pro）则
能应对复杂的多步任务。 . ### OpenAI. ### Anthropic. ### Google DeepMind. ###

DeepSeek. | 模型 | 语音支持 | 上下文窗口 | 费用（每百万tokens） |. | Claude 4 Sonnet | ☒
200K | 输入\$3 / 输出\$15 |....

- **在科研与项目开发中如何高效调用国内国外 AI 大语言模型 LLM API-阿里云开发者社区** (relevance: 100%) <https://developer.aliyun.com/article/1704566> # 在科研与项目开发中如何高效调用国内国外 AI 大语言模型 LLM API. 这些并不是个例，而是每一个试图将大语言模型（LLM API）集成到实际科研流程或生产级产品中的开发者都会遇到的“隐形墙”。在 Demo 阶段，我们关注的是 Prompt 的技巧、思维链（CoT）的设计，是模型能不能答对这道数学题；但在 Engineering 阶段，我们实际上在与**大模型API**的基础设施做斗争。稳定性、延迟、并发控制、成本审计，这些枯燥但至关重要的指标，决定了一个 AI 项目是仅仅停留在 PPT 上，还是能真正服务于千万用户。本文将剥离掉 AI 那些光鲜亮丽的概念，从纯粹的“工程与资源调度...
- **阿里巴巴通义大模型包含哪些？ - 飞书文档** (relevance: 100%) <https://docs.feishu.cn/v/wiki/JyTFwDoTOiWqBPkfSYScbGDjnBh/aj...> 大模型。5.Gemini. Gemini 是最新、功能最强大的大型语言模型(LLM)，由Google 子公司Google Deepmind 团队开发，Gemini 是一个“原生多模态AI 模型”，它被从头开始设计
- **Yi-Large 赶上了GPT-4，超越了Claude 3 Opus 和Gemini 1.5 pro 在 ...** (relevance: 100%) https://www.reddit.com/r/singularity/comments/1cyoun2/yilarge_catching_up_to_gpt4_overtakes_claude_3/?tl=zh-hans 这部分是竞技场系统的遗留问题——目前的模型足够好，可以处理大多数随意的提示，达到类似的水平，并且ELO 评分并不是线性的。
- **对比明明白白3大顶级模型-GPT-5.2/Gemini 3/Claude Opus 4.5! 老金 ...** (relevance: 100%) <https://juejin.cn/post/7584297353419833344> 2、之前开源过的单窗口联合使用方法- 用最少的成本，做最有效的事。这里包含了老金的开源地址，可以查看到CLaude Code 内怎么联合使用Claude、Gemini、GPT。

4.推理模型

检索关键词: o1,R1,推理,思维链

Answer

Alibaba's QwQ-Max model competes with DeepSeek's R1 and OpenAI's o1 in advanced reasoning tasks. It supports deep thinking and internet search, showcasing complete reasoning chains. The model aims for strong, versatile problem-solving in math and programming.

Sources

- **RBench公布最新大模型推理能力排行榜，GPT-5以微弱优势排名第一 — Jittor** (relevance: 76%) <https://cg.cs.tsinghua.edu.cn/jittor/news/2025-09-02-18-22-00-00-RBench/> # RBench公布最新大模型推理能力排行榜，GPT-5以微弱优势排名第一. ## RBench公布最新大模型推理能力排行榜，GPT-5以微弱优势排名第一. 大模型的智能正在进入一个新的衡量维度：推理。与单纯的知识记忆和复述不同，真正的智能体现在应对复杂问题时能否进行缜密的分析、严谨的推导和明智的决策——这正是推理能力的核心，也是模型在数学、编程、科学问答等高级任务中展现类人思维的关键。过去一年，整个行业见证了推理能力的“寒武纪大爆发”。这股浪潮由OpenAI在2024年9月推出的o1模型点燃，并迅速席卷全球。仅仅数月后，2025年1月，DeepSeek R1的横空出世，让开源大模型第一次...
- **旺精通~阿里START：自学工具调用的长思维链推理模型** (relevance: 72%) <https://zhuanlan.zhihu.com/p/32078743531> 随后，以OpenAI-o1 (OpenAI, 2024b) 和 DeepSeek-R1 (DeepSeek-AI, 2025) 为代表的强化学习取得突破，建立了一种名为长思维链的新范式，该范式模仿人类的认知策略，
- **阿里巴巴公布下一代推理模型 与DeepSeek等竞争 | 联合早报** (relevance: 72%) <https://www.zaobao.com.sg/realtime/china/story20250225-5927991> user%20--%3e%3cdefs%3e%3cstyle%3e%20.st0,%20.st1%20{%20fill:%20none;%20}%20.st1%20{%20stroke:%20%236f6f6f;%20stroke-width:%202px;%20}%20.st2%20{%20fill:%20%236f6f6f;%20fill-rule:%20evenodd;%20}%20.st3%20{%20clip-path:%20url(%23clippath);%20}%20%3c/style%3e%3cclipPath%20id='clippath'%3e%3crect%20clas...
- **类o1系列模型大盘点：QwQ - DeepSeek技术社区** (relevance: 59%) <https://deepseek.csdn.net/67ab1e2879aaf67875cb9ab6.html> DeepSeek R1 系列模型使用强化学习训练，推理过程包含大量反思和验证，思维链长度可达数万字。该系列模型在数学、代码以及各种复杂逻辑推理任务上，取得了
- **DeepSeek 开源R1 系列推理模型，性能对标OpenAI o1** (relevance: 52%) <https://developer.aliyun.com/article/1650188> DeepSeek R1-Zero 是一款基于纯强化学习的开源推理模型，无需监督微调数据，支持多任务泛化与自我进化，适用于数学推理、代码生成等场景。

4.多模态模型

检索关键词: 多模态,视觉,视频生成,Sora,Seedance

Answer

Alibaba's Wan 2.6 is a leading AI video generation model, often seen as a top alternative to Sora. Seedance, developed by ByteDance, competes in the same field. Both models focus on multi-modal capabilities for video creation.

Sources

- **林俊瑒点赞，干翻字节Seedance 2.0的“欢乐马”模型，阿里造？** (relevance: 100%) <https://finance.sina.cn/stock/jdts/2026-04-09/detail-inhtxqku0738735.d.html?oid=%E5%A4%A7%E7%90%86%E5%A4%96%E5%9B%B4%E5%A5%B3%E5%8C%85%E5%A4%9C>
张迪目前是阿里淘天集团未来生活实验室的负责人，聚焦多模态大模型等前沿技术。 ... 上个月，OpenAI宣布关停上线Sora，退出AI视频生成赛道。这个曾经
- **Seedance vs Sora vs Kling：AI 视频生成模型深度对比** (relevance: 100%) <https://developer.aliyun.com/article/1711714> Sora 的核心创新在于引入"世界模型"(World Model)概念。它不仅仅是在像素层面生成视频,而是通过大规模预训练学习物理世界的运行规律——重力、光影、材质
- **神秘模型屠榜多日、碾压Seedance 2.0，背后竟是阿里大招 ...** (relevance: 100%) <https://www.hstong.com/news/detail/26041020352508837> 近日，这样一款名为 HappyHorse-1.0 的神秘模型悄然登顶Artificial Analysis 视频模型排行榜，排在了 Seedance 2.0、Kling 3.0 以及目前所有其他视频生成
- **国产模型悄然打赢一场多模态战役** (relevance: 100%) <https://eu.36kr.com/zh/p/3739204925764102> Seedance 2.0凭借它的强大能力，已经被人们视为未来制作电影的“神器”，而它现在唯一存在的尴尬之处，就在于缺少配音。音频生成看起来比视频生成要简单，但给
- **AI视频生成后Sora时代：Wan 2.6、Seedance与Kling重塑格局_人工智能_xyghehehehe-AtomGit开源社区** (relevance: 100%) <https://gitcode.csdn.net/69d1b9bd54b52172bc67097c.html> # logo AtomGit开源社区. ### AtomGit开源社区. | 功能 | Wan 2.6 | Seedance | Kling | Vidu Q3 | Pika |. | 开发商 | 阿里巴巴 | 字节跳动 | 快手 | — | Pika Labs |. 阿里巴巴 Wan 2.6 —— 综合最强，Sora最佳继任者. Wan 2.6是目前功能最完整的AI视频生成模型，被多个评测平台认定为"Sora的最佳替代方案". `# Wan 2.6 API调用示例（通过WaveSpeedAI）. "https://api.wavespeed.ai/api/wan/v2/text-t...

4.算力卡

检索关键词: GPU,H100,B200,TPU,算力

Answer

Alibaba's GPU, H100, B200, and TPUs have high computational power for AI tasks. These chips compete with global leaders like Nvidia and AMD. Alibaba's GPUs aim to bridge the performance gap with advanced designs and manufacturing.

Sources

- **地球上算力芯片参数汇总、整理、对比 - 吴建明wujianming - 博客园** (relevance: 76%) <https://www.cnblogs.com/wujianming-110117/p/18886018> # 吴建明. ## 微信视频号: sph0RgSyDYV47z6 快手号: 4874645212 抖音号: dy0so323fq2w 小红书号: 95619019828 B站1: UID:3546863642871878 B站2: UID: 3546955410049087 知乎视频: https://www.zhihu.com/people/wujianming_110117/zvideos 知乎: https://www.zhihu.com/people/wujianming_110117. # 地球上算力芯片参数汇总、整理、对比. AI大模型能力的快速提升 (如Qwen3、Llama4的多模态升级与逻辑推理能力)...
https://www.cnblogs.com/wujianming-110117/p/18886018
- **一张图说清: H100、H200、B200 到底该怎么选? 最近发现B200出来了以后, 很多有算力需求的团队都蠢蠢欲动要上B - 掘金** (relevance: 68%) <https://juejin.cn/post/7586892413890068526> | NVLink | 第四代 (900 GB/s) | 第四代 | 第五代 (1.8 TB/s) |. H200 不是算力升级, 而是显存与带宽升级, 解决“跑不动”的问题; . B200 则是一次架构级跃迁, 面向千卡集群、下一代 AI 工厂设计。 . | <7B 参数, 微调/推理 | A10 / L4 / RTX 6000 Ada | 小模型对算力要求低, A10/L4 成本更低; H100 属性能过剩, 仅在统一集群时考虑 |. | 7B-30B, 全参训练 | H100 | 在 FP8 + 梯度检查点 + ZeRO 下可高效训练PyTorch/TensorFlow 生态最成熟, 调试工...
https://juejin.cn/post/7586892413890068526
- **[PDF] AI系列专题报告（一） - 算力** (relevance: 68%) https://pdf.dfcfw.com/pdf/H3_AP202506121689781660_1.pdf AI系列专题报告（一） 算力：算力基建景气度高，国产AI芯片发展势头良好 证券研究报告 分析师： 陈福栋S1060523070003（证券投资咨询） 分析师： 闫磊 S1060519100002（证券投资咨询） 平安证券研究所电子信息团队 2025年6月12日 请务必阅读正文后免责条款 电子行业强于大市（维持） 核心摘要 ☑AIGC蓬勃发展，对底层智能算力产生强劲需求。行业前期，训练是算力需求的主力，大量大模型训练需要海量算力支撑。2024年末，DeepSeek重磅发布，其轻量化、低成本、高性能特征大幅拉低了AI应用门槛，有望成为各类推理场景爆发的契机，推理算力市场需求潜力巨大。在此背景下...
- **揭秘！阿里隐藏大招曝光，一文读懂超火GPU** (relevance: 64%) <https://eu.36kr.com/de/p/3658910978372356> # 阿里放出隐藏大招？一文读懂大火的GPU. 近期，阿里又放出一枚重磅炸弹：阿里巴巴集团已决定，支持旗下芯片公司“平头哥半导体”未来独立上市。 . 据说，平头哥在2025年推出的通用GPU芯片（PPU），综合性能可以对标英伟达H20，升级版性能则可以比肩A100。 . 这个A100，就是前段时间刚刚解禁的，英伟达H200的上一代产

品，也是当下中小规模的AI训练，性价比最高的产品之一。12月5日，被称为“小英伟达”的摩尔线程登陆科创板，高开涨幅468%，中一签就是小27万元；一边是市场的火热，另一边，是对手千方百计的阻挠，这个GPU赛道，究竟有着怎样的含金量？## **到底是什么是GPU？ ...

- **42_大语言模型的计算需求：从GPU到TPU-阿里云开发者社区** (relevance: 62%) <https://developer.aliyun.com/article/1683983> # 42_大语言模型的计算需求：从GPU到TPU. ## 引言：大语言模型时代的计算革命. 随着2025年大语言模型技术的持续突破和规模化应用，计算资源已成为推动AI发展的关键驱动力。从最初的CPU计算，到GPU加速，再到专用AI加速器的崛起，大语言模型的计算需求正在重塑全球数据中心的基础设施架构。当前，全球AI半导体市场规模预计在2027年将达到2380亿美元（基本情境）甚至4050亿美元（乐观情境），这一增长背后，是大语言模型对计算能力、内存带宽和能效比的极致追求。本深度解析将系统阐述大语言模型从训练到推理全流程的计算需求演变，详细比较不同硬件架构（GPU、TPU、ASIC、FPGA...

4.数据存储

检索关键词: HBM,显存,存储,NVLink

Answer

阿里巴巴使用HBM显存和NVLink技术提升GPU性能，显存通过高速互联技术实现数据交换，提高AI训练效率。

Sources

- **别再分不清显存和内存了！一文讲透AI算力的核心秘密** (relevance: 100%) <https://developer.aliyun.com/article/1708501> GPU（显存）：直接采用数据中心级显卡（NVIDIA H100/H200，AMD MI300X，国产昇腾910B等），它们拥有80GB以上的HBM显存和超高速互联技术（NVLink）。
- **探索大模型世界的多元算力：CPU、GPU与算存互连的复杂比较与 ...** (relevance: 100%) <https://developer.aliyun.com/article/1267050> NVLink最初是为了实现高速GPU之间的数据交换而设计的，通过NVSwitch的帮助，可以将服务器内部的多个GPU连接在一起，形成一个容量成倍增加的显存池。二、
- **小白也能看懂的国内外AI 芯片概述** (relevance: 100%) <https://zhuanlan.zhihu.com/p/667686665> NVIDIA GPU 显存有两种类型，GDDR 和HBM，每种也有不同的型号。针对显存我们通常会关注两个指标：显存大小和显存带宽。HBM 显存通常可以提供更高的显存

- **算力之后，存力接棒！中国存储厂商“卡位战”打响 - 经理人** (relevance: 100%) <https://www.sino-manager.com/detail/10534> 这并非纸上谈兵——英伟达DGX H100服务器单台配置30TB NVMe SSD，其数据吞吐速率直接决定千亿参数大模型的训练效率；而HBM(高带宽内存)通过TSV硅通孔技术堆叠
- **告别AI算力圈“局外人”的100词手册 - 阿里云开发者社区** (relevance: 98%) <https://developer.aliyun.com/article/1715105> 本文系统梳理AI与算力领域的100个核心术语，涵盖基础概念（如LLM、AGI、训练/推理）、硬件架构（GPU/TPU/NPU、HBM、NVLink）、数据中心（集群、液冷、PUE）及

4.数据加速

检索关键词: FlashAttention,量化,推理优化

Answer

FlashAttention accelerates attention computation, boosting inference speed by 37-40%. It is used in Alibaba's vLLM framework and HighService for large language model optimization. Quantization and memory optimization techniques further enhance performance.

Sources

- **深度解析！一起扒扒阿里Qwen3背后的技术细节 - 搜狐** (relevance: 73%) https://www.sohu.com/a/891165884_121124363 工具链优化：.vLLM框架：支持FlashAttention-2加速，推理速度提升37%。昇腾适配：与昇腾910B芯片协同，千亿模型推理能耗下降55%。量化工具：INT8量化
- **广告深度学习计算：阿里妈妈大模型服务框架HighService - 智源社区** (relevance: 67%) <https://hub.baai.ac.cn/view/43319> 算子加速：主要使用了FlashAttention算法加速推理过程。• Batching推理优化：AIGB场景单次推理的计算量，相较于AIGC场景较小，单次推理无法用满GPU的算力资源，
- **Qwen2.5-7B-Instruct高性能推理：vLLM+FlashAttention优化教程原创** (relevance: 60%) https://blog.csdn.net/weixin_36073714/article/details/157091608 集成FlashAttention-2 显著加速注意力计算，推理速度提升40%+; 支持量化加载（如GGUF/Q4_K_M），RTX 3060即可流畅运行; 提供完整可复现的部署流程与性能
- **解析LLM推理中FlashAttention计算与PagedAttention内存优化** (relevance: 57%) <https://developer.aliyun.com/article/1682430> 简介： 本文深度解析FlashAttention与PagedAttention两大LLM推理优化技术：前者通过分块计算提升注意力效率，后者借助分页管理降低KV Cache内存开销。

- **VisionPlaid**是阿里云推出的高性能视觉扩散模型推理加速框架，通过序列并行、量化通信和异步Offload等技术优化显存与速度平衡，深度兼容ComfyUI并支持多卡加速。-函数计算(FC)-阿里云帮助中心 (relevance: 54%) <https://help.aliyun.com/zh/functioncompute/fc/visionplaid-release-notes> | VisionPlaid | 1 | 14.98 s/it | 308.11 s | 1.6x |. | LightX2V | 4steps+fp8 | 1 | 0.81 s/it | 4.10 s | 1x |. | VisionPlaid | 4steps+fp8 | 1 | 0.71 s/it | 3.51 s | 1.17x vs LightX2V |. | ComfyUI | bf16 | 1 | 9.04 s/it | 188.39 s | 0.69x |. | ComfyUI | 4steps+bf16 | 1 | 4.38 s/it | 24.40 s | 0.56x |. ...

4.Agent

检索关键词: 智能体,Agent,AutoGPT

Answer

An AI agent (智能体) like AutoGPT autonomously performs tasks by breaking down goals into subtasks. It uses large language models to interact with tools. Alibaba's agent framework is also a notable example.

Sources

- **以AutoGPT为例浅谈智能体Agent** (relevance: 100%) <https://agent.csdn.net/6835389a606a8318e85a6806.html> AutoGPT是一个AI agent（智能体），也是开源的应用程序，结合了GPT-4和GPT-3.5技术，给定自然语言的目标，它将尝试将其分解成子任务，并在自动循环中使用搜索
- **LangGraph - AI-Compass Agent智能体技术生态：整合AutoGPT** (relevance: 100%) <https://www.nowcoder.com/discuss/776566610302656512>
- 1.Refact-AI-Agent. # 1.Agently. * 新闻汇总报告生成器AgentEra/Agently-Daily-News-Collector: An open-source LLM based automatically daily news collecting workflow showcase powered by Agently AI application development framework. * camel-ai/camel: 🐪CAMEL: The first and the best multi-agent framework. # 1.R...
- **深入浅出完整解析AI Agent（AI智能体）的核心基础知识 - 知乎专栏** (relevance: 100%) <https://zhuanlan.zhihu.com/p/1919046969076195976> 这通常依赖于其训练数据中对各种工具功能的“理解”。在现代AI框架（如LangChain, AutoGPT）中，我们可以预先为模型提供一个工具清单，其中包含每个工具的名称、
- **2025年大佬爆肝整理的大模型AI Agent智能体入门到进阶学习笔记** (relevance: 100%) <https://zhuanlan.zhihu.com/p/1903198488520549993> 智能体（Agent）是人工智能领

域中的一个核心概念，指的是具有智能的实体，能够感知其环境、通过学习和推理改变自身状态，并采取行动以实现特定目标。智能体既

- **智能体-agent** (relevance: 100%) [https://java2ai.com/docs/dev/get-started/agent/ ...](https://java2ai.com/docs/dev/get-started/agent/) Alibaba 正式版也马上来了点此了解. ×. Spring AI Alibaba-logo. 文档. 1.0.0-M6.1 ... 智能体-agent. :::danger ⚠ 文档已过期. ⚠ 本文档已过期，请访问最新文档

五、整体技术趋势判断

5.1 战略方向

基于2026年04月12日的检索结果，阿里巴巴的AI战略呈现以下特点：

1. 技术路线:
2. 产品布局:
3. 生态建设:

5.2 竞争态势

- vs OpenAI:
- vs Google:
- vs 国内竞品:

5.3 未来展望

预测阿里巴巴在未来3-6个月可能的技术/产品动向：

- 1.
- 2.
- 3.

六、参考来源

- Tavily Search 检索结果
 - 企业官方博客/公告
 - 技术媒体（量子位、机器之心等）
 - 学术论文（arXiv）
-

本报告由 OpenClaw AI 系统自动生成

报告版本: v1.0

生成时间: Sun Apr 12 06:00:44 AM CST 2026