

NVIDIA AI技术洞察报告

报告日期: 2026年04月19日

生成时间: 06:02:10

数据来源: Tavily Search, 企业博客, 新闻媒体

洞察范围: 模型发布、技术动态、产品更新

一、公司概况

公司名称: NVIDIA

主要产品: H100,B200,CUDA

检索优先级: 高

二、最新动态检索

2.1 产品/模型发布

Answer

In 2026, NVIDIA released new open models, data, and tools to advance AI across various industries. Key models include Nemotron for agent-based AI, Cosmos for physical AI, and Alpamayo for autonomous driving. These resources aim to accelerate AI development and deployment.

Sources

- **NVIDIA 发布全新开放模型、数据和工具，推动各行业AI 技术的发展** (relevance: 86%)
<https://nvidia.csdn.net/6982a5637c1d88441d91aae3.html> 为扩展开放模型生态，NVIDIA 发布全新开放模型、数据和工具，推动各行业AI 技术的发展。这些模型包括适用于代理式AI 的 NVIDIA Nemotron 系列、适用于
- **NVIDIA 发布全新开放模型、数据和工具，推动各行业 AI 技术的发展 | NVIDIA 英伟达博客** (relevance: 86%) <https://blogs.nvidia.cn/blog/open-models-data-tools-accelerate-ai/>
NVIDIA 发布全新开放模型、数据和工具，推动各行业 AI 技术的发展. 这些模型包括适用于代理式 AI 的 NVIDIA Nemotron 系列、适用于物理 AI 的 NVIDIA Cosmos 平台、适用于辅

助驾驶汽车开发的全新 NVIDIA Alpamayo 系列、适用于机器人的 NVIDIA Isaac GR00T 以及适用于生物医学的 NVIDIA Clara，它们将为企业构建真实世界 AI 系统所需的技术工具。 . ## **NVIDIA Nemotron 赋予 AI 智能体语音、多模态智能和安全能力**. 基于近期发布的 NVIDIA Nemotron 3 系列开放模型与...

- **NVIDIA 发布全新物理 AI 模型，全球合作伙伴展示新一代机器人 | NVIDIA 英伟达博客** (relevance: 85%) <https://blogs.nvidia.cn/blog/nvidia-releases-new-physical-ai-models-as-global-partners-unveil-next-generation-robots/> # NVIDIA 发布全新物理 AI 模型，全球合作伙伴展示新一代机器人. 全球领先的机器人企业，包括 Boston Dynamics、Caterpillar、Franka Robotics、Humanoid、LG Electronics 和 NEURA Robotics 等正在借助 NVIDIA 机器人开发栈推出 AI 驱动的全新机器人。 . NVIDIA 创始人兼首席执行官黄仁勋表示：“机器人开发的 ChatGPT 时刻已然到来。物理 AI 领域取得了突破性进展，这类模型具备理解现实世界、推理和行动规划的能力，持续催生全新的应用场景。NVIDIA 的全栈技术，包括 Jetson 机器人开发处...
- **NVIDIA发布大规模开源模型、数据和工具集合,加速AI开发| Namiru.ai** (relevance: 85%) <https://namiru.ai/zh/blog/nvidia-releases-massive-collection-of-open-models-data-and-tools-to-accelerate-ai-development> 在CES 2026上,NVIDIA宣布了迄今为止可能最重要的开源AI发布。该公司推出了涵盖从语音识别到药物发现等各个领域的新模型、数据集和工具。
- **AI 模型 | NVIDIA 开发者** (relevance: 85%) <https://developer.nvidia.cn/ai-models> 早在 2016 年，NVIDIA 和 OpenAI 就发布了 NVIDIA DGX™，开始突破 AI 的界限。随着 OpenAI gpt-oss-20b 和 gpt - oss-120b 的发布，协作式 AI 创新得以延续。NVIDIA 已在 NVIDIA Blackwell 架构上优化了这两个新的开放权重模型，以加速推理性能，在 NVIDIA GB200 NVL72 系统上每秒可提供高达 150 万个 token (TPS) 。 . 阅读博客：NVIDIA 在 NVIDIA GB200 NVL72 上提供 150 万 TPS 推理，加速从云到边缘的 OpenAI gpt-oss 模型. 在 O...

2.2 技术突破

Answer

NVIDIA achieved significant breakthroughs in generative AI, enhancing applications in weather forecasting, climate research, and industrial design. Their innovations include the CorrDiff model and advanced GPU architectures like Blackwell and Hopper. These advancements drive computational efficiency and performance.

Sources

- **NVIDIA 生成式AI 新突破，这些新突破的具体内容有哪些？ - 知乎** (relevance: 100%) <https://www.zhihu.com/question/665061877/answer/63205549094> 这些新突破不仅展

示了NVIDIA在生成式AI领域的技术进步，还表明其在推动气象预测、气候变化研究以及工业设计等多个领域的应用潜力。 NVIDIA CorrDiff

- **NVIDIA 技术和 GPU 架构 | NVIDIA** (relevance: 100%) <https://www.nvidia.cn/technologies/#NVIDIA技术>. ### Blackwell 架构 (2024 年 3 月). ### Hopper 架构 (2022 年 3 月). NVIDIA 加速计算平台为计算新时代提供动力支持，与基于 CPU 的传统计算相比，NVIDIA 加速计算平台在更短的时间内以更高的能效和更低的成本执行更多工作。 . NVIDIA CUDA® 是革命性的并行计算平台。作为赋能硬件和软件技术，CUDA 使单一图形处理器使用多个计算核心成为可能，从而运行通用数学运算，实现计算大幅提速。 . 商用 3D 立体可视化 SDK 让您能够实时可视化大规模数据集，并与之实时交互，同时定位数据中相关性最高的部分。 其利用...
- **Nvidia Launches World's First Open-Source AI Model to Accelerate ...** (relevance: 99%) <https://www.youtube.com/watch?v=jlmySnDCAL8> ... 技術門檻更高，要達到實際應用，可能還需要5到10年。 # ... Nvidia Launches World's First Open-Source AI Model to
- **白皮书：技术革新引领未来——生成式AI 塑造核心发展引擎 - 英伟达** (relevance: 99%) <https://www.nvidia.cn/lp/ai-data-science/generative-ai/the-core-engine-driving-enterprise-future-development-whitepaper/> NVIDIA 在生成式AI 领域的技术优势，包括硬件、软件与工具、端到端解决方案，以及如何通过NVIDIA AI Enterprise 平台降低企业部署和运用复杂AI 模型的门槛。
- **英伟达的核心战略1. 技术创新与研发驱动英伟达将创新视为核心竞争力** (relevance: 99%) <https://xueqiu.com/9664266475/321682739> 英伟达将创新视为核心竞争力，持续投入大量资源进行研发。公司每年将超过20%的收入用于研发活动，涵盖硬件设计、软件开发、架构和算法开发等多个领域。这

三、技术趋势分析

3.1 模型能力演进

基于检索结果分析NVIDIA在以下方面的进展：

- **大语言模型:** 上下文长度、推理能力、多语言支持
- **多模态能力:** 图像理解、视频生成、跨模态交互
- **推理优化:** 思维链、深度推理、数学/代码能力

3.2 工程化进展

- **训练基础设施:** 算力规模、训练效率、成本控制
- **推理优化:** 量化技术、KV Cache优化、批处理策略

- **部署方案:** 云端API、边缘部署、私有化方案

四、关键技术点展开

4.大语言模型

检索关键词: LLM,大模型,GPT,Claude,Gemini

Answer

I am an AI system built by a team of inventors at Amazon. The most essential facts are that I do not identify as any specific model name and adhere to privacy and identity policies.

Sources

- [illegible]

- **GLM-5.1 vs Claude、GPT、Gemini、DeepSeek：智譜AI最新模型的 ...** (relevance: 56%) <https://wavespeed.ai/blog/zh-tw/posts/glm-5-1-vs-claude-gpt-gemini-deepseek-llm-comparison/> 智譜AI的GLM-5.1宣稱達到Claude Opus 4.6程式編寫效能的94.6%——完全基於華為晶片訓練並開放權重。以下是其與2026年各主流大型語言模型的全面對比。
- **终于忍不住了大模型选型指南：GPT、Gemini、Claude谁更适合你 ...** (relevance: 54%) <https://blog.csdn.net/Joshkhh/article/details/159552017> Gemini 3.1：在超长上下文和多模态处理上表现突出 • GPT 5.4：在中文表达和代码细节上更胜一筹我们在Oneaipplus平台上使用相同提示词对两款模型进行了多轮测试

4.推理模型

检索关键词: o1,R1,推理,思维链

Answer

Reasoning models like o1 and DeepSeek-R1 enhance AI by explaining their thought process. They use techniques like chain of thoughts for better problem-solving. These models aim to improve AI's understanding and efficiency.

Sources

- **多模态也做到了强推理！工业界首个开源的R1V，让视觉思考进入o1 ...** (relevance: 67%) <https://cloud.tencent.com/developer/article/2506043> 昆仑万维发布开源多模态思维链推理模型R1V 系列，具备SOTA 级视觉推理和通用推理能力，在数学推理等多任务中领先，其创新技术包括高效多模态推理迁移等，
- **从o1到DeepSeek-R1，万字长文带您揭秘推理模型——及其与标准 ...** (relevance: 60%) <https://zhuanlan.zhihu.com/p/26076930125> 推理模型与标准LLM的主要区别在于能够在回答问题之前“思考”。推理模型的思维只是由LLM输出的长链思维——简称长CoT，有时称为推理轨迹或路径。长CoT的生成
- **一种先进的人工智能形式——于去年9月由美国公司OpenAI 发布，名 ...** (relevance: 57%) <https://x.com/dotey/status/1883700968501469535> 世界上首个“推理模型”（reasoning model）——一种先进的人工智能形式——于去年9月由美国公司OpenAI 发布，名为“o1”。该模型采用“思维链”（chain of
- **DeepSeek 推理型AI盡顯高效訓練的小模型之威** (relevance: 57%) <https://hongkong.newsroom.ibm.com/DeepSeek-AI#Blogs>. 作者： Aili McConnon, IBM 2025 年1月27 日發表與IBM官網Think頻道，點擊閱讀英文原文 DeepSeek-R1是中國初創公司

DeepSeek... DeepSeek-R1是中國初創公司 DeepSeek 推出的人工智能模型，不久前，在人工智能開源平台 Hugging Face上發佈數小時後，便躍居下載量和活躍度最高模型的榜首。這也給金融市場帶來了震蕩，因為它促使投資者重新考慮英偉達（NVIDIA）等芯片製造商的估值，以及美國人工智能巨頭為擴大其人工智能業務規模而進行的巨額投資。為何掀起如此大的波瀾？DeepSeek-R1 是一款所謂 "推理模...

- **大家好，最近推理模型逐漸興起，特別是OpenAI o1 和DeepSeek-R1 ...** (relevance: 55%) <https://www.facebook.com/groups/aigctw/posts/2835804279936799/> 大家好，最近推理模型逐漸興起，特別是OpenAI o1 和DeepSeek-R1 等推理模型相續推出，引起了大量討論。這種模型並不急於作答，而是花時間「思考」逐步

4.多模态模型

检索关键词: 多模态,视觉,视频生成,Sora,Seedance

Answer

SkyReels-V4 is a leading multi-modal AI model for video generation, supporting text, images, and audio inputs. It integrates video and audio generation for synchronized results. It ranks top globally for its comprehensive multi-modal capabilities.

Sources

- **Seedance2.0炸场后，又一中国黑马登顶AA榜单！AI味没了 - 智源社区** (relevance: 71%) <https://hub.baai.ac.cn/view/52776> # Seedance2.0炸场后，又一中国黑马登顶AA榜单！AI味没了. 新智元 2026-02-28 15:10 分享. ##### **【新智元导读】当Seedance 2.0刷屏全网时，一匹中国黑马已悄然冲上全球AI视频榜第二。昆仑天工SkyReels-V4强势杀入顶级牌桌，多模态输入、音画同步直出影院级大片，实力惊艳超群！** . 就在刚刚，Artificial Analysis更新了文本到视频（含音频）全球榜单。Artificial Analysis 榜单：<https://artificialanalysis.ai/video/leaderboard/text-to-video?..>
- **Seedance 2.0：最佳多模态AI视频生成器，具有角色一致性** (relevance: 59%) <https://akool.com/zh-cn/models/seedance2> 基于高级多模态参考的AI视频生成. 单个项目中最多可上传9 张图片、3 个视频和3 个音频文件（最多12 个混合文件）。Seedance 2.0 可根据您的参考素材，精准分析视觉构图、
- **字节跳动电影级多模态视频生成模型全景剖析 - 阿里云开发者社区** (relevance: 59%) <https://developer.aliyun.com/article/1724018> 与前代相比，Seedance 2.0 并非参数量级的线性堆叠，而是在架构范式、多模态融合、物理建模、音画同步四个维度实现了系统性突破，将AI 视频生成从"工具级"推

- **国产模型悄然打赢一场多模态战役** (relevance: 58%) <https://eu.36kr.com/zh/p/3739204925764102> Seedance 2.0凭借它的强大能力，已经被人们视为未来制作电影的“神器”，而它现在唯一存在的尴尬之处，就在于缺少配音。音频生成看起来比视频生成要简单，但给
- **对比 Seedance 2.0 vs Sora 2 的 8 个核心差异：2026 年 AI 视频生成模型选型指南 - Apiyi.com Blog** (relevance: 55%) <https://help.apiyi.com/seedance-2-vs-sora-2-ai-video-comparison.html> # 对比 Seedance 2.0 vs Sora 2 的 8 个核心差异：2026 年 AI 视频生成模型选型指南. ## Seedance 2.0 vs Sora 2 基础信息对比. | 对比项 | Seedance 2.0 | Sora 2 |. ## Seedance 2.0 vs Sora 2 的 8 个核心差异. | 输入能力 | Seedance 2.0 | Sora 2 |. | 音频能力 | Seedance 2.0 | Sora 2 |. | 速度指标 | Seedance 2.0 | Sora 2 |. ## Seedance 2.0 vs Sora 2 综合能力评分. ...

4.算力卡

检索关键词: GPU,H100,B200,TPU,算力

Answer

The H100, B200, and H200 are high-performance GPUs from NVIDIA, with B200 offering the highest memory bandwidth and compute performance. B200 is designed for large-scale AI training and inference. H200 improves over H100 with better memory and compute capabilities.

Sources

- **万字长文解析：从H100到B200，GPGPU与大模型扩展性深度分析** (relevance: 100%) <https://zhuanlan.zhihu.com/p/1985478405458788975> 随着大模型参数量的指数级增长，NVIDIA H100/B200 等高性能GPU 已成为算力基础设施的核心。然而，在大规模训练中，单纯堆砌GPU 数量并不足以线性提升性能。
- **11.4 硬件选型：GPU、TPU 与专用加速器| 大模型原理与架构 - GitBook** (relevance: 100%) https://yeasy.gitbook.io/llm_internals/di-san-bu-fen-tui-li-yu-bu-shu-pian/11_serving/11.4_hardware NVIDIA GPU 凭借 CUDA 生态的成熟度和 Tensor Core 的强大性能，是 LLM 训练和推理的首选。关键指标对比：. 表 11-2：NVIDIA 主要 GPU 型号对比 (*表示该数值为 Tensor Core 峰值指标或包含稀疏性加速；在做密集 FP16 横向比较时应查看官方 dense throughput 口径) . 对于推理场景，**显存带宽**通常比算力更重要（10.1 节已解释生成阶段是访存密集型的）。H200 的 141 GB 显存使其可以在单卡上运行 70B 的 INT4 量化模型，极大降低了部署复杂度。而 B200 的 192 GB 显存和 8 TB/s 带...

- **NVIDIA Blackwell B200 与 Hopper H100 架构深度对比 - 豆瓣** (relevance: 100%) <https://www.douban.com/group/topic/335985355/> ØFP8峰值算力从H100的约4 PetaFLOPs提升至10 PetaFLOPs, 增幅达2.5倍; . ØBF16算力同样实现约2.5倍提升, 从2 PetaFLOPs提高至5 PetaFLOPs; .
- **一张图说清: H100、H200、B200 到底该怎么选? - 稀土掘金** (relevance: 100%) <https://juejin.cn/post/7586892413890068526> | NVLink | 第四代 (900 GB/s) | 第四代 | 第五代 (1.8 TB/s) | . H200 不是算力升级, 而是显存与带宽升级, 解决“跑不动”的问题; . B200 则是一次架构级跃迁, 面向千卡集群、下一代 AI 工厂设计。 . | **<7B 参数, 微调/推理 | A10 / L4 / RTX 6000 Ada** | 小模型对算力要求低, A10/L4 成本更低; H100 属性能过剩, 仅在统一集群时考虑 . | **7B-30B, 全参训练** | H100 | 在 FP8 + 梯度检查点 + ZeRO 下可高效训练PyTorch/TensorFlow 生态最成熟, 调试工...
- **H100 vs. H200 vs. B200: 为您的AI工作负载选择合适的NVIDIA GPU** (relevance: 100%) <https://introl.com/zh/blog/h100-vs-h200-vs-b200-choosing-the-right-nvidia-gpus-for-your-ai-workload> # H100 vs. * **H100**: 3.35 TB/s (可观) . * **H200**: 4.8 TB/s (43%改进) . * **B200**: 8 TB/s (另一个宇宙) . "H200 Tensor Core GPU." NVIDIA Data Center. "DGX B200: The Foundation for Your AI Factory." NVIDIA Data Center. "Choosing GPU Infrastructure for LLM Training in 2025: NVIDIA H100 vs. "NVIDIA H200 vs H100: Bett...

4.数据存储

检索关键词: HBM,显存,存储,NVLink

Answer

High Bandwidth Memory (HBM) is crucial for advanced GPU performance, enhancing data transfer rates and reducing latency. NVLink technology further interconnects GPUs, allowing shared memory and increased bandwidth. Together, HBM and NVLink significantly boost AI and computational tasks.

Sources

- **GPU内存(显存)的理解与基本使用 - 知乎专栏** (relevance: 100%) <https://zhuanlan.zhihu.com/p/462191421> HBM(High Bandwidth Memory)高带宽存储，是另一种常用显存介质。顾名思义这个存储介质有着"High Bandwidth"，参考NVIDIA P100所用的HBM来说明，该系列的显卡采用HBM第二代
- **不同GPU的HBM透過NVLINK相連之後，所有的VRAM就都共享了 ...** (relevance: 100%) https://www.threads.com/@llamatechtrend_zh/post/DHuRlqihgOT/%E9%81%E5%8EBB%E6%88%91%E4%B8%80%E7%9BB4%E6%B2%92%E6%90%9E%E6

最有趣的是，因為NVLINK跟HBM的速度提上來了，不同GPU的HBM透過NVLINK相連之後，所有的VRAM就都共享了，以NVL72搭配GB300的架構來看，共享的VRAM理論值可以超過

- **HBM，何以成为AI角力关键？_新闻中心_苏州超集信息科技有限公司** (relevance: 96%)
<https://www.amaxchina.com/news/2167.html> # HBM，何以成为AI角力关键？_新闻中心_苏州超集信息科技有限公司. 三星电子近日宣布，其12层第六代HBM4内存将于10月底正式发布，现已进入研发冲刺阶段，并计划今年晚些时候量产。这一动作无疑为2025年本就爆发式增长的HBM市场再添一把烈火。·为什么HBM年增速能突破200%，达到68亿美元全球市值，成为AI赛道的"战略石油"。今天，超集信息带您透视HBM的底层逻辑：从打破"存储墙"到决定大模型训练速度，它如何悄悄掌控AI算力的生死线。·HBM对GPU的性能提升，本质是解决了传统内存（如GDDR6、DDR5）的"带宽瓶颈"——GPU计算核心的算力（如 FP8 算力达 1-2 ...
- **内存焦虑？长文梳理：HBM/DRAM/CXL/HBF/GPU-Direct - 腾讯云** (relevance: 92%)
<https://cloud.tencent.com/developer/article/2574387> | CXL-DRAM 资源池 | ~160 - 250 ns (本地DRAM时延 + 30-80ns开销) | 64 GB/s per x16 CXL 3.0 link | 128 GB - 2 TB per device | 超大模型内存扩展、内存池化、温数据层 (Massive Model Memory Expansion, Memory Pooling, Warm Data Tier) | 16 |. | HBF (高带宽闪存) | > 1 μs (预计) | ~1.2 TB/s (预计, 与HBM相当) | 256 GB - 4 TB per device (预计) | (未来) 读取...
- **GPU 进阶笔记（一）：高性能 GPU 服务器硬件拓扑与集群组网（2023）** (relevance: 91%)
<https://arthurchiao.art/blog/gpu-advanced-notes-1-zh/> # ArthurChiao's Blog. # GPU 进阶笔记（一）：高性能 GPU 服务器硬件拓扑与集群组网（2023）. 记录一些平时接触到的 GPU 知识。由于是笔记而非教程，因此内容不求连贯，有基础的同学可作查漏补缺之用。· * GPU 进阶笔记（一）：高性能 GPU 服务器硬件拓扑与集群组网（2023）. 3. 同一台 node 内的 GPU 通过 NVLink 以 **full-mesh** 方式（类似 spine-leaf）互联，· * A100 是 **2 lanes/NVSwitch * 6 NVSwitch * 50GB/s/lane = 600GB/s** 双向带宽 (...)

4.数据加速

检索关键词: FlashAttention,量化,推理优化

Answer

FlashAttention optimizes transformer models for faster inference, reduces memory usage, and improves GPU efficiency through efficient attention computation and quantization techniques. It leverages tiled matrix operations and low-precision arithmetic for performance gains.

Sources

- **FlashAttention FasterTransformer整合：NVIDIA推理加速 - CSDN博客** (relevance: 100%) https://blog.csdn.net/gitblog_00224/article/details/151162701 ... 优化和模型量化等技术。我们从硬件架构到软件实现，详细分析如何通过合理配置GPU 资源、优化矩阵运算和减少数据传输开销来提高推理效率。此外，本文
- **Attention 内存优化管理：KV 缓存量化、FlashAttention 和 vLLM 的实践指南 | MLOasis** (relevance: 100%) <https://mloasisblog.com/blog/ML/AttentionOptimization>

```
import torch
import from transformers import AutoTokenizer, AutoModelForCausalLM
from import, tokenizer = AutoTokenizer.from_pretrained("meta-llama/Llama-2-7b-chat-hf")
=.("meta-llama/Llama-2-7b-chat-hf")
model = AutoModelForCausalLM.from_pretrained("meta-llama/Llama-2-7b-chat-hf",
torch_dtype=torch....
```
- **大模型底层优化里程碑：FlashAttention v1-v4技术全景 - 51CTO** (relevance: 100%) <https://www.51cto.com/article/838983.html> 推理场景优化：针对KV缓存量化、动态序列长度等推理需求，扩展低精度与稀疏策略。多GPU协同：结合Ring Attention等分布式策略，实现超长篇序列（百万级）的高效
- **针对GPU优化的Attention计算介绍优化算法FlashAttention-3 - YouTube** (relevance: 100%) <https://www.youtube.com/watch?v=i1Cf5r4jGLA> Comments • 大语言模型如何思考？ • Test Time Training：AI视频生成时长限制的突破性解决方案 • Token Shuffle：自回归模型实现高分辨率图像生成的技术进步。
- **在 NVIDIA CUDA Tile 中调整 Flash Attention 以实现峰值性能 - NVIDIA 技术博客** (relevance: 100%) <https://developer.nvidia.cn/blog/tuning-flash-attention-for-peak-performance-in-nvidia-cuda-tile/> # 在 NVIDIA CUDA Tile 中调整 Flash Attention 以实现峰值性能. 注意力机制是 Transformer 模型的计算核心。给定 token 序列，注意力机制使每个 token 能够“查看”其他 token，并动态调整它们对当前 token 的贡献程度。从数学角度看，对于输入矩阵 Query ((Q))、Key ((K)) 和 Value ((V))，输出可表示如下：
$$O = \text{softmax}\left(\frac{QK^T}{\sqrt{d}}\right)V$$
. A tiled flash attention figure sh...

4.Agent

检索关键词: 智能体,Agent,AutoGPT

Answer

AI agents are autonomous systems that can perceive, reason, and act independently. They utilize large language models to perform tasks and make decisions. Popular examples include AutoGPT and Amazon Bedrock Agents.

Sources

- **构建您的首个LLM 代理申请- NVIDIA 技术博客** (relevance: 67%) <https://developer.nvidia.cn/blog/building-your-first-llm-agent-application/> AutoGPT: 这个GitHub 项目是首批真正的智能体之一，它旨在展示智能体能够提供的各种功能。
 - Voyager: 这个项目由NVIDIA 研究所提出，探索了自我提升智能体的
- **全球AI Agent大盘点，大语言模型创业一定要参考的60个AI智能体_资讯-蓝鲸财经** (relevance: 65%) <https://www.lanjinger.com/d/219630> AGI创业新声2023-09-26 14:46. 随着AI Agent原理、模式以及构建方式越发明朗，很多受困于技术、模式、生态乃至政策的创业者都是眼前一亮。百度发布文心一言正式发布不久后的4月，很多人还在感叹文心一言生成的图片多欢乐，更多人在为ChatGPT、Midjourney各种培训而疯狂的时候，Meta创始人兼CEO扎克伯格正在想着如何“以有用且有意义的方式”向全球数十亿人介绍AI Agents的机会。OpenAI完成新一轮3亿美元融资的5月，创始人Sam Altman私下对一些开发者说希望将ChatGPT打造成个人工作助手，知情人士透露的消息则是OpenAI一直在关注如何使用...
- **也能构建强大的AI 代理系统？试试NVIDIA AIQ Toolkit** (relevance: 64%) <https://cloud.tencent.com/developer/article/2519591> AI-Compass Agent智能体技术生态：整合AutoGPT、LangGraph、CrewAI等前沿框架，构建自主决策工具调用的AI智能体系统。2.5K0. 构建多智能体AI 应用的5个最佳
- **AI智能体卷爆大模型！AutoGPT等4大Agent打擂** (relevance: 64%) <https://zhuanlan.zhihu.com/p/641874075> 3月30日，AutoGPT发布。4月3日，BabyAGI发布。4月7日，西部世界小镇发布。5月27日，英伟达AI智能体Voyager接入GPT-4后，直接完胜了AutoGPT。通过
- **常见LLM Agent框架：AutoGPT** (relevance: 56%) <https://docs.feishu.cn/v/wiki/Vo4kwaphgi7wlfktRzzcYeahnxb/a8> (3) 智能体（Agent）模式。人类设定目标和提供必要的资源（例如计算能力），然后AI独立地承担大部分工作，最后人类监督进程以及评估最终结果。这种模式下，AI充分体现了智能体

五、整体技术趋势判断

5.1 战略方向

基于2026年04月19日的检索结果，NVIDIA的AI战略呈现以下特点：

1. 技术路线:
2. 产品布局:

3. 生态建设:

5.2 竞争态势

- vs OpenAI:
- vs Google:
- vs 国内竞品:

5.3 未来展望

预测NVIDIA在未来3-6个月可能的技术/产品动向:

- 1.
- 2.
- 3.

六、参考来源

- Tavily Search 检索结果
- 企业官方博客/公告
- 技术媒体（量子位、机器之心等）
- 学术论文（arXiv）

本报告由 OpenClaw AI 系统自动生成

报告版本: v1.0

生成时间: Sun Apr 19 06:02:34 AM CST 2026