

字节跳动 AI技术洞察报告

报告日期: 2026年04月19日

生成时间: 06:00:01

数据来源: Tavily Search, 企业博客, 新闻媒体

洞察范围: 模型发布、技术动态、产品更新

一、公司概况

公司名称: 字节跳动

主要产品: 豆包, Seedance, Seed

检索优先级: 高

二、最新动态检索

2.1 产品/模型发布

Answer

ByteDance released Doubao-Seed-2.0, a major upgrade to its multimodal AI model, featuring enhanced visual understanding and complex command execution. Seedance 2.0, another model, offers high-quality, controllable video generation. Both models showcase ByteDance's advancements in AI technology.

Sources

- 字节大模型，重磅发布！ (relevance: 84%) <https://www.stcn.com/article/detail/3644236.html> 要闻 金融 评论 产经 创投 滚动. A股 公司 新股 基金 港美股. 来源：证券时报网作者：周春媚2026-02-14 15:56. 在这个春节的“群模大战”中，作为“多模态AI王者”的字节跳动，接连惊艳市场。2月14日，字节火山引擎发布豆包大模型2.0（Doubao-Seed-2.0）。据介绍，这是字节跳动最新推出的多模态Agent（智能体）模型，也是豆包大模型自2024年5月正式发布以来首次大版本的跨代升级。豆包大模型2.0具有更稳健的视觉与多模态理解、更可靠的复杂指令执行、更快速更灵活的推理选择三大核心亮点。目前，豆包2.0 Pro和Code模型...

- **字节跳动：Seedance 2.0 正式发布，音视频生成质量和可控性达专业生产场景要求 - IT之家** (relevance: 77%) <https://www.ithome.com/0/921/381.htm> 业界 手机 电脑 测评 视频 AI 苹果 iPhone 鸿蒙 软件. 智车 数码 学院 游戏 直播 5G 微软 Win10 Win11 专题. # 字节跳动：Seedance 2.0 正式发布，音视频生成质量和可控性达专业生产场景要求. 2026/2/12 13:19:56 来源：IT之家 作者：**远洋** 责编：**远洋**. IT之家 2 月 12 日消息，据字节跳动 Seed 官方微信公众号消息，今天，新一代视频创作模型 Seedance 2.0 正式发布。Seedance 2.0 采用统一的多模态音视频联合生成架构，支持文字、图片、音频、视频四种模态输入，集成了目前业界最全面的多...
- **Seedance 2.0：字节跳动最新多模态 AI 视频模型深度解析 | PixVerse** (relevance: 76%) <https://pixverse.ai/zh/blog/what-is-seedance-2-0-ai-video-model> # Seedance 2.0：字节跳动最新多模态 AI 视频模型深度解析. 深入了解 Seedance 2.0，字节跳动推出的最新 AI 视频生成模型，具备四模态输入、高级运镜控制及全能参考系统。Seedance 2.0：字节跳动最新多模态 AI 视频模型深度解析. # Seedance 2.0：字节跳动最新多模态 AI 视频模型深度解析. ## 简介. AI 视频生成领域持续快速演进，新模型不断突破数字创作的边界。近期，字节跳动推出了全新的多模态视频生成模型 **Seedance 2.0**，在科技和创意社区引起了广泛关注。Seedance 2.0 定位于“可控创作”工具，引入了多项旨在...
- **团队动态 - 字节跳动Seed** (relevance: 75%) <https://seed.bytedance.com/zh/blog/official-launch-of-seedance-2-0> # Seedance 2.0 正式发布. 今天，我们正式发布新一代视频创作模型 Seedance 2.0。Seedance 2.0 采用统一的多模态音视频联合生成架构，支持文字、图片、音频、视频四种模态输入，集成了目前业界最全面的多模态内容参考和编辑能力。> https://seed.bytedance.com/seedance2_0. > 1) 即梦网页端-视频生成-选择 Seedance 2.0; > 2) 豆包 App 对话框-Seedance2.0-选择 2.0 模型; > 3) 火山方舟体验中心-选择 Doubao-Seedance-2.0。Seedance 2.0 能完...
- **字节跳动Seed** (relevance: 75%) <https://seed.bytedance.com/zh/> 每秒推理速度 2146 Tokens，扩散语言模型 Seed Diffusion Preview 发布. 每秒推理速度 2146 Tokens，扩散语言模型 Seed Diffusion Preview 发布. 字节跳动 Seed 与比亚迪锂电池深化合作：将成立 AI 联合实验室加速电池研发. 字节跳动 Seed 与比亚迪锂电池深化合作：将成立 AI 联合实验室加速电池研发. 解锁任意模态模型训练，字节跳动 Seed 开源 VeOmni 框架. 解锁任意模态模型训练，字节跳动 Seed 开源 VeOmni 框架. 字节跳动 Seed Prover 取得 IMO 2025 银牌分数. 字节跳动 ...

2.2 技术突破

Answer

ByteDance has made significant technical breakthroughs in AI, recommendation systems, and distributed computing. Their innovations include the "information flow + recommendation engine" model and advanced chaos engineering practices.

Sources

- **字节跳动技术实力如何，对于做技术的年轻人来说 - 知乎专栏** (relevance: 100%) <https://zhuanlan.zhihu.com/p/547241653> 字节跳动有一个明显的特点是很鼓励技术创新，包括字节首创的“信息流+推荐引擎”的模式也是技术创新下的成果，从头条和抖音的内容推荐就可以看出来，这种创新
- **字节跳动如何在AI领域吸引和留住顶尖人才？ - 飞书文档** (relevance: 100%) <https://docs.feishu.cn/v/wiki/CaHlw9Cjhi6b9okTrdqceJBQn6g/aj> 功能上，AnimateDiff-Lightning 模型只需4至8步的推理，就能生成出质量极佳的视频。这种高效的生成能力对于视频制作行业是一次重大的技术突破，为用户提供了更加便捷和高效的
- **字节跳动技术团队年度 TOP10 技术干货，陪你度过不平凡的 2020 - 文章 - 开发者社区 - 火山引擎** (relevance: 100%) <https://developer.volcengine.com/articles/7599494153433448499> # 字节跳动技术团队年度 TOP10 技术干货，陪你度过不平凡的 2020. 2020 注定是不平凡的一年，在这特殊的一年里，字节跳动技术团队依旧在技术人身边，分享字节跳动的技术实践。· 本年度字节跳动技术团队共发布了50篇技术干货，其中许多都受到读者的喜爱。值此元旦佳节，我们精选出了其中最受大家欢迎的10 篇文章，供大家回顾，点击文章标题即可阅读全文。· 混沌工程是通过故障注入的方式帮助系统寻找薄弱点，从而提高系统的稳定性。随着微服务、云原生相关技术的发展，分布式系统已经流行在业界各处，但因此也带来了复杂度急剧上升、故障发生难以预测后果、难以避免与验证等挑战。而混沌工程正是通过故障注入等方式...
- **字节跳动技术团队的个人主页- 动态 - 稀土掘金** (relevance: 100%) <https://juejin.cn/user/1838039172387262> 字节跳动开源Godel-Rescheduler：适用于云原生系统的全局最优重调度框架. 背景在云原生调度中，一次调度往往无法解决所有问题，需要配合重调度来优化资源分配
- **技术博客 - ByteDance Seed** (relevance: 99%) <https://seed.bytedance.com/zh/blog> Seed 全双工语音大模型发布：懂倾听、抗干扰，走向更自然的交互. 2026.04.09 ; 字节跳动 Seed 2027 届大模型人才校招启动（含实习）. 2026.04.01.

三、技术趋势分析

3.1 模型能力演进

基于检索结果分析字节跳动在以下方面的进展：

- **大语言模型:** 上下文长度、推理能力、多语言支持
- **多模态能力:** 图像理解、视频生成、跨模态交互
- **推理优化:** 思维链、深度推理、数学/代码能力

3.2 工程化进展

- **训练基础设施:** 算力规模、训练效率、成本控制
- **推理优化:** 量化技术、KV Cache优化、批处理策略
- **部署方案:** 云端API、边缘部署、私有化方案

四、关键技术点展开

4.大语言模型

检索关键词: LLM,大模型,GPT,Claude,Gemini

Answer

I am an AI system built by a team of inventors at Amazon. I provide factual, straightforward answers without personal identification. My responses are based on general knowledge and essential facts.

Sources

- **国内外知名大模型及应用——模型/应用维度（2026/04/17）** (relevance: 72%) <https://zhuanlan.zhihu.com/p/670574382>
- **Wan:** 国内闭源组更新生图模型 **Wan2.7-Image, [Wan2.7-Video](https://zhida.zhihu.com/search?content_id=237146705&content_type=Article&match_order=1&q=Wan2.7-Video&zd_token=eyJhbGciOiJIUzI1NiIsInR5cCI6IkpXVCJ9.eyJpc3MiOiJ6aGlkYV9zZXJ2ZXIiLCJleHAiOiJ0eS01IiwiaWF0Ijoi)
- **1. 大模型概述与发展历程 | 秀才的进阶之路** (relevance: 72%) https://golangstar.cn/go_agent_series/llm_base/llm_overview.html 欢迎来到《Go Agent 实战指南》的第一篇。在正式动手写 Agent 代码之前，我们需要先搞清楚一件事：**大模型到底是什么？它是如何一步步走到今天的？**要开发 AI Agent 应用，你首先得理解它的"发动机"——大语言模型（Large Language Model，简称 LLM）。.你可能会问：我是 Go 语言开发者，直接学怎么调 API、怎么写 Agent 不就行了？为什么还要了解大模型本身？. Agent 的所有智能行为——理解用户意图、规划执行步骤、选择合适的工具、生成最终回答——全都依赖大模型来完成。如果你不了解大模型的能力边界和工作原理，写出来的 Agent 应用就容易出...
- **2025 AI大模型全景图谱：深度解析14家顶流玩家技术路线与优势 | BetterYeah** (relevance: 59%) <https://www.betteryeah.com/blog/2025-top-llm-players-comparison-and-trends> 图1: OpenAI GPT系列模型迭代时间轴 (2023-2025)，展示从

GPT-3.5到GPT-5的关键迭代路径. * **类型**：闭源 / 托管为主（通过 Google AI Studio、Vertex 等服务提供）。. * **能力演进路径**：企业化起步 → 开源/中英双语与推理增强 → 推理专向模型 → 多语种与规范化生态。|. | GPT | OpenAI | GPT-5 | 闭源 | 顶级的通用能力，强大的逻辑推理与Agent能力，生态成熟|. | Gemini | Google | Gemini 2.5 | 闭源 | “思考型模型”，内置推理能力，百万级长上...

- **字节跳动开源Seed-X 7B多语言翻译模型：28语种全覆盖，性能超越GPT-4、Gemini-2.5与Claude-3.5-腾讯云开发者社区-腾讯云** (relevance: 59%) <https://cloud.tencent.com/developer/article/2543952> 在机器翻译领域，如何在保证高质量的同时兼顾模型规模与推理效率一直是研究与工程应用的两难选择。近日，字节跳动团队开源了 **Seed-X** 系列多语言翻译模型（7B），通过精巧的模型结构设计与强化学习微调，实现在仅 7 亿参数规模下，对 28 种语言的翻译性能媲美甚至超越诸如 Gemini-2.5、Claude-3.5、GPT-4 等超大模型。Seed-X 的开源，不仅为学术研究提供了强有力的基线，也为各行业落地翻译应用带来了轻量、高效的新选择。以下将从模型概述、架构与训练流程、性能评估、多场景部署及应用、快速使用示例等方面进行深度剖析，并保留所有原始图片与表格，帮助读者全面了解 Seed-X...
- **字节跳动开源Seed-X 7B多语言翻译模型：28语种全覆盖** (relevance: 48%) <https://developer.volcengine.com/articles/7536063523282288681> 字节跳动开源Seed-X 7B多语言翻译模型：28语种全覆盖，性能超越GPT-4、Gemini-2.5与Claude-3.5在机器翻译领域，如何在保证高质量的同时兼顾模型规模与

4.推理模型

检索关键词: o1,R1,推理,思维链

Answer

DeepSeek-R1 is a reasoning model developed by a Chinese startup that performs comparably to OpenAI's o1 in certain tasks. It uses reinforcement learning to improve its reasoning capabilities. The model's low training cost has attracted significant attention.

Sources

- **解密prompt系列49. 回顾R1之前的思维链发展路线 - 风雨中的小七 - 博客园** (relevance: 68%) <https://www.cnblogs.com/gogoSandy/p/18733245> # 解密prompt系列49. 在所有人都在谈论R1的今天，作为算法也是有些千头万绪无从抓起。所以这一章先复盘，我先按照自己的思路来梳理下R1之前整个模型思维链的发展过程。下一章再展望主要去看RL在Agent上的一些尝试，毕竟Agent规划和长思考的本质是非常像的，在优化中面临的问题也是类似的。.# 阶段1-模型能思考：思维链能提升任务效果. 开始讨论如何使用思维链来提升大模型效果的起点就是Let's think step by step的论文，它首次提出了Chain of

Thought概念，也就是让模型先思考再回答可以有效提升任务完成效果。 . 不难发现以上的论文还基本...

- **IBM Hong Kong newsroom - Blogs** (relevance: 68%) <https://hongkong.newsroom.ibm.com/DeepSeek-AI#Blogs>. 作者: Aili McConnon, IBM 2025年1月27日發表與IBM官網Think頻道，點擊閱讀英文原文 DeepSeek-R1是中國初創公司 DeepSeek... DeepSeek-R1是中國初創公司 DeepSeek 推出的人工智能模型，不久前，在人工智能開源平台 Hugging Face上發佈數小時後，便躍居下載量和活躍度最高模型的榜首。這也給金融市場帶來了震蕩，因為它促使投資者重新考慮英偉達（NVIDIA）等芯片製造商的估值，以及美國人工智能巨頭為擴大其人工智能業務規模而進行的巨額投資。 . 為何掀起如此大的波瀾？ DeepSeek-R1 是一款所謂 "推理模...
- **从o1到DeepSeek-R1，万字长文带您揭秘推理模型——及其与标准 ...** (relevance: 62%) <https://zhuanlan.zhihu.com/p/26076930125> 推理模型与标准LLM的主要区别在于能够在回答问题之前“思考”。推理模型的思维只是由LLM输出的长链思维——简称长CoT，有时称为推理轨迹或路径。长CoT的
- **从o1-mini到DeepSeek-R1，万字长文带你读懂推理模型的历史与技术 - 一起AI技术** (relevance: 60%) <https://17aitech.com/?p=38883> 首页 » 从o1-mini到DeepSeek-R1，万字长文带你读懂推理模型的历史与技术. 文章来源于互联网:从o1-mini到DeepSeek-R1，万字长文带你读懂推理模型的历史与技术. 自 OpenAI 发布 o1-mini 模型以来，推理模型就一直是 AI 社区的热门话题，而春节前面世的开放式推理模型 DeepSeek-R1 更是让推理模型的热度达到了前所未有的高峰。 . Wolfe 发布了一篇题为「**揭秘推理模型**」的深度长文，详细梳理了自 o1-mini 开始至今的推理模型发展史，并详细介绍了让标准 LLM 变成推理模型的具体技术和方法。 . 近段时间，LLM 研究中出现了一个全新...
- **中国版的o1来了！ DeepSeek-R1-Lite媲美o1-preview，还原完整COT ...** (relevance: 59%) <https://developer.volcengine.com/articles/7441466492882944037> 红色实线展示了模型所能达到的准确率与所给定的推理长度呈正相关； . 相比传统的多次采样+投票（Majority Voting），模型思维链长度增加展现出了更高的效率。

4.多模态模型

检索关键词: 多模态,视觉,视频生成,Sora,Seedance

Answer

ByteDance's Seedance 2.0 is a multi-modal AI model for video generation, surpassing previous models like Sora. It integrates text, images, audio, and video inputs for synchronized output. Seedance 2.0 enhances motion modeling and audio-visual synchronization.

Sources

- **实测Seedance 2.0：当AI成为导演，Sora 2被超越了？** _ 东方财富网 (relevance: 80%) <https://finance.eastmoney.com/a/202602093645544648.html> 指数 期指 期权 个股 板块 排行 新股 基金 港股 美股 期货 外汇 黄金 自选股 自选基金. 资金流向 主力排名 板块资金 个股研报 新股申购 转债申购 北交所申购 AH股比价 年报大全 融资融券 龙虎榜 限售解禁 IPO 审核 大宗交易 估值分析. 实测Seedance 2.0：当AI成为导演，Sora 2被超越了？. 近日，字节跳动悄然上线了其新一代视频生成模型Seedance 2.0，搅动了AI视频比赛的进程。. 虽然字节官方还未对该模型进行官宣，仅从2月7日开始小范围内测，但新京报贝壳财经记者从朋友圈中已经感受到了大众对其生成效果的震撼。在社交平台，有创作者发出了“不需要人类了，AI...”
- **国产模型悄然打赢一场多模态战役 - 36氪** (relevance: 74%) <https://eu.36kr.com/zh/p/3739204925764102> 而在多模态赛道，文生视频已经进入激烈的内卷阶段，字节跳动凭借Seedance 2.0跻身全球第一梯队，可灵和Sora也紧随其后。相比之下，通义万相显得不温不火，在
- **字节跳动Seedance 2.0：当AI 视频生成学会了"听声辨位" - 知乎专栏** (relevance: 71%) <https://zhuanlan.zhihu.com/p/2028423289064661378> Seedance 2.0 真正的突破在于：它是一个原生的多模态音视频联合生成模型，能同时理解文字、图片、音频和视频四种输入，并输出画面与声音深度同步的内容。
- **字节跳动的Seedance 2.0人工智能视频生成器在一段病毒 ... - Reddit** (relevance: 70%) https://www.reddit.com/r/technology/comments/1r6aegw/bytedances_seedance_20_ai_video_generator_sparks/?tl=zh-hans 当Sora 发布时，他们没说太多。我把这叫做双重标准，更像是媒体在 ... 字节跳动发布Seedance 2.0视频模型，带有导演模式和多模态升级. 136 个点
- **Seedance 2.0 正式发布 - ByteDance Seed** (relevance: 62%) <https://seed.bytedance.com/zh/blog/official-launch-of-seedance-2-0> # Seedance 2.0 正式发布. 今天，我们正式发布新一代视频创作模型 Seedance 2.0。 . Seedance 2.0 采用统一的多模态音视频联合生成架构，支持文字、图片、音频、视频四种模态输入，集成了目前业界最全面的多模态内容参考和编辑能力。 . > https://seed.bytedance.com/seedance2_0. > 1) 即梦网页端-视频生成-选择 Seedance 2.0; . > 2) 豆包 App 对话框-Seedance2.0-选择 2.0 模型; . > 3) 火山方舟体验中心-选择 Doubao-Seedance-2.0。 . Seedance 2.0 能完...

4.算力卡

检索关键词: GPU,H100,B200,TPU,算力

Answer

ByteDance's MegaScale system uses 12,288 Ampere GPUs for large-scale AI training. H100, H200, and B200 GPUs differ in memory, bandwidth, and performance. B200 offers significant improvements in efficiency, bandwidth, and memory for large-scale AI applications.

Sources

- **[PDF] AI系列专题报告（一） - 算力** (relevance: 73%) https://pdf.dfcfw.com/pdf/H3_AP202506121689781660_1.pdf AI系列专题报告（一） 算力：算力基建景气度高，国产AI芯片发展势头良好 证券研究报告 分析师： 陈福栋S1060523070003（证券投资咨询） 分析师： 闫磊 S1060519100002（证券投资咨询） 平安证券研究所电子信息团队 2025年6月12日 请务必阅读正文后免责条款 电子行业强于大市（维持） 核心摘要 ☑AIGC蓬勃发展，对底层智能算力产生强劲需求。行业前期，训练是算力需求的主力，大量大模型训练需要海量算力支撑。2024年末，DeepSeek重磅发布，其轻量化、低成本、高性能特征大幅拉低了AI应用门槛，有望成为各类推理场景爆发的契机，推理算力市场需求潜力巨大。在此背景下...
- **一张图说清：H100、H200、B200 到底该怎么选？最近发现B200出来了以后，很多有算力需求的团队都蠢蠢欲动要上B - 掘金** (relevance: 70%) <https://juejin.cn/post/7586892413890068526> | NVLink | 第四代（900 GB/s） | 第四代 | 第五代（1.8 TB/s） | . H200 不是算力升级，而是显存与带宽升级，解决“跑不动”的问题；. B200 则是一次架构级跃迁，面向千卡集群、下一代 AI 工厂设计。 . | <7B 参数，微调/推理 | A10 / L4 / RTX 6000 Ada | 小模型对算力要求低，A10/L4 成本更低；H100 属性能过剩，仅在统一集群时考虑 | . | 7B-30B，全参训练 | H100 | 在 FP8 + 梯度检查点 + ZeRO 下可高效训练PyTorch/ TensorFlow 生态最成熟，调试工...
- **万字长文解析：从H100 到B200，GPGPU 与大模型扩展性深度分析** (relevance: 65%) <https://zhuanlan.zhihu.com/p/1985478405458788975> GPU 算力增速远超带宽提升,数据并行的临界Batch Size 从H100 的2500 tokens/GPU 激增到B200 的5625 tokens/GPU; 应对策略包括FP8/FP4 量化、MoE 稀疏
- **11.4 硬件选型：GPU、TPU 与专用加速器 | 大模型原理与架构 | LLM Internals** (relevance: 46%) https://yeasy.gitbook.io/llm_internals/di-san-bu-fen-tui-li-yu-bu-shu-pian/11_serving/11.4_hardware NVIDIA GPU 凭借 CUDA 生态的成熟度和 Tensor Core 的强大性能，是 LLM 训练和推理的首选。关键指标对比：. 表 11-2：NVIDIA 主要 GPU 型号对比（*表示该数值为 Tensor Core 峰值指标或包含稀疏性加速；在做密集 FP16 横向比较时应查看官方 dense throughput 口径）. 对于推理场景，**显存带宽**通常比算力更重要（10.1 节已解释生成阶段是访存密集型的）。H200 的 141 GB 显存使其可以在单卡上

运行 70B 的 INT4 量化模型，极大降低了部署复杂度。而 B200 的 192 GB 显存和 8 TB/s 带...

- **2026年4月算力产业链深度剖析：高端缺货、国产替代，三大策略揭秘！** (relevance: 40%) <https://www.gudaobang.com/view.php?id=2054> 2026-04-16 22:36:16 热度: 1,427 添加收藏. 结合 2026 年 4 月最新产业数据，对**算力租赁、AIDC、国产 GPU**三大核心板块逻辑进行交叉验证，更新**价格趋势、供需缺口、盈利质量、订单落地**四大关键维度，明确**高端算力稀缺性持续、AIDC 技术壁垒固化、国产 GPU 份额拐点确认**三大核心结论，同步优化标的策略与风险防控。 . 1. **技术壁垒再强化：液冷成为 AIDC 标配，PUE 成核心竞争指标** AI 集群单柜功耗突破 8-10kW（传统 IDC 仅 2-4kW），风冷散热彻底失效，**液冷 + 低 PUE**成为 AIDC...

4.数据存储

检索关键词: HBM,显存,存储,NVLink

Answer

ByteDance uses HBM and NVLink for high-speed data storage and processing. HBM offers high bandwidth and low latency. NVLink enables fast interconnect speeds for data transfer.

Sources

- **AI救活了一家马桶公司，也点燃了存储芯片超级周期 - 新浪财经** (relevance: 99%) [https://finance.sina.cn/stock/jdts/2026-04-11/detail-inhuazck1586282.d.html?oid=%EB%B0%94%EC%B9%B4%EB%9D%BC%EC%82%AC%EC%9D%B4%ED%8A%B8\[link:~KR1144.C%EB%B0%94%EC%B9%B4%EB%9D%BC%EC%82%AC%EC%9D%B4%ED%8A%B8oz9&vt=4&cid=7](https://finance.sina.cn/stock/jdts/2026-04-11/detail-inhuazck1586282.d.html?oid=%EB%B0%94%EC%B9%B4%EB%9D%BC%EC%82%AC%EC%9D%B4%ED%8A%B8[link:~KR1144.C%EB%B0%94%EC%B9%B4%EB%9D%BC%EC%82%AC%EC%9D%B4%ED%8A%B8oz9&vt=4&cid=7) 它的特点是速度极快，但断电就丢数据，属于“短期记忆”。其中，HBM（高带宽内存）是DRAM的一种特殊进化形态。它把多层DRAM
- **05.大模型推理与AI Infra(DONE) - GitHub** (relevance: 98%) <https://github.com/Infrasys-AI/AIInfra/blob/main/00Summary/05InferStack.md> HBM 是存储顶层，定位高速度低容量，服务实时计算数据：HBM 直接集成在计算芯片上，速度达TB/s 级，容量多为几十GB，成本每GB 约10 美元。推理中，HBM 核心存储高频数据：一是KV
- **【原创】传昇腾950PR获字节和阿里巴巴大单!销售预计过500亿！ | 电子创新网** (relevance: 74%) <https://www.eetrend.com/content/2026/100599853.html> # **【原创】传昇腾950PR获字节和阿里巴巴大单!** 据外媒报道，据两位知情人士透露（作者注：未经产业核实，请慎重对待此消息）华为昇腾950PR在中国客户测试进展顺利，包括字节跳动和阿里巴巴在内的多家科技巨头计划下单。 . 这一进展对华为而言具有里程碑意义，对中国AI市

场也具有重要里程碑意义。据透露，本土互联网大厂此次计划更广泛地使用新款 950PR 芯片，因为该芯片与英伟达 CUDA 软件系统的兼容性更强，响应速度也更快，这让他们更加满意。据透露，华为计划今年出货约 75 万颗 950PR 芯片，采用传统DDR显存的950PR显卡售价约为每张5万元人民币（约合6900美元），而配备速度更快的...

- **2026年AI Infra重点发展方向的深度分析** (relevance: 31%) <https://zhuanlan.zhihu.com/p/1999176653281187226> 节点内多路径互连（MIHF）架构将聚合PCIe、NVLink和CXL带宽，实现主机内存到GPU的高效数据供给，支撑“无限内存”训练。推荐系统的分层存储（HPS）：针对推荐
- **[PDF] 拥抱AI 和存储国产化机会** (relevance: 4%) <https://pic-test-gjmetal-1324067834.cos.ap-shanghai.myqcloud.com/news2/af21ee24dd424b1084b2762d94f030bf20251219184025.pdf> 中国存储公司的α：两存全球市占率提升可期 DRAM 侧，2024 年长鑫存储推出新一代16Gb DDR5 产品，跳过17nm（D1y）节点直接采用16nm（D1z）节点。产能和出货上，长鑫也在加速从DDR4/LPDDR4 向DDR5/LPDDR5 转移，根据Counterpoint 预测，2025Q1 长鑫存储按比特出货量全球市占率6%，预计2025Q4 将提升至8%；年底DDR5 市占率预计将从 2025Q1 的1%提升至7%，LPDDR5 预计将从2025Q1 的0.5%提升至9%。此外，AI 算力驱动下，国内HBM 及3D DRAM 产业化也有望加速，共同驱动存储产业...

4.数据加速

检索关键词: FlashAttention,量化,推理优化

Answer

FlashAttention optimizes large model training by reducing memory access and improving GPU efficiency. It uses hardware-aware algorithms to perform attention computations in faster SRAM. FlashAttention has been iteratively improved to better utilize hardware and reduce latency.

Sources

- **端侧AI Infra开发实习生-音视频技术 - 字节跳动招聘官网** (relevance: 62%) <https://jobs.bytedance.com/campus/m/position/detail/7594472672476760325?recomId=5a64c401-1efc-11f1-b8f3-043f72a6392c&sourceJobId=7532098404223666450> 1、负责模型推理全流程优化，低比特量化（AWQ、GPTQ、SpinQuant等）、模型剪枝、蒸馏等模型压缩技术，以及FlashAttention、KVCache高效管理、投机推理等推理优化手段

- **大厂大模型算法岗推理类面试题总结_牛客网** (relevance: 58%) <https://www.nowcoder.com/feed/main/detail/68262da0086c49dfad1848931306b17d> 02-22 21:56 中山大学 算法工程师 发布于山东. # 大厂大模型算法岗推理类面试题总结. KV Cache、PagedAttention、FlashAttention 等技术, 提升吞吐和显存利用率。字节跳动: 全面覆盖推理优化、推荐系统、多模态等多个方向, 考察系统化思维能力。PagedAttention、KV Cache、FlashAttention 核心技术的实现机制。➡➡积累实战经验: 准备具体的优化案例, 包括量化效果、延迟提升数据等量化指标。每个项目组的程序工程师入职之后的生存考核方式 每个项目组的程序工程师入职之后的生存考核方式决定他会如何成为一位合格的...
- **FlashAttention 系列技术详解: 加速大模型训练的利器 - 文章 - 开发者社区 - 火山引擎** (relevance: 50%) <https://developer.volcengine.com/articles/7444834108175286298> # FlashAttention 系列技术详解: 加速大模型训练的利器. ## FlashAttention 的解决方案. 为了解决上述问题, **FlashAttention** 提出了一种 **快速、节省内存、精确的注意力计算方法**, 通过减少内存读写次数, 提高 GPU 的内存 IO 效率, 加快训练速度, 并增加上下文窗口长度。其核心目标是通过 **硬件感知 (IO-awareness)** 的算法优化, 将整个注意力计算过程在更高速的 **SRAM** (静态随机存取存储器) 中完成, 减少对 HBM (高带宽内存) 的依赖。在传统的注意力机制中, 首先需要将输入矩阵从 HBM 中读取, 随后计算注意...
- **FlashAttention: 具有 IO 感知, 快速且内存高效的新型注意力算法** (relevance: 50%) https://www.high-flyer.cn/en/blog/flash_attn/ Transformer 模型的核心是自注意力机制 (self attention), 其在序列长度上时间和存储的复杂度都在 $O(N^2)$ 级别。随着大语言模型 (LLMs) 规模的不断扩大, 为 LLM 配备更长的上下文背景, 在工程实现上面临着非常大的挑战。以 A100 为例: A100 GPU 有 40~80GB 的高带宽内存 (HBM), 带宽为 1.5-2.0 TB/s, 而每 108 个流处理器有 192KB 的 SRAM, 带宽估计在 19TB/s 左右。可以看到虽然 SRAM 容量小了很多, 但是速度却提升了10倍, 所以如何高效的利用 SRAM 是提速注意力算法的关键。可以看到, masking, s...
- **FlashAttention系列演进: 从基础优化到硬件级加速的全面解析** (relevance: 41%) https://blog.csdn.net/weixin_29310605/article/details/158645138 文章浏览阅读83次。本文全面解析了FlashAttention系列从基础优化到硬件级加速的演进历程。FlashAttention通过分块计算和重计算技术, 将Transformer注意

4.Agent

检索关键词: 智能体,Agent,AutoGPT

Answer

Auto-GPT is an open-source AI agent framework that enables autonomous task execution. It is part of a broader trend of AI agents, including those from ByteDance and Alibaba, that leverage large language models for various applications.

Sources

- **AutoGPT-Forge使用教程，自行构建agent智能体 - CSDN博客** (relevance: 76%) https://blog.csdn.net/qq_33345365/article/details/138151006 AutoGPT是一个AI agent（智能体），也是开源的应用程序，结合了GPT ... 字节跳动的Coze平台或者百度的千帆平台，上面已经有很多通过大模型实现的
- **Agent调研--19类Agent框架对比（上）-阿里云开发者社区** (relevance: 72%) <https://developer.aliyun.com/article/1480814> [开发者社区](#). #### [人工智能](#). [发布](#). ... []([htt...](#)
- **agent是什么意思？2025最新的Agent智能体工具盘点 - 知乎专栏** (relevance: 70%) <https://zhuanlan.zhihu.com/p/1948476677979079677> AutoGPT是早期引爆AI Agent概念的开源项目之一，它展示了让GPT-4等大型语言模型实现完全自主任务执行的巨大潜力。作为一个开源框架，它吸引了大量的开发者
- **9个智能体平台和框架，有没有你不知道的** (relevance: 66%) <https://zhuanlan.zhihu.com/p/827742454> AutoGPT是最早出现的自主Agent框架，能够执行复杂任务并进行自我迭代。它想实现的是让AI Agent完全自主地理解问题，规划任务，创建 workflow，部署执行并监控。
- **AI Agent技术的最新进展与改变世界的典型项目巡礼** (relevance: 65%) <https://developer.volcengine.com/articles/7388907819530977291> 简介：虽然内部设计为单个智能体，但其自我批判的逻辑被视为多智能体策略的简化版本。AutoGPT能够根据反馈调整其行为，体现了智能体自我改进的能力。应用：

五、整体技术趋势判断

5.1 战略方向

基于2026年04月19日的检索结果，字节跳动的AI战略呈现以下特点：

1. 技术路线:
2. 产品布局:
3. 生态建设:

5.2 竞争态势

- vs OpenAI:
- vs Google:
- vs 国内竞品:

5.3 未来展望

预测字节跳动在未来3-6个月可能的技术/产品动向：

- 1.
- 2.
- 3.

六、参考来源

- Tavily Search 检索结果
- 企业官方博客/公告
- 技术媒体（量子位、机器之心等）
- 学术论文（arXiv）

本报告由 OpenClaw AI 系统自动生成

报告版本: v1.0

生成时间: Sun Apr 19 06:00:24 AM CST 2026