

智谱AI AI技术洞察报告

报告日期: 2026年04月19日

生成时间: 06:01:06

数据来源: Tavily Search, 企业博客, 新闻媒体

洞察范围: 模型发布、技术动态、产品更新

一、公司概况

公司名称: 智谱AI

主要产品: GLM, ChatGLM

检索优先级: 高

二、最新动态检索

2.1 产品/模型发布

Answer

ZhipuAI released the GLM-5V-Turbo model, integrating visual and coding capabilities for GUI control and multi-modal programming. The company continues to develop advanced AI models and open platforms. The latest model aims to enhance coding efficiency with visual understanding.

Sources

- **智譜勢將發布新一代AI模型加快步伐與DeepSeek展開競爭 - Yahoo 財經** (relevance: 100%) <https://hk.finance.yahoo.com/news/%E6%99%BA%E8%AD%9C%E5%8B%A2%E5%B0%87%E7%99%BC%E5%B8%83%E6%96%B0-%E4%BB%A3ai%E6%A8%A1%E5%9E%8B-%E5%8A%A0%E5%BF%AB%E6%AD%A5%E4%BC%90%E8%88%87deepseek%E5%B1%95%E9%9>

- **智谱于2025年7月28日发布并开源新一代旗舰模型GLM-4.5** (relevance: 100%) <https://www.zhihu.com/question/1933283098667251646> 最近，国产模型真是一个比一个还顶。刚刚，智谱发布了他们的新一代旗舰模型GLM-4.5，并在Hugging Face上同步开源。我提前拿到了内测，狠狠的跑了一
- **智谱.AI ZhipuAI - 组织详情** (relevance: 100%) <https://modelscope.cn/organization/ZhipuAI> 智谱AI由清华大学计算机系的技术成果转化而来。公司主导研发了多语言千亿级超大规模预 ... 已发布 GLM系列模型，包括预训练模型，对话模型，多模态模型以及代码生成模型。
- **智谱发布GLM-5V-Turbo 多模态Coding 基座模型，为龙虾安上眼睛** (relevance: 100%) <https://www.ithome.com/0/935/149.htm> 智谱GLM-5V-Turbo 原生融合视觉与编程能力，可看懂设计稿、网页截图等，直接生成可运行代码。模型支持200k 上下文，在GUI 操控、多模态编程等基准表现
- **智谱AI** (relevance: 100%) <https://bigmodel.cn/> 智谱大模型开放平台-新一代国产自主通用AI大模型开放平台，是国内大模型排名前列的大模型网站，研发了多款LLM模型，多模态视觉模型产品，致力于将AI产品技术与行业场景双轮

2.2 技术突破

Answer

The company has achieved significant breakthroughs in AI technology, particularly with its GLM series models, and aims to develop advanced general intelligence (AGI). It has been recognized as a leader in the global AI model market. The company's long-term goal is to achieve AGI through extensive research and development.

Sources

- **智谱GLM-5技术解密：如何用三大创新突破AI智能体工程瓶颈？** (relevance: 100%) <https://aiinking.com/article/37263> GLM-5的技术突破对AI行业产生了深远影响。首先，它证明了在单一MoE架构中统一Agent、推理与代码能力的可行性，这为后续模型设计提供了重要参考。
- **赛道Hyper | 智谱GLM-4.5：技术突破成因与行业价值 - 华尔街见闻** (relevance: 100%) <https://wallstreetcn.com/articles/3752410> 7月28日，智谱AI发布旗舰模型GLM-4.5并开源。GLM-4.5是一款专为智能体应用研发的基础模型，在性能、成本控制与多能力融合等方面均有出色

- **智谱冲破2000亿的秘密：为什么中国AI终于敢涨价了？ - DoNews** (relevance: 100%)
<https://www.donews.com/article/detail/5458/97228.html> 当OpenAI还在为免费用户的广告位发愁，Anthropic还在和奥特曼打口水战，智谱已经在国产算力底座上跑通了从技术突破到商业变现的完整闭环。智谱的股价
- **单日股价暴涨的秘密！智谱GLM-5技术细节全公开，纯国产算力跑出 ...** (relevance: 100%)
<https://www.woshipm.com/ai/6344309.html> 这款国产大模型不仅在长上下文处理能力上实现128K输出的突破，更通过数据炼金术与架构创新，证明了工业级AI应用的可行性。本文将深度拆解这份技术报告，揭示GLM-5如何从参数
- **智谱AI深度研究报告：技术、资本与商业化路径的全景剖析 - U深研** (relevance: 100%)
<https://unifuncs.com/s/jDsMFzqJ> 尽管风险显著，智谱的长期价值在于其AGI路径的系统性布局。L3自主学习能力已初步显现，GLM-4.5在Agent任务上的表现接近Claude 4 Sonnet，表明从"可用"到"好用"的跨越正在发生98zzGLM-4.5: Reasoning, Coding, and Agentic Abililties GLM-4.5: Reasoning, Coding, and Agentic Abilities (2025-07-28, 5个月前) Techniques Model Architecture & Pre-training In the GLM-4.5 series, we adopt ...

三、技术趋势分析

3.1 模型能力演进

基于检索结果分析智谱AI在以下方面的进展：

- **大语言模型:** 上下文长度、推理能力、多语言支持
- **多模态能力:** 图像理解、视频生成、跨模态交互
- **推理优化:** 思维链、深度推理、数学/代码能力

3.2 工程化进展

- **训练基础设施:** 算力规模、训练效率、成本控制
- **推理优化:** 量化技术、KV Cache优化、批处理策略
- **部署方案:** 云端API、边缘部署、私有化方案

四、关键技术点展开

4.大语言模型

检索关键词: LLM,大模型,GPT,Claude,Gemini

Answer

I am an AI system built by a team of inventors at Amazon. I provide information based on my training data. I do not identify as any specific model name.

Sources

- [illegible]

事。它的名字里藏着一个野心：从"vibe coding"（氛围编程）走向"agentic engineering"（智能体工程）...

- **大型語言模型列表**- 維基百科，自由的百科全書 (relevance: 53%) https://zh.wikipedia.org/wiki/%E5%A4%A7%E5%9E%B%E8%AF%AD%E8%A8%80%E6%A8%A1%E5%9E%B%E5%88%97%E8|T5&action=edit&redlink=1 "T5 (语言模型)（页面不存在）"）（英语：T5 (language model) "en:T5 (language model)"） | 000000002019-10-01-00002019年10月 | Google | 11 ! | LLaMA (Large Language Model Meta AI) | 000000002023-02-01-00002023年2月 | Meta AI | 65 ! | Gemini 1.5 "Gemini (语言模型)" | 000000002024-02-01-00002024年2月 | ...

4.推理模型

检索关键词: o1,R1,推理,思维链

Answer

The o1,R1 models use reasoning and thought chains for complex problem-solving. They generate step-by-step reasoning paths to improve accuracy. These models aim to match or exceed the performance of leading AI systems.

Sources

- **类o1系列模型大盘点：QwQ、Deepseek-R1、Marco-o1、Huatuo-o1** (relevance: 100%) <https://deepseek.csdn.net/67ab1e2879aaf67875cb9ab6.html> 模型会尝试不同的解决方案，并根据结果调整其推理路径。生成思路链：在推理过程中，模型会生成一个内部的思路链，记录每一步的推理过程和结果。这个思路链
- **国产AI卷翻硅谷，奥特曼发文“阴阳”，类o1模型都在卷什么？** (relevance: 100%) <https://zhuanlan.zhihu.com/p/19824257286> ... R1 ... 链思维推理方面取得了SOTA成绩。性能最强的long-CoT版本Kimi k1.5，数学、代码、多模态推理能力可以达到长思考SOTA模型OpenAI o1正式版的水平。
- **g1：o1推理链开源实现，原理竟如此简单！解决60-80%的困扰LLM ...** (relevance: 100%) <https://cloud.tencent.com/developer/article/2472870> OpenAI 的o1 在复杂任务表现卓越，相关开源项目g1 模仿其思维链，基于Groq 模型和动态提示词，能提高推理能力，在部分问题上准确率显著高于原始模型，但仍有局限，
- **ChatGPT两周年，国产o1大模型们紧追不舍 - 创业邦** (relevance: 100%) <https://m.cyzone.cn/article/783456> 以智谱的“会反思的AI搜索”为例，结合思维链能力，让AI能

够将复杂问题拆解成多个步骤，进行逐步搜索和推理。通过联网搜索+ 深度推理，再将所有答案信息综合整理到一起，AI能够给

- **AI大神力挺的「智能体式思考」，DeepSeek式思考的终结？ - 雷科技** (relevance: 100%) <https://www.leikeji.com/article/75823> 对比之下，以OpenAI o1、DeepSeek R1 为代表的推理模型，更多还是在「颅内推演」，最后直接输出一个回答。不是说纯推理式思考没有价值，但更适用于

4.多模态模型

检索关键词: 多模态,视觉,视频生成,Sora,Seedance

Answer

Sora has been discontinued, and Seedance 2.0 is now leading in AI video generation. PrismAudio by Alibaba excels in video-to-audio generation. Seedance 2.0 allows for precise control over visual references, enhancing its directorial capabilities.

Sources

- **Sora下架，阿里“欢乐马”登顶：中美AI视频模型开始分道扬镳_腾讯新闻** (relevance: 80%) https://news.qq.com/rain/a/20260413A063VU00?adChannelId=news_news_top # Sora下架，阿里“欢乐马”登顶：中美AI视频模型开始分道扬镳. 2026-04-13 16:57发布于北京腾讯新闻《深网》栏目官方账号. 4月初，名叫HappyHorse-1.0（又被称“欢乐马”）的匿名模型悄悄出现在Artificial Analysis旗下Video Arena盲测榜单上。. 图生视频(无音频)榜单上，它拿到1411分登顶，把Seedance 2.0甩出约55分；在文生视频(无音频)一栏，1379分同样排在字节跳动Seedance 2.0、快手可灵AI 3.0、昆仑万维SkyReels V4等公开产品前。. 从4月7日开始的两天里，这匹马的“主人”成了AI圈最热的一道...
- **一键生成“换脸”视频作品 真假难辨的AI内容该如何监管？_新闻频道_央视网(cctv.com)** (relevance: 70%) <https://news.cctv.com/2026/02/15/ARTIBxzqjnss6bgkHQ8mKqC9260215.shtml> # 一键生成“换脸”视频作品 真假难辨的AI内容该如何监管？. 来源：央视新闻 | 2026年02月15日 06:44:53. 央视新闻 | 2026年02月15日 06:44:53. ##### 原标题：. 这几天，国内AI大模型都在密集上线新的版本，其中，国内平台进行内测的新一代视频生成模型，就给相关行业带来了巨大的震撼。只要输入简单的文字描述，然后一键点击，这个大模型就能自动生成包含多镜头切换、连贯叙事和同步音效的视频作品，影视制作的门槛大大降低，甚至有人惊呼，以后做一部电影只需要导演一个人就够了。. 但惊喜背后，惊吓也随之而来，由该平台生成的明星、演员的视频在网络疯传，真假难辨的程度...

- **国产模型悄无声息地赢得了一场多模态战役_人工智能_中國龍在廣州-AtomGit开源社区** (relevance: 65%) <https://gitcode.csdn.net/69c7443354b52172bc651536.html> # logo AtomGit开源社区. ## 登录社区云. ### AtomGit开源社区. ## 温馨提示：您尚未绑定手机号. # 国产模型悄无声息地赢得了一场多模态战役. ### 中國龍在廣州. Seedance 2.0凭借它的强大能力，已经被人们视为未来制作电影的“神器”，而它现在唯一存在的尴尬之处，就在于缺少配音。. 音频生成看起来比视频生成要简单，但给视频精准配音（Video-to-Audio, V2A）却十分困难：完美的配音不仅要“贴脸（语义与声音同步）”，还要做到“好听（美学质量）”和“身临其境（空间立体声）”。. 为了补齐视频生成模型“走向电影”的短板，阿里通义实验室和香港科技...
- **字节跳动Seedance 2.0：当AI 视频生成学会了"听声辨位" - 知乎专栏** (relevance: 65%) <https://zhuanlan.zhihu.com/p/2028423289064661378> Seedance 2.0 真正的突破在于：它是一个原生的多模态音视频联合生成模型，能同时理解文字、图片、音频和视频四种输入，并输出画面与声音深度同步的内容。
- **生成式 AI 模型 Seedance 2.0：全方位参考指南 - Atlas Cloud Blog** (relevance: 61%) <https://www.atlascloud.ai/zh/blog/case-studies/generative-ai-model-seedance-2-0-a-guide-to-all-round-reference> # 生成式 AI 模型 Seedance 2.0：全方位参考指南. ### Seedance 的优势：身份锁定与动作迁移. 获取 Seedance 2.0 的方式取决于你的具体需求——无论你是个人爱好者，还是希望将 AI 集成到全球营销视觉识别活动中的企业。. Atlas Cloud Seedance 2.0 Video Models. Atlas Cloud Seedance 2.0 Video Models. #### Seedance 2.0 教程：操作企业控制台. 3api_url = "https://api.atlascloud.ai/v1/video/generation..."

4.算力卡

检索关键词: GPU,H100,B200,TPU,算力

Answer

H100, B200, and TPU are AI accelerators; H100 offers high performance, B200 has significant memory and bandwidth, and TPU provides specialized deep learning processing.

Sources

- **万字长文解析：从H100 到B200，GPGPU 与大模型扩展性深度分析** (relevance: 100%) <https://zhuanlan.zhihu.com/p/1985478405458788975> GPU 算力增速远超带宽提升,数据并行的临界Batch Size 从H100 的2500 tokens/GPU 激增到B200 的5625 tokens/GPU; 应对策略包括FP8/FP4 量化、MoE 稀疏

- **GH200，一個伺服器機櫃共有32顆H100，GB200在GPU數量上提升 ...** (relevance: 100%) <https://www.threads.com/@wukt999/post/C5LEhbcRnve> DGX B200，為8顆B200，每個B200 是由2個B100組成-DGX H100，為8顆H100 GB200，一個伺服器機櫃共有144顆B100 -GH200，一個伺服器機櫃共有32顆H100，GB200在GPU
- **芯片推理速度是英伟达的21倍，成本低30%，奥特曼早早投资了** (relevance: 100%) <https://www.51cto.com/aigc/9921.html> 这种技术路线与英伟达AI GPU算力体系以及谷歌TPU(AI ASIC技术路线)都截然 ... 智谱AI开源6款模型，推理速度200 tokens/秒碾压竞品，价格仅1/30
- **11.4 硬件选型：GPU、TPU 与专用加速器| 大模型原理与架构 - GitBook** (relevance: 100%) https://yeasy.gitbook.io/llm_internals/di-san-bu-fen-tui-li-yu-bu-shu-pian/11_serving/11.4_hardware NVIDIA GPU 凭借 CUDA 生态的成熟度和 Tensor Core 的强大性能，是 LLM 训练和推理的首选。关键指标对比：. 表 11-2：NVIDIA 主要 GPU 型号对比（*表示该数值为 Tensor Core 峰值指标或包含稀疏性加速；在做密集 FP16 横向比较时应查看官方 dense throughput 口径）。对于推理场景，**显存带宽**通常比算力更重要（10.1 节已解释生成阶段是访存密集型的）。H200 的 141 GB 显存使其可以在单卡上运行 70B 的 INT4 量化模型，极大降低了部署复杂度。而 B200 的 192 GB 显存和 8 TB/s 带...
- **一张图说清：H100、H200、B200 到底该怎么选？ - 博客园** (relevance: 100%) <https://www.cnblogs.com/AlayaNeW/articles/19388803> H100 是当前生态最成熟、交付最稳定的“主力卡”；
 - H200 不是算力升级，而是显存与带宽升级，解决“跑不动”的问题；
 - B200 则是一次架构级跃迁，面向千卡集群、下

4.数据存储

检索关键词: HBM,显存,存储,NVLink

Answer

HBM provides high bandwidth for GPU computing, NVLink enhances inter-GPU communication, and storage solutions like HBM and NVLink improve AI model training and inference efficiency.

Sources

- **AI芯片与数据中心关键技术 - 知乎专栏** (relevance: 100%) <https://zhuanlan.zhihu.com/p/3914664135> 模型训练和推理过程中，显存不仅决定了模型的大小和数据处理能力，还直接影响GPU的计算效率。HBM主要是由DRAM进行多层封装实现的，因此正好满足了GPU对计算时高带宽访存的

Sources

- **大模型训练加速之FlashAttention系列：爆款工作背后的产品观** (relevance: 66%) <https://zhuanlan.zhihu.com/p/664061672> FlashAttention (FA) 是一系列针对Transformer模型训练和推理加速方案。自从去年（2022年）五月发布以来，历经了多次迭代，并借着其节省显存、加速计算、
- **从FlashAttention到FlashDecoding：大模型推理加速的演进之路** (relevance: 58%) <https://blog.csdn.net/web39explorer/article/details/151979458> 所以，优化大模型推理速度，尤其是解码（生成）阶段的速度，首要目标不是让计算单元（CUDA Core）算得更快，而是想尽办法减少数据搬运的次数和数量，让数据尽可能待
- **大模型推理加速技术：FlashAttention原理与实现 - 阿里云开发者社区** (relevance: 58%) <https://developer.aliyun.com/article/1685039> FlashAttention的核心思想是通过分块计算避免存储完整的注意力矩阵，实现IO复杂度从 $O(N^2)$ 到 $O(N)$ 的优化。
- **FlashAttention 系列技术详解：加速大模型训练的利器** (relevance: 51%) <https://developer.volcengine.com/articles/7444834108175286298> # FlashAttention 系列技术详解：加速大模型训练的利器. ## FlashAttention 的解决方案. 为了解决上述问题，**FlashAttention** 提出了一种 **快速、节省内存、精确的注意力计算方法**，通过减少内存读写次数，提高 GPU 的内存 IO 效率，加快训练速度，并增加上下文窗口长度。其核心目标是通过 **硬件感知（IO-awareness）** 的算法优化，将整个注意力计算过程在更高速的 **SRAM**（静态随机存取存储器）中完成，减少对 HBM（高带宽内存）的依赖。在传统的注意力机制中，首先需要将输入矩阵从 HBM 中读取，随后计算注意...
- **通俗易懂聊flashAttention的加速原理 - 知乎专栏** (relevance: 51%) <https://zhuanlan.zhihu.com/p/672698614> flashAttention其加速的原理是非常简单的，也是最基础和常见的系统性能优化的手段，即通过利用更高速的上层存储计算单元，减少对低速更下层存储器的访问次数，

4.Agent

检索关键词: 智能体,Agent,AutoGPT

Answer

I am an AI system built by a team of inventors at Amazon. I provide information based on my programming and existing knowledge. I do not identify as any specific model name.

Sources

- **智谱AI开放平台** (relevance: 76%) <https://open.bigmodel.cn/>   https://cdn.bigmodel.cn/static/platform/images/activity/university/pop_right_bottom_new.png...
 - **[PDF] 智谱发布AI Agent AutoGLM 沉思** (relevance: 73%) https://pdf.dfcfw.com/pdf/H3_AP202504011649808739_1.pdf?1743498170000.pdf [Table_RightTitle] 证券研究报告|计算机 [Table_Title] 智谱发布AI Agent AutoGLM 沉思，将迎来 智谱 “开源年” [Table_IndustryRank] 强于大市(维持) [Table_ReportType] ——计算机行业快评报告 [Table_ReportDate] 2025 年03 月31 日 [Table_Summary] 事件：2025 年3 月31 日，智谱在中关村论坛上正式发布AutoGLM 沉思，据介 绍这是首个集深度研究与实际操作能力于一体的Agent。目前， AutoGLM 沉思在智谱清言PC 客户端上线，用户可免费体验其...
 - **智谱发布全新Agent，集深度研究和操作执行于一体** (relevance: 63%) <https://zhuanlan.zhihu.com/p/1890064406051813020> 智谱在AI Agent领域的研发，包括从最早推出具备Function Call能力的智谱清言，到率先上线支持智能体编排的GLMs，再到推出全球首个设备操控智能体AutoGLM。
 - **智能体开发平台 - 智谱AI开放文档** (relevance: 62%) <https://docs.bigmodel.cn/cn/guide/platform/intelligent-agent> ## 1. ## 2. ## 3. ## 4. 您创建的智能体通常会有 4 个初始变量，分别是 `{{对话记录}}`、`{{用户-对话}}`、`{{LLM/Agent}}`、`{{当前时间}}` Description. ### 4.4 Agent 节点. Description **功能介绍**：您可以使用 Agent 节点丰富自己的智能体功能：**. Prompt 输入框**：编辑 Prompt 的区域，默认为 system prompt。全屏后的高级模式支持分别输入 System Prompt 和 User Prompt。点击 Prompt 输入框右下角进入全屏模式后，在左上角进入...
 - **智谱发布AutoGLM 2.0，“云手机”能否实现Agent全自动操作？** (relevance: 61%) <https://www.stcn.com/article/detail/3202210.html> 要闻 金融 评论 产经 创投 滚动. A股 公司 新股 基金 港美股. 智谱发布AutoGLM 2.0，“云手机”能否实现Agent全自动操作？. 来源：界面新闻作者：伍洋宇2025-08-20 14:51. 8月20日，智谱发布AI Agent产品 AutoGLM 2.0，由最新开源模型GLM-4.5与GLM-4.5V驱动，面向普通用户开放。团队表示，AutoGLM本次为iOS、安卓、网页全平台上线，接下来会保持1-2周一次新feature（功能）发布的节奏。. AutoGLM 2.0定位为可直接“点、拖、输”的执行型智能体，相比把答案写在对话框里的传统助手...
-

五、整体技术趋势判断

5.1 战略方向

基于2026年04月19日的检索结果，智谱AI的AI战略呈现以下特点：

1. 技术路线:
2. 产品布局:
3. 生态建设:

5.2 竞争态势

- vs OpenAI:
- vs Google:
- vs 国内竞品:

5.3 未来展望

预测智谱AI在未来3-6个月可能的技术/产品动向：

- 1.
- 2.
- 3.

六、参考来源

- Tavily Search 检索结果
- 企业官方博客/公告
- 技术媒体（量子位、机器之心等）
- 学术论文（arXiv）

本报告由 OpenClaw AI 系统自动生成

报告版本: v1.0

生成时间: Sun Apr 19 06:01:27 AM CST 2026