

阿里巴巴 AI技术洞察报告

报告日期: 2026年04月19日

生成时间: 06:00:24

数据来源: Tavily Search, 企业博客, 新闻媒体

洞察范围: 模型发布、技术动态、产品更新

一、公司概况

公司名称: 阿里巴巴

主要产品: 通义千问, Qwen

检索优先级: 高

二、最新动态检索

2.1 产品/模型发布

Answer

Alibaba released its third proprietary AI model, Qwen3.6-Plus, to enhance business monetization. The model focuses on large language capabilities. This marks a significant step in Alibaba's AI strategy.

Sources

- 阿里巴巴发布第三款闭源AI模型，加速业务变现 - 凤凰网财经 (relevance: 88%) <https://finance.ifeng.com/c/8s1HhJLljsA> 阿里巴巴在三天内发布了第三款自研人工智能模型，凸显公司正加大力度从其核心AI服务中获利。这家电商巨头周四发布了新一代大语言模型 Qwen3.6-Plus。此前，该公司刚发布
- 阿里巴巴发布用于现实世界应用的人工智能模型 - Binance (relevance: 87%) <https://www.binance.com/zh-CN/square/post/290065305813569> 阿里巴巴推出了一种新的人工智能模型，旨在增强机器人和其他设备在执行现实世界任务中的能力。由阿里巴巴研究院开发的人工智能模型，旨在为需要高精度和

- **阿里巴巴发布第三款闭源AI模型加速业务变现 - 新浪财经** (relevance: 86%) <https://finance.sina.com.cn/roll/2026-04-03/doc-inhtetzf3832412.shtml> 阿里巴巴三天内发布第三款自研AI模型，加大从核心AI服务获利力度。4月2日发布新一代大语言模型Qwen3.6 - Plus，此前还发布图像生成平台升级版和多模态
- **阿里巴巴發布新款Qwen3.5模型瞄準「代理AI時代」 | 鉅亨網 - 美股雷達** (relevance: 83%) <https://news.cnyes.com/news/id/6345749> ### 鉅亨熱AI. ### 人氣排行. ### 主編精選. ### 鉅亨講座. ### 熱門時事. ### . ### . ### . ### 鉅亨熱基金. ### 熱門排行. ### 台股專家觀點. # 阿里巴巴發布新款Qwen3.5模型瞄準「代理AI時代」. 鉅亨網編譯羅昀玫 2026-02-17 05:10. 阿里巴巴 (Alibaba) 週一 (15 日) 宣布推出新一代人工智慧模型 Qwen3.5，主打可獨立執行複雜任務，並鎖定「代理 AI」(agentic AI) 應用場景。 . 阿里巴巴表示，Qwen3.5 在效能與成本方面大幅升級，使用成本較前一代降低 60%...
- **阿里巴巴發布第三款閉源AI模型加速業務變現 - Yahoo 財經** (relevance: 83%) <https://hk.finance.yahoo.com/news/%E9%98%BF%E9%87%8C%E5%B7%B4%E5%B7%B4%E7%99%BC%E5%B8%83%E7%AC%AC%E5%8A%A0%E9%80%9F%E6%A5%AD%E5%8B%99%E8%AE%8A%E7%8F%BE-114129870.html> 【彭博】-- 阿里巴巴在三天內發布了第三款自研人工智能模型，凸顯公司正加大力度從其核心AI服務中獲利。 這家中國電商巨頭周四發布了新一代大語言

2.2 技术突破

Answer

Alibaba focuses on AI breakthroughs, including AGI and ASI development, and plans massive investments in AI infrastructure. The company aims to lead in AI technology and applications globally.

Sources

- **《麻省理工科技评论》全球十大突破性技术，阿里巴巴正研究其中4项** (relevance: 74%) <https://zhuanlan.zhihu.com/p/34029781> 中国科技巨头阿里巴巴成为给所有人的人工智能（云端AI）、对抗性神经网络、传感城市、材料的量子飞跃四项技术主要研究者。“全球十大突破性技术”是科技领域
- **清华大学联手阿里巴巴重大突破：让AI生成图像变得更快更聪明的全新 ...** (relevance: 69%) <https://www.techwalker.com/2025/1208/3174881.shtml> 清华大学和阿里巴巴联合研究团队提出了一种名为"反向表示对齐"的创新方法，显著改进了正规化流这类AI图像生成模型。通过在生成过程而非编码过程中注入

- **AI终极目标是造福社会**阿里巴巴唯一的方向就是**不断创新** - 搜狐 (relevance: 60%) https://www.sohu.com/a/1000103595_121857546 在他看来，中国AI突破取决于我们基于共赢互利的开源信念。2025年，中国开源模型的全球下载量领先世界，让全球各地的开发者都能免费获取、微调并部署这些强大
- **阿里巴巴公布十大科技趋势** (relevance: 60%) <https://tapmedia-th.com/blog-cn/tt57> # 阿里巴巴公布十大科技趋势. ##### **【趋势一】以氮化镓、碳化硅为代表的第三代半导体迎来应用大爆发.** 具备耐高温、耐高压、抗辐射等优异特性的第三代半导体材料，随着性价比优势逐渐显现，将被广泛运用到新产业中。近年来，碳化硅（SiC）元件已用作汽车逆变器，氮化镓（GaN）快速充电器也大量上市。. 未来五年，基于第三代半导体材料的电子器件将广泛应用于5G基站、新能源汽车、特高压、数据中心等场景。 . ##### **【趋势二】后“量子霸权”时代，量子纠错和实用优势成核心命题.** 2020年为后“量子霸权”元年，世界对量子计算的投入持续上涨，技术和生态蓬勃发展，多个平台异彩缤纷。 . 这一潮流...
- **阿里核爆级AI战略十大要点，全球资本燃情 | 解构阿里系 - 21经济网** (relevance: 56%) <https://www.21jingji.com/article/20250924/herald/44099dd4d321d46e5d5a6813728e9cea.html> 首页 宏观 公司 金融 证券 全球 观点 汽车 新健康 人文 创投 智库 更多). 大湾区 一带一路 文旅 理财 投资通 21视频 直播 品牌活动. # 阿里核爆级AI战略十大要点，全球资本燃情 | 解构阿里系. ##### 2025年09月24日 18:24 21世纪经济报道 21财经APP 陶力. 9月24日，阿里巴巴港股全天大涨9.14%，股价创下2021年10月以来新高，市值一日暴增近3000亿。本月该股已累计上涨超四成，年内涨幅接近翻倍。截至发稿，其总市值达到3.32万亿港元。从美股层面来看，当地时间周一，华尔街明星基金经理“木头姐”凯茜·伍德（Cathie Wood）管理的...

三、技术趋势分析

3.1 模型能力演进

基于检索结果分析阿里巴巴在以下方面的进展：

- **大语言模型:** 上下文长度、推理能力、多语言支持
- **多模态能力:** 图像理解、视频生成、跨模态交互
- **推理优化:** 思维链、深度推理、数学/代码能力

3.2 工程化进展

- **训练基础设施:** 算力规模、训练效率、成本控制
 - **推理优化:** 量化技术、KV Cache优化、批处理策略
 - **部署方案:** 云端API、边缘部署、私有化方案
-

四、关键技术点展开

4.大语言模型

检索关键词: LLM,大模型,GPT,Claude,Gemini

Answer

I am an AI system built by a team of inventors at Amazon. I do not identify as any specific model name. My purpose is to provide factual, concise information.

Sources

- **台灣企業LLM 選型指南2026：GPT、Claude、Gemini - LargitData** (relevance: 100%) <https://www.largitdata.com/knowledge/taiwan-enterprise-llm-guide/> 大型語言模型（LLM）已成為企業AI 轉型的核心引擎，但面對OpenAI GPT-4o、Anthropic Claude 3.5、Google Gemini 1.5、Meta Llama 3 等眾多選項，台灣企業
- **2026年十大最佳大型语言模型（LLM） - Botpress** (relevance: 100%) <https://botpress.com/zh-cn/blog/best-large-language-models> Abstract illustration with colorful shapes. * 最适合对话的LLM（如GPT-4o和Claude Sonnet 4）擅长处理细腻的对话、上下文保持和语气切换，而以推理为主的模型（如DeepSeek R1和Gemini 2.5 Pro）则能应对复杂的多步任务。 . ### OpenAI. ### Anthropic. ### Google DeepMind. ### DeepSeek. | 模型 | 语音支持 | 上下文窗口 | 费用（每百万tokens） | . | Claude 4 Sonnet | ☒ 200K | 输入\$3 / 输出\$15 |
- **GLM-5.1 vs Claude、GPT、Gemini、DeepSeek：智譜AI最新模型的 ...** (relevance: 100%) <https://wavespeed.ai/blog/zh-tw/posts/glm-5-1-vs-claude-gpt-gemini-deepseek-llm-comparison/> 智譜AI的GLM-5.1宣稱達到Claude Opus 4.6程式編寫效能的94.6%——完全基於華為晶片訓練並開放權重。以下是其與2026年各主流大型語言模型的全面對比。
- **2025大模型最全复盘：“中国开源” 崛起、OpenAI “走下神坛”、Vibe Coding提升10倍生产力！ - 智源社区** (relevance: 100%) <https://hub.baai.ac.cn/view/51654>
- 2025 年，是 OpenAI 失去领先优势，谷歌迎头赶上的一年，Gemini 3.0 和 Nano Banana 让 OpenAI 的 GPT-5 系列模型黯然失色，而且好像，“整个行业都已经追了上来”。 . * 2025 年，Coding Agent 和 Claude Code 成为了大模型价值落地的真正所在，越来越多的开发者、甚至编程小白都可以通过 Vibe Coding 的方式提升 10 倍生产力。 . Claude Code 网页版被我称为异步编程智能体，这种系统在下达指令后就可以不用管它，它会独立钻研问题，并在完成后直接提交一个拉取请求。OpenAI 的 “Codex cloud” ...

- **2025：大语言模型（LLM）之年-36氪** (relevance: 100%) <https://m.36kr.com/p/3640423298125193> OpenAI 在 2024 年 9 月用 o1 和 o1-mini 开启了“推理”革命，也叫做推理侧扩展或可验证奖励强化学习（RLVR）。在 2025 年初，他们通过推出 o3、o3-mini 和 o4-mini 进一步强化了这一优势。自此，“推理”已成为几乎每家主流 AI 实验室模型的招牌功能。一个显著的成果是 AI 辅助搜索现在真的变好用了。以前将搜索引擎连接到 LLM 的效果差强人意，但现在我发现，即使是复杂的调研问题，ChatGPT 的 GPT-5 Thinking 通常也能给出答案。Claude Code 是我所谓的“编程智能体”最杰出的代表——这种 LLM 系统可以编写代码...

4.推理模型

检索关键词: o1,R1,推理,思维链

Answer

Alibaba's DeepSeek R1 is a reinforcement learning-based reasoning model, comparable to OpenAI's o1, emphasizing "thinking chain" processes for improved logic and reasoning. It supports multi-task generalization and self-improvement.

Sources

- **DeepSeek 开源R1 系列推理模型，性能对标OpenAI o1，基于纯强化 ...** (relevance: 100%) <https://developer.aliyun.com/article/1650188> DeepSeek R1-Zero 是一款基于纯强化学习的开源推理模型，无需监督微调数据，支持多任务泛化与自我进化，适用于数学推理、代码生成等场景。
- **旺精通~阿里START：自学工具调用的长思维链推理模型 - 知乎专栏** (relevance: 100%) <https://zhuanlan.zhihu.com/p/32078743531> 随后，以OpenAI-o1（OpenAI，2024b）和DeepSeek-R1（DeepSeek-AI，2025）为代表的强化学习取得突破，建立了一种名为长思维链的新范式，该范式模仿人类的认知策略，
- **什么是推理大模型？DeepSeek R1推理大模型与DeepSeek V3模型的 ...** (relevance: 100%) <https://deepseek.csdn.net/67c7c668807ce562bfda7294.html> 由于OpenAI o1模型的训练使用了一种新的AI训练方法，强调了“思维链”过程和强化学习的重要性，最终导致它在数学逻辑和推理方面有了大幅提升，大家开始称这里有
- **OpenAI 新作：推理模型在控制思维链上面临困难 - 知乎专栏** (relevance: 100%) <https://zhuanlan.zhihu.com/p/2014418635104470117> 该研究探讨了现代推理模型（如o1、DeepSeek R1 等）是否能够为了逃避监控而有意控制其思维链（Chain-of-Thought, CoT）的内容。主要发现一：推理模型在控制

- **模型思考效率评测最佳实践 - EvalScope** (relevance: 100%) https://evalscope.readthedocs.io/zh-cn/v0.13.0/best_practice/think_eval.html 特别是对于R1类模型，其输出通常包含较长的思维链，输出token数量往往超过1万。使用高效的推理框架部署模型可以显著提高推理速度。下面以DeepSeek-R1-Distill-Qwen-7B为例，

4.多模态模型

检索关键词: 多模态,视觉,视频生成,Sora,Seedance

Answer

Alibaba's HappyHorse model outperformed Seedance 2.0 in AI video generation tests, signaling a shift in the competitive landscape. HappyHorse integrates text, video, and audio in a single model, focusing on faster inference speeds. The model's success highlights Alibaba's strategic advancements in AI video technology.

Sources

- **Sora下架，阿里“欢乐马”登顶：中美AI视频模型开始分道扬镳_腾讯新闻** (relevance: 82%) <https://news.qq.com/rain/a/20260413A063VU00?adChannelId=news?#> Sora下架，阿里“欢乐马”登顶：中美AI视频模型开始分道扬镳. 2026-04-13 16:57发布于北京腾讯新闻《深网》栏目官方账号. 4月初，名叫HappyHorse-1.0（又被称“欢乐马”）的匿名模型悄悄出现在Artificial Analysis旗下Video Arena盲测榜单上。. 图生视频(无音频)榜单上，它拿到1411分登顶，把Seedance 2.0甩出约55分；在文生视频(无音频)一栏，1379分同样排在字节跳动Seedance 2.0、快手可灵AI 3.0、昆仑万维SkyReels V4等公开产品前。. 从4月7日开始的两天里，这匹马的“主人”成了AI圈最热的一道...
- **Sora 时代后的轻量级替代方案：阿里巴巴极具性价比的AI 视频生成器** (relevance: 67%) <https://www.atlascloud.ai/zh/blog/guides/wan-2-6-api-guide> 一个API Key 即可访问Wan 2.6 及其他300 多种模型，包括Seedance 2.0、Kling 3.0、Veo 3.1 和Sora 2。无需创建多个账号，统一计费，并提供全英文文档和支持。
- **神秘模型屠榜多日、碾压Seedance 2.0! 背后竟是阿里大招：新部门 ...** (relevance: 63%) <https://www.infoq.cn/article/H6Y6KmRbTKapOjYmTU63> 其独特之处就在于音视频联合生成架构，由一个统一的Transformer 架构同时完成两项任务。它能在单次推理过程中一次性同步生成视频与音频，而非先出视频、后期
- **【Seedance 2.0 技术解析】：字节跳动电影级多模态视频生成模型 ...** (relevance: 61%) <https://developer.aliyun.com/article/1724018> 字节跳动于2026年2月发布Seedance 2.0，登顶AI视频生成Elo榜（1269分）。其首创双分支扩散Transformer（DB-DiT），实现原生音画同步、60秒2K视频、8+语言唇

- **Seedance2.0春晚出圈，AI视频应用浮现哪些风口？ - 21经济网** (relevance: 59%) <https://www.21jingji.com/article/20260219/herald/2ab78178c06af2dfcbc10436f3c8805a.html>
首页 宏观 公司 金融 证券 全球 观点 汽车 新健康 人文 创投 智库 更多). 大湾区 一带一路 文旅 理财 投资通 21视频 直播 品牌活动. # Seedance2.0春晚出圈，AI视频应用浮现哪些风口？ . ##### 2026年02月19日 12:41 财联社. 2026年央视马年春晚热点纷呈，人形机器人扎堆亮相的同时，Seedance 2.0大模型以春晚为首个公开应用场景完成首秀，深度参与多项节目视觉制作。 . 本届春晚中，“AI生成影像+实景舞台扩展”的创新模式引发全网热议，而Seedance 2.0正是这一模式的核心技术支撑，参与了《贺花神》、《驭风歌》、《快乐小马》等节目...

4.算力卡

检索关键词: GPU,H100,B200,TPU,算力

Answer

The H100 and B200 GPUs from Nvidia offer high computational power for AI tasks, with the B200 providing superior bandwidth and efficiency for large-scale training. The H100 is suitable for training large models, while the B200 is designed for extreme scalability and efficiency.

Sources

- **地球上算力芯片参数汇总、整理、对比- 吴建明wujianming - 博客园** (relevance: 76%) <https://www.cnblogs.com/wujianming-110117/p/18886018> # 吴建明. ## 微信视频号: sph0RgSyDYV47z6 快手号: 4874645212 抖音号: dy0so323fq2w 小红书号: 95619019828 B站1: UID:3546863642871878 B站2: UID: 3546955410049087 知乎视频: https://www.zhihu.com/people/wujianming_110117/zvideos 知乎: https://www.zhihu.com/people/wujianming_110117. # 地球上算力芯片参数汇总、整理、对比. AI大模型能力的快速提升（如Qwen3、Llama4的多模态升级与逻...
- **[PDF] AI系列专题报告（一） - 算力** (relevance: 68%) https://pdf.dfcfw.com/pdf/H3_AP202506121689781660_1.pdf AI系列专题报告（一） 算力：算力基建景气度高，国产AI芯片发展势头良好 证券研究报告 分析师： 陈福栋S1060523070003（证券投资咨询） 分析师： 闫磊 S1060519100002（证券投资咨询） 平安证券研究所电子信息团队 2025年6月12日 请务必阅读正文后免责条款 电子行业强于大市（维持） 核心摘要 ☑AIGC蓬勃发展，对底层智能算力产生强劲需求。行业前期，训练是算力需求的主力，大量大模型训练需要海量算力支撑。2024年末，DeepSeek重磅发布，其轻量化、低成本、高性能特征大幅拉低了AI应用门槛，有望成为各类推理场景爆发的契机，推理算力市场需求潜力巨大。在此背景下...

- **一张图说清：H100、H200、B200 到底该怎么选？ - 稀土掘金** (relevance: 65%) <https://juejin.cn/post/7586892413890068526> | NVLink | 第四代 (900 GB/s) | 第四代 | 第五代 (1.8 TB/s) | . H200 不是算力升级，而是显存与带宽升级，解决“跑不动”的问题；. B200 则是一次架构级跃迁，面向千卡集群、下一代 AI 工厂设计。 . | **<7B 参数，微调/推理 | A10 / L4 / RTX 6000 Ada** | 小模型对算力要求低，A10/L4 成本更低；H100 属性能过剩，仅在统一集群时考虑 | . | **7B-30B，全参训练** | H100 | 在 FP8 + 梯度检查点 + ZeRO 下可高效训练PyTorch/TensorFlow 生态最成熟，调试工...
- **万字长文解析：从H100 到B200，GPGPU 与大模型扩展性深度分析** (relevance: 61%) <https://zhuanlan.zhihu.com/p/1985478405458788975> GPU 算力增速远超带宽提升,数据并行的临界Batch Size 从H100 的2500 tokens/GPU 激增到B200 的5625 tokens/GPU; 应对策略包括FP8/FP4 量化、MoE 稀疏
- **揭秘！阿里隐藏大招曝光，一文读懂超火GPU - 36氪** (relevance: 52%) <https://eu.36kr.com/de/p/3658910978372356> 【产品水平】：采用7nm工艺，FP16算力达800 TFLOPS，性能直逼英伟达H100的80%。 【特点】：拥有从芯片到框架（MindSpore）的闭环，主打“系统换性能”，支持16万卡级

4.数据存储

检索关键词: HBM,显存,存储,NVLink

Answer

阿里巴巴使用HBM显存和NVLink技术提升AI算力，主要依赖高带宽内存和高速互联技术。显存和NVLink提高数据传输效率。

Sources

- **别再分不清显存和内存了！一文讲透AI算力的核心秘密** (relevance: 67%) <https://developer.aliyun.com/article/1708501> GPU（显存）：直接采用数据中心级显卡（NVIDIA H100/H200，AMD MI300X，国产昇腾910B等），它们拥有80GB以上的HBM显存和超高速互联技术（NVLink）。
- **告别AI算力圈“局外人”的100词手册 - 阿里云开发者社区** (relevance: 40%) <https://developer.aliyun.com/article/1715105> 本文系统梳理AI与算力领域的100个核心术语，涵盖基础概念（如LLM、AGI、训练/推理）、硬件架构（GPU/TPU/NPU、HBM、NVLink）、数据中心（集群、液冷、PUE）及

- **小白也能看懂的国内外AI 芯片概述** (relevance: 31%) <https://zhuanlan.zhihu.com/p/667686665> NVIDIA GPU 显存有两种类型，GDDR 和 HBM，每种也有不同的型号。针对显存我们通常会关注两个指标：显存大小和显存带宽。HBM 显存通常可以提供更高的显存
- **算力之后，存力接棒！中国存储厂商“卡位战”打响 - 经理人** (relevance: 28%) <https://www.sino-manager.com/detail/10534> 这并非纸上谈兵——英伟达 DGX H100 服务器单台配置 30TB NVMe SSD，其数据吞吐速率直接决定千亿参数大模型的训练效率；而 HBM(高带宽内存)通过 TSV 硅通孔技术堆叠
- **传昇腾950PR获字节和阿里巴巴大单!销售预计过500亿! - 网易** (relevance: 27%) <https://www.163.com/dy/article/KP8MCD2B05568W0A.html> 据华为介绍，Atlas 350 的单卡算力达到了英伟达 H20 的 2.87 倍，是目前国内唯一支持 FP4 低精度的推理产品；HBM（高带宽内存）容量是 H20 的 1.16 倍，达到了 112GB，多模式

4.数据加速

检索关键词: FlashAttention,量化,推理优化

Answer

FlashAttention optimizes large model inference by reducing memory access complexity from $O(N^2)$ to $O(N)$ through block computation. It combines quantization and recomputation to speed up reasoning. This technique enhances both training and inference efficiency.

Sources

- **LLM推理加速4：MInference/FlashAttention-3/EAGLE-2/Q- ...** (relevance: 70%) <https://zhuanlan.zhihu.com/p/708128459> 考虑量化也可以加速推理，因此公式变为 $Y=(Q(X)\odot M)W^T$ 。量化. 这种方法可以和量化一起使用，公式则变成 $Y=(Q(X)\odot M)Q(W^T)$ 。为了进一步提高激活的稀疏性，对
- **大模型推理加速技术：FlashAttention原理与实现** (relevance: 65%) <https://developer.aliyun.com/article/1685039> FlashAttention 的核心思想是通过分块计算避免存储完整的注意力矩阵，实现 IO 复杂度从 $O(N^2)$ 到 $O(N)$ 的优化。
- **训练加速：FlashAttention集成- 推导注意力优化的独特内存节省** (relevance: 63%) <https://developer.aliyun.com/article/1684066> 自适应注意力优化：根据输入特性和模型架构动态调整优化策略，实现最佳性能。端到端优化：将 FlashAttention 与模型结构设计、训练策略等更深入地融合，实现端

- **Oumi推理加速：FlashAttention集成指南** (relevance: 54%) https://blog.csdn.net/gitblog_00687/article/details/151298421 核心优化机制 · 分块计算（Tiling）：将注意力矩阵分割为小块，实现局部计算，避免完整矩阵存储 · 重计算（Recomputation）：在反向传播时重新计算部分中间结果，替代
- **一文掌握大模型推理加速：FlashAttention与PagedAttention ...** (relevance: 47%) <https://adg.csdn.net/69708750437a6b40336a8ee2.html> 文章详细解析了FlashAttention和PagedAttention两种大模型推理加速技术。FlashAttention通过分块计算和重计算机制将内存访问次数从 $O(n^2)$ 降至 $O(n)$ ，

4.Agent

检索关键词: 智能体,Agent,AutoGPT

Answer

An AI agent, like AutoGPT, is an autonomous software system that can perform tasks independently. It uses machine learning to understand and interact with its environment. AutoGPT is an example of an advanced AI agent framework.

Sources

- **autogpt和智能体的区别- Agent - CSDN博客** (relevance: 100%) <https://blog.csdn.net/vinnieg/article/details/140550243> 以AutoGPT为例浅谈智能体Agent. AutoGPT是一个AI agent（智能体），也是开源的应用程序，结合了GPT-4和GPT-3.5技术，给定自然语言的目标，它将尝试将其
- **AI Agent智能体应用原理剖析：AutoGPT、HuggingFPT等#大模型#AI ...** (relevance: 100%) <https://www.bilibili.com/video/BV1KC4y1S7ZG/> AI Agent智能体应用原理剖析：AutoGPT、HuggingFPT等#大模型#AI系统#智能体. ZOMI酱. 相关推荐. 查看更多. 【大模型推理】大模型推理Prefill 和Decoder 阶段详解.
- **深入浅出完整解析AI Agent（AI智能体）的核心基础知识 - 知乎专栏** (relevance: 100%) <https://zhuanlan.zhihu.com/p/1919046969076195976> 这通常依赖于其训练数据中对各种工具功能的“理解”。在现代AI框架（如LangChain, AutoGPT）中，我们可以预先为模型提供一个工具清单，其中包含每个工具的名称、
- **单智能体框架AutoGPT有哪些优缺点？ - 飞书文档** (relevance: 100%) <https://docs.feishu.cn/v/wiki/Uwh7wnNN0iWbwqknboocnmMlnbe/ah> 1.2 AI Agent 和LLM、RPA 的区别. LLM 和AI Agent 的区别在于：AI Agent 可以独立思考，并做出行动. RPA 和AI Agent 的区别在于：AI Agent 能够处理未知环境信息. 1.3 AI

- **AI-Compass Agent智能体技术生态：整合AutoGPT、LangGraph、CrewAI_牛客网**
(relevance: 100%) <https://www.nowcoder.com/discuss/776566610302656512>
- 1.Refact-AI-Agent. # 1.Agently. * 新闻汇总报告生成器AgentEra/Agently-Daily-News-Collector: An open-source LLM based automatically daily news collecting workflow showcase powered by Agently AI application development framework. * camel-ai/camel: CAMEL: The first and the best multi-agent framework. # 1.R...

五、整体技术趋势判断

5.1 战略方向

基于2026年04月19日的检索结果，阿里巴巴的AI战略呈现以下特点：

1. 技术路线:
2. 产品布局:
3. 生态建设:

5.2 竞争态势

- vs OpenAI:
- vs Google:
- vs 国内竞品:

5.3 未来展望

预测阿里巴巴在未来3-6个月可能的技术/产品动向：

- 1.
- 2.
- 3.

六、参考来源

- Tavily Search 检索结果
 - 企业官方博客/公告
 - 技术媒体（量子位、机器之心等）
 - 学术论文（arXiv）
-

本报告由 OpenClaw AI 系统自动生成

报告版本: v1.0

生成时间: Sun Apr 19 06:00:45 AM CST 2026